

第一章 概述

§1-1 模式识别的基本概念

- 两类别问题/二分类
 - 待识别的目标物体属于两种类型之一，二选一
- 多类别问题
 - 待识别的目标物体属于多种（两种以上）类型之一

第一章 概述

§1-1 模式识别的基本概念

- 两类别问题/二分类
 - 两类目标物体不分主次
 - 情感识别（正面评价/负面评价）
 - 性别识别
 - 猫狗分类
 - 感兴趣的目標物体只有一种，分为正负类

第一章 概述

§1-1 模式识别的基本概念



→ *Dog*



→ *Cat*

第一章 概述

§1-1 模式识别的基本概念

- 多类别问题


- 单标签分类：目标物体只属于一种类别
- 多标签分类：目标物体可属于多种类别

第一章 概述

§1-1 模式识别的基本概念

- 单标签分类

MNIST 是一个手
写数字图像数据集



第一章 概述

§1-1 模式识别的基本概念

■ 多标签分类

文章标签

知乎

关注

推荐

热榜

专栏

圈子

New

付费咨询

知学堂

斯诺登事件立的一等功

模块五：安全、评测与工程化（生产篇）

#	参考文章	内容	核心价值
12	Demystifying evals for AI agents (anthropic.com/engineering)	Agent 评测怎么做	评测体系设计
13	Beyond permission prompts: Claude Code sandboxing (anthropic.com/engineering)	Agent 安全：从权限提示到沙箱隔离	安全与自主性的平衡
14	Claude Code: Best practices for agentic coding (anthropic.com/engineering)	Coding Agent 最佳实践	Coding Agent 的工程经验
15	A postmortem of three recent issues (anthropic.com/engineering)	Agent 故障复盘：三个真实案例分析	从失败中学习


发布于 2026-01-13 17:55 · 广东

人工智能

Agent

第一章 概述

§1-2 模式识别发展史




第一章 概述

§1-2 模式识别发展史

- 1929年，斯塔夫·陶谢克 光电发明阅读机，能够阅读0-9的数字。被公认为 OCR（光学字符识别）技术的雏形



Gustav Tauschek




阅读机 Reading Machine, 1929

- 30年代 Fisher提出统计分类理论, 奠定了统计模式识别的基础。因此, 在60~70年代, 统计模式识别发展很快。[类内距离小, 类间距离大]

第一章 概述

§1-2 模式识别发展史

- 50年代 Noam Chomsky 提出**形式语言理论**，美籍华人付京荪 提出**句法结构模式识别**，开创结构模式识别的思路。



句法模式识别，1974



CS 傅京荪

- 60年代 L.A.Zadeh提出了**模糊集理论**，模糊模式识别理论得到了较广泛的应用。


第一章 概述

§1-2 模式识别发展史

- 80年代 Hopfield提出**神经网络模型理论**。近些年人工神经网络在模式识别和人工智能上得到较广泛的应用。




David Rumelhart



BP 神经网络, 1986

- 90年代小样本学习理论，**支持向量机**也受到了很大的重视。



支持向量机 SVM, 1995



Vladimir Vapnik


第一章 概述

§1-2 模式识别发展史

- 2006年至今深度学习的兴起，模式识别取得突破性进展。



Geoffrey Hinton



深度学习 Deep Learning, 2006

第一章 概述

§1-3 模式识别系统

➤ 监督模式识别系统设计目的



分类的目的
是什么？

如何根据这些
特征将这些样
本分类？

case	sex	glasses	moustache	smile	hairs	looking
1	m	y	n	y	grey	0.5
2	f	n	n	y	yellow	0.6
3	m	y	n	n	green	0.8
4	m	n	n	n	yellow	0.2
5	m	n	n	y?	black	0.1
6	m	n	y	n	black	0.3
7	m	y	n	y	brown	0.7
8	m	n	n	y	grey	0.3
9	m	y	y	y	no	0.1
10	f	n	n	n	yellow	0.8
11	m	n	y	n	no	0.3
12	f	n	n	n	brown	0.4


• 这些人应该分成几类？根据什么分？
• 如果要求把这些入分成两类，如何分？
根据性别？是否戴眼镜？头发颜色？长相？
...

第一章 概述

§1-3 模式识别系统

➤ 监督模式识别系统处理流程

- 有已知样本情况：监督模式识别




第一章 概述

§1-3 模式识别系统

➤ 监督模式识别系统处理流程

- 有已知样本情况：监督模式识别




- **信息获取**：通过传感器将物理世界的模式转换为可处理的数字信号。例：用麦克风录一段语音，得到音频波形数据
- **预处理**：对原始数据进行去噪、归一化等操作，提升数据质量。例：去除录音中的背景噪声，统一采样率

第一章 概述

§1-3 模式识别系统

➤ 监督模式识别系统处理流程

- 有已知样本情况：监督模式识别




- **特征提取**：从原始数据中构造能反映本质差异的特征。例：从语音信号中提取MFCC频谱特征
- **特征选择**：从已有特征集合中挑选出最有效的子集，去除冗余和无关特征。例：20维特征中只保留对区分“猫叫vs狗叫”贡献最大的8维

第一章 概述

§1-3 模式识别系统

➤ 监督模式识别系统处理流程

- 有已知样本情况：监督模式识别



- **分类器设计（训练）**：利用已标注的训练样本，学习从特征空间到类别的决策规则。例：用500段标注好的动物叫声训练一个神经网络分类器
- **分类决策（识别）**：将训练好的分类器应用于新样本，输出其所属类别。例：输入一段新录音，模型输出"猫叫"

第一章 概述

§1-3 模式识别系统


- 例子——鱼的分类
- 自动按品种分类传送带上的鱼类（鲈鱼和鲑鱼）



第一章 概述

§1-3 模式识别系统

■ 例子——鱼的分类



鲈鱼

种类

鲑鱼

体延长而侧扁，眼间隔微凹。其间有**4**条隆起线。口大，下颌长于上颌。吻尖，牙细小，在两颌、犁骨及腭骨上排列成绒毛状牙带。前鳃盖骨后缘有细锯齿，隅角及下缘有钝棘。第一背鳍发达并有**12**根硬棘。第二背鳍由**13**根鳍条组成；腹鳍位于胸鳍始点稍后方。第二背鳍基部浅黄色，胸鳍黄绿色，尾鳍叉形呈浅褐色。

鲑鱼上下嘴边无牙，只在口腔中部有少量小牙。体型细长如潜水艇状，鱼鳞细小，用肉眼极难看到，身上的斑点为白色、灰色、黄色、桔红色和鲜红色，腹部的鳍、翅及尾部下沿都有一条白色的条纹边，非常明显美观。



第一章 概述

§1-3 模式识别系统

■ 例子——鱼的分类

■ 问题分析

- 架设一台摄像机，拍摄若干样品的图像用来提取特征
 - 长度
 - 光泽
 - 宽度
 - 鳍的数量和形状
 - 嘴的位置, etc...
- 这是用于我们的分类器的所有可能的特征

第一章 概述

§1-3 模式识别系统

- 例子——鱼的分类
- 预处理：使用图像分割技术将鱼彼此分开，并将鱼同背景分开
- 特征提取与选择：将每条鱼的信息送入一个特征提取器，其作用是通过测量特定的“特征”或“属性”来简化原始数据
- 分类决策：将特征传送给一个分类器，并期望减少将鲑鱼和鲈鱼错分的数目


第一章 概述

§1-3 模式识别系统

- 例子——鱼的分类
- 分类
 - 选择鱼的长度作为一种可能的特征

第一章 概述

§1-3 模式识别系统



第一章 概述

§1-3 模式识别系统


- 例子——鱼的分类

长度本身不是一个好的特征!

选择光泽度作为一种可能的特征

第一章 概述


§1-3 模式识别系统



第一章 概述

§1-3 模式识别系统

- 例子
- 采用鱼的光泽度和宽度




第一章 概述

§1-3 模式识别系统

■ 例子

Salmon: 鲑鱼

Sea bass: 鲈鱼




第一章 概述

§1-3 模式识别系统

■ 例子

复杂的分类算法导致复杂的判定边界。判定曲线被过分调谐到这些训练样本上，其推广能力却很差


分类器的推广能力：
即分类器对未知模式的正确分类的能力



第一章 概述

§1-3 模式识别系统

■ 例子



第一章 概述

§1-3 模式识别系统


- 模式识别的方法
 - 模板匹配
 - 统计方法
 - 句法方法
 - 神经网络

第一章 概述

§1-3 模式识别系统

■ 模板匹配


- 首先对每个类别建立一个或多个模板
- 输入样本和数据库中每个类别的模板进行比较，求相关性或距离
- 根据相关性或距离大小进行决策



第一章 概述

§1-3 模式识别系统

- 模板匹配
 - 优点：直接、简单
 - 缺点：适应性差
 - 形变模板



第一章 概述

§1-3 模式识别系统

- 统计方法

- 根据训练样本，建立决策边界
- 统计决策理论——根据每一类总体的概率分布决定决策边界
- 判别分析方法——给出带参数的决策边界，根据某种准则，由训练样本决定“最优”的参数
- 本课程的重点内容

第一章 概述

§1-3 模式识别系统

- 统计方法

- 优点

- 严谨的数学基础：所有推导都建立在概率论和数理统计之上，可以清晰地通过数学公式解释为什么模型做出了某个决策
 - 小样本表现优异：在数据量较少的情况下，往往能通过先验知识和正则化取得非常稳健的效果
 - 计算效率高：训练和推理速度通常极快，对硬件资源要求低

第一章 概述

§1-3 模式识别系统

- 统计方法

- 缺点

- 对特征工程高度依赖：无法直接处理原始数据（如像素、原始音频波形），需要人类专家手工提取有意义的特征
 - 处理高维、非线性数据的局限性：当面对极其复杂的模式（如自然语言语义、大规模图像识别）时，其表达能力往往逊色于多层神经网络
 - 先验假设的局限：很多方法假设数据符合某种特定分布（比如高斯分布）。如果现实数据的分布与假设偏差很大，模型的性能会大幅下降

第一章 概述

§1-3 模式识别系统

■ 句法方法



- 许多复杂的模式可以分解为简单的子模式，这些子模式组成所谓 “基元”
- 每个模式都可以由基元根据一定的关系来组成
- 基元可以认为是语言中的字母，每个模式都可以认为是一个句子，关系可以认为是语法

第一章 概述

§1-3 模式识别系统

■ 句法方法

- 模式的相似性由句子的相似性来决定
- 优点：适合结构性强的模式
- 缺点：抗噪声能力差，计算复杂度高




第一章 概述

§1-3 模式识别系统

■ 神经网络

- 大规模并行计算
- 学习、推广、自适应、容错、分布表达和计算
- 优点：可以有效的解决一些复杂的非线性问题
- 缺点：缺少有效的学习理论



第一章 概述

§1-4 模式识别的基本问题

- 样本的表示方法
- 模式类的紧致性
- 样本的相似与分类
- 数据的标准化

第一章 概述

§1-4 模式识别的基本问题

模式(样本)表示方法

1) 向量表示： 假设一个样本有 n 个变量(特征)

$$X = (X_1, X_2, \dots, X_n)^T$$

2) 矩阵表示： N 个样本， n 个变量(特征)

变量 样本	x_1	x_2	$\dots$	x_n
X_1	X_{11}	X_{12}	$\dots$	X_{1n}
X_2	X_{21}	X_{22}	$\dots$	X_{2n}
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
X_N	X_{N1}	X_{N2}	$\dots$	X_{Nn}

第一章 概述


§1-4 模式识别的基本问题

3) 几何表示

一维表示 (标量)

$$X_1 = 1.5$$


$$X_2 = 3$$



二维表示 (向量)

$$X_1 = (1, 2)^T$$


$$X_2 = (2, 1)^T$$



三维表示 (向量)

$$X_1 = (1, 1, 0)^T$$

$$X_2 = (1, 0, 1)^T$$



第一章 概述



§1-4 模式识别的基本问题

4) 基元 (链码) 表示：
在右侧的图中八个基元
分别表示0, 1, 2, 3,
4, 5, 6, 7, 八个方向
和基元线段长度。

则右侧样本可以表示为

$$X_1 = 006666$$

这种方法将在句法模式识别中用到。




第一章 概述


§1-4 模式识别的基本问题

模式类的紧致性

临界点(样本)：在多类样本中，某些样本的值有微小变化时就变成另一类样本称为临界样本（点）。



无临界点




有临界点

第一章 概述

§1-4 模式识别的基本问题

模式类的紧致性

- **紧致集**：同一类样本的分布比较集中，没有或临界样本很少，这样的模式类称**紧致集**。



第一章 概述

§1-4 模式识别的基本问题

紧致集的性质

- ① 要求临界点很少
- ② 集合 (类别) 内的任意两点的连线, 在线上的点属于同一集合
- ③ 集合内的每一个点都有足够大的邻域, 并且在邻域内只包含同一集合的点
 - 集合内的任何一个样本点, 它的周围 (一个小圈子内) 都应该还有空间
 - 同一类的点是成群结队聚在一起的, 而不是和别种类混杂在一起

第一章 概述

§1-4 模式识别的基本问题

样本的相似与分类

- 1) 两个样本 x_i , x_j 之间的相似性度量标准需要满足：
 - ① 应为非负值
 - ② 样本与本身的相似性度量应最大
 - ③ 度量应满足对称性
 - ④ 在满足紧致性的条件下，相似性应该是点间距离的单调函数

第一章 概述

§1-4 模式识别的基本问题

样本的相似与分类

2) 用各种距离表示相似性：

已知两个样本

$$\mathbf{x}_i = \{x_{i1}, x_{i2}, x_{i3}, \cdots, x_{in}\}^T$$

$$\mathbf{x}_j = \{x_{j1}, x_{j2}, x_{j3}, \cdots, x_{jn}\}^T$$

第一章 概述

§1-4 模式识别的基本问题

① 绝对值距离/曼哈顿距离/出租车距离

$$d_{ij} = \sum_{k=1}^n |x_{ik} - x_{jk}|$$

- 为**L₁-距离**或**城市区块距离**，即两点在各个坐标轴方向上的位移绝对值之和

第一章 概述

§1-4 模式识别的基本问题

② 欧几里德距离（欧氏距离）

$$d_{ij} = \sqrt{\sum_{k=1}^n (x_{ik} - x_{jk})^2}$$

欧氏距离即两点之间的直线距离

第一章 概述

§1-4 模式识别的基本问题

③明考夫斯基距离（明氏距离）

是欧氏距离和曼哈顿距离的推广与概括，它通过一个可变参数 q 定义两点间的距离

$$d_{ij}(q) = \left(\sum_{k=1}^n |x_{ik} - x_{jk}|^q \right)^{1/q}$$

当 $q = 1$ 时为绝对值距离，当 $q = 2$ 时为欧氏距离

第一章 概述

§1-4 模式识别的基本问题

④切比雪夫距离

指两点在所有维度坐标差的绝对值中的最大值

$$d_{ij}(\infty) = \max_{1 \leq k \leq n} |x_{ik} - x_{jk}|$$

当明氏距离公式中的 q 趋向于无穷大时，它就会变成切比雪夫距离

第一章 概述

§1-4 模式识别的基本问题

⑤ 马哈拉诺比斯距离（马氏距离）

考虑数据分布特征的尺度无关距离，它通过协方差矩阵对空间进行“标准化”处理，消除维度间相关性的干扰

$$d_{ij} = \sqrt{(\mathbf{x}_i - \mathbf{x}_j)^T \Sigma^{-1} (\mathbf{x}_i - \mathbf{x}_j)}$$

- 其中 Σ 为协方差矩阵
- 当协方差矩阵是单位矩阵时，马氏距离会退化成欧氏距离

第一章 概述

§1-4 模式识别的基本问题

距离计算例子

共 4 个鸢尾花样本，每个样本
3 个特征，分别为花萼长度、
花萼宽度、花瓣长度

样本 1 (x_1): [1, 1, 1]

样本 2 (x_2): [2, 3, 3]

样本 3 (x_3): [1, 2, 1]

样本 4 (x_4): [2, 2, 3]

计算 x_1 到 x_2 的距离 (相似性)



第一章 概述

§1-4 模式识别的基本问题

1. 基础距离 (只看 x_1 和 x_2 的差值)

先算出各维度的差值: $\Delta = [2 - 1, 3 - 1, 3 - 1] = [1, 2, 2]$

- 曼哈顿距离 (L_1): 直接相加

$$1 + 2 + 2 = 5$$

- 欧氏距离 (L_2): 平方和开根号

$$\sqrt{1^2 + 2^2 + 2^2} = \sqrt{1 + 4 + 4} = \sqrt{9} = 3$$

- 明氏距离 ($p = 3$): 三次方再开三次方根

$$\sqrt[3]{1^3 + 2^3 + 2^3} = \sqrt[3]{1 + 8 + 8} = \sqrt[3]{17} \approx 2.57$$

- 切比雪夫距离 (L_∞): 找最大的差值

$$\max(1, 2, 2) = 2$$

样本 1 (x_1): $[1, 1, 1]$

样本 2 (x_2): $[2, 3, 3]$

样本 3 (x_3): $[1, 2, 1]$

样本 4 (x_4): $[2, 2, 3]$

第一章 概述

§1-4 模式识别的基本问题

距离计算例子

马氏距离在手算时很麻烦，但流程为：

1. 计算均值向量
2. 计算协方差矩阵
3. 计算协方差矩阵对应的逆矩阵
4. 根据公式计算出距离数值

样本 1 (x_1): $[1, 1, 1]$

样本 2 (x_2): $[2, 3, 3]$

样本 3 (x_3): $[1, 2, 1]$

样本 4 (x_4): $[2, 2, 3]$


第一章 概述

§1-4 模式识别的基本问题

⑥ 夹角余弦相似度

- 用向量空间中两个向量夹角的余弦值衡量两个样本间差异的大小
- 如果两个向量的方向一致，即夹角接近零，余弦值接近1，那么这两个向量就相近

$$\begin{aligned}\cos(\theta) &= \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} \\ &= \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}\end{aligned}$$



样本间夹角小的为一类，具有高相似性

因为x1, x2 的夹角小，所以x1, x2 最相似

第一章 概述

§1-4 模式识别的基本问题

■ 例子：

- 用户对内容评分，5分制。
- A和B两个用户对两个商品的评分分别为A：(1,2)和B：(4,5)。
- 使用余弦相似度得出的结果是0.98，看起来两者极为相似，但从评分上看 A 不喜欢这两个东西，而B比较喜欢。
- 造成这个现象的原因就在于，余弦相似度没法衡量每个维数值的差异，**对数值的不敏感**导致了结果的误差。

第一章 概述

§1-4 模式识别的基本问题

- 调整余弦相似度

- 用于修正上述不合理性
- 所有维度上的数值都减去一个均值，比如 A 和 B 的评分均值都是3，那么调整后为 $(-2, -1)$ 和 $(1, 2)$ ，再用余弦相似度计算，得到 -0.8 ，相似度为负值并且差异不小，但显然更加符合现实

第一章 概述

§1-4 模式识别的基本问题

数据的标准化

- 使各指标的数值都处于同一个数量级别上，例如 $0 \sim 1$ 或 $-1 \sim 1$ 的区间内

第一章 概述

§1-4 模式识别的基本问题

(1) 极差标准化：

将原始数据缩放到 $[0, 1]$ 之间，使得不同量纲的特征具有可比性

对于每一列特征，标准化的公式为：

$$x' = \frac{x - \min}{\max - \min}$$

如果有新数据加入，可能会导致最大值和最小值变化，需要重新进行标准化

第一章 概述

§1-4 模式识别的基本问题

(1) 极差标准化：

特征 2 (f_2): [1, 3, 2, 2]

- 最大值 (max) = 3, 最小值 (min) = 1
- 极差 (max - min) = 3 - 1 = 2

• 计算结果：

- $x_{1,2} \rightarrow (1 - 1)/2 = 0$
- $x_{2,2} \rightarrow (3 - 1)/2 = 1$
- $x_{3,2} \rightarrow (2 - 1)/2 = 0.5$
- $x_{4,2} \rightarrow (2 - 1)/2 = 0.5$

样本 1 (x_1): [1, 1, 1]

样本 2 (x_2): [2, 3, 3]

样本 3 (x_3): [1, 2, 1]

样本 4 (x_4): [2, 2, 3]



第一章 概述

§1-4 模式识别的基本问题

(2) 标准差标准化 (Z-score标准化)

将数据按比例缩放，使得处理后的数据均值为 0，标准差为 1

对于每一列特征，标准化的公式为：

$$z = \frac{x - \mu}{\sigma} \rightarrow \mu = \frac{\sum_{i=1}^n x_i}{n}$$

其中：

- μ 是该特征的均值。
- σ 是该特征的标准差。

$$\sigma = \sqrt{\frac{\sum_{i=1}^n (x_i - \mu)^2}{n}}$$

第一章 概述

§1-4 模式识别的基本问题

(2) 标准差标准化 (Z-score标准化)

特征 2 (f_2): [1, 3, 2, 2]

- 均值 (μ_2): $(1 + 3 + 2 + 2)/4 = 2$

- 标准差 (σ_2): $\sqrt{[(1-2)^2 + (3-2)^2 + (2-2)^2 + (2-2)^2]/4} = \sqrt{0.5} \approx 0.707$

- 标准化后:

- $x_{1,2} \rightarrow (1 - 2)/0.707 \approx -1.414$

- $x_{2,2} \rightarrow (3 - 2)/0.707 \approx 1.414$

- $x_{3,2} \rightarrow (2 - 2)/0.707 = 0$

- $x_{4,2} \rightarrow (2 - 2)/0.707 = 0$

样本 1 (x_1): [1, 1, 1]

样本 2 (x_2): [2, 3, 3]

样本 3 (x_3): [1, 2, 1]

样本 4 (x_4): [2, 2, 3]

与极差标准化固定在 $[0, 1]$ 不同，标准差标准化没有固定的理论取值范围

识别系统的性能评价

		True condition			
Total population		Condition positive	Condition negative	Prevalence = $\frac{\Sigma \text{Condition positive}}{\Sigma \text{Total population}}$	Accuracy (ACC) = $\frac{\Sigma \text{True positive} + \Sigma \text{True negative}}{\Sigma \text{Total population}}$
Predicted condition	Predicted condition positive	True positive	False positive, Type I error	Positive predictive value (PPV), Precision = $\frac{\Sigma \text{True positive}}{\Sigma \text{Predicted condition positive}}$	False discovery rate (FDR) = $\frac{\Sigma \text{False positive}}{\Sigma \text{Predicted condition positive}}$
	Predicted condition negative	False negative, Type II error	True negative	False omission rate (FOR) = $\frac{\Sigma \text{False negative}}{\Sigma \text{Predicted condition negative}}$	Negative predictive value (NPV) = $\frac{\Sigma \text{True negative}}{\Sigma \text{Predicted condition negative}}$
		True positive rate (TPR), Recall, Sensitivity, probability of detection, $\text{Power} = \frac{\Sigma \text{True positive}}{\Sigma \text{Condition positive}}$	False positive rate (FPR), Fall-out, probability of false alarm $= \frac{\Sigma \text{False positive}}{\Sigma \text{Condition negative}}$	Positive likelihood ratio (LR+) = $\frac{\text{TPR}}{\text{FPR}}$	Diagnostic odds ratio (DOR) = $\frac{\text{LR+}}{\text{LR-}}$ $F_1 \text{ score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$
		False negative rate (FNR), Miss rate = $\frac{\Sigma \text{False negative}}{\Sigma \text{Condition positive}}$	Specificity (SPC), Selectivity, True negative rate (TNR) $= \frac{\Sigma \text{True negative}}{\Sigma \text{Condition negative}}$	Negative likelihood ratio (LR-) = $\frac{\text{FNR}}{\text{TNR}}$	


识别系统的性能评价

■ 两分类问题

- **True Positive** (真正, TP) : 预测为正类, 且实际确实是正类的数目
- **True Negative** (真负, TN) : 预测为负类, 且实际确实是负类的数目
- **False Positive** (假正, FP) : 预测为正类, 但实际却是负类 (误报/虚警, 模型发生第一类错误)
- **False Negative** (假负, FN) : 预测为负类, 但实际却是正类 (漏报/漏诊, 模型发生第二类错误)

混淆矩阵

预测类别	真实类别	
	1	0
1 Positive (阳)	True Positive 真阳	False Positive 假阳
0 Negative (阴)	False Negative 假阴	True Negative 真阴




识别系统的性能评价

■ 准确率 (Accuracy) :

预测正确样本数与总样本数的比值

$$ACC = \frac{TP + TN}{TP + TN + FP + FN}$$

预测类别	真实类别	
	1	0
1 Positive (阳)	True Positive 真阳	False Positive 假阳
0 Negative (阴)	False Negative 假阴	True Negative 真阴




识别系统的性能评价

■ 精确率 (Precision) :

在所有预测为正的样本中，真正正例的比例（预测的质量）

$$\text{Precision} = \frac{TP}{TP+FP}$$

预测类别	真实类别	
	1	0
1 Positive (阳)	True Positive 真阳	False Positive 假阳
0 Negative (阴)	False Negative 假阴	True Negative 真阴




识别系统的性能评价

■ 召回率 (Recall) :

在所有真实为正的样本中，被模型正确检出的比例（覆盖的广度），和**灵敏度** (Sensitivity) 等价

$$\text{Recall} = \frac{TP}{TP + FN}$$

预测类别	真实类别	
	1	0
1 Positive (阳)	True Positive 真阳	False Positive 假阳
0 Negative (阴)	False Negative 假阴	True Negative 真阴



识别系统的性能评价


■ 特异度 (Specificity) :

在所有实际为阴性的样本中，被模型正确判定为阴性的比例

$$\text{Specificity} = \frac{TN}{FP + TN}$$

应用场景：在确认诊断或重大手术决策前，需要极高的特异度，以确保不会对健康人进行不必要的治疗

预测类别	真实类别	
	1	0
1 Positive (阳)	True Positive 真阳	False Positive 假阳
0 Negative (阴)	False Negative 假阴	True Negative 真阴




识别系统的性能评价

■ 综合评价指标 (F-Measure)

综合考虑 **精确率** (Precision) 与 **召回率** (Recall) , 避免单一指标偏高导致的评估失真 , 通过参数 β 进行加权调和平均


$$F_{\beta} = (1 + \beta^2) \cdot \frac{\text{precision} \cdot \text{recall}}{(\beta^2 \cdot \text{precision}) + \text{recall}}$$

参数 β 是非负数



识别系统的性能评价

- **综合评价指标 (F-Measure)**
- β 的含义是指 recall 比 precision 重要的倍数，三种特殊取值：
 - F_1 measure : 认为 recall 和 precision 同等重要
 - F_2 measure : 认为 recall 比 precision 重要 (更重视漏诊率)
 - $F_{0.5}$ measure : 认为 recall 没 precision 重要 (减少漏诊率的影响)




性能评价指标计算示例

 案例背景：“早八生死线：这课点名吗？”

情境：现在是早上 7:50。小明躺在床上，面对一个极其纠结的二分类判别任务：

- 正类 (Positive): 老师要点名（目标：必须到场，否则扣学分）。
- 负类 (Negative): 老师不点名（目标：继续睡觉，实现睡眠自由）。
- 小明根据“今天上什么课”、“今天不是周五”、“今天天气如何”等特征做出了判断。一个学期下来，他一共经历了 **50** 次这样的生死抉择



性能评价指标计算示例

- **TP (真阳性) = 10 次**：你预判要点名并挣扎着去了，老师真的点了。

结果：学分保住，虽然你在课上补觉，但你是胜利者。

- **FP (假阳性) = 5 次**：你预判要点名并去了，结果老师根本没点。


结果：你损失了宝贵的 1.5 小时睡眠，在教室里追悔莫及（误报）。

- **FN (假阴性) = 5 次**：你预判不点名并继续睡，结果老师居然点了。

结果：你收到了室友的紧急短信，但为时已晚，平时分扣除（漏报）。

- **TN (真阴性) = 30 次**：你预判不点名并心安理得地睡了，老师确实没点。

结果：双赢！你获得了完美的睡眠，且没有任何学分损失。



性能评价指标计算示例

① Accuracy (准确率)

衡量整体判断对的概率。

TP: 10 次

FP: 5 次

FN: 5 次

TN: 30 次

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} = \frac{10 + 30}{50} = 0.80$$

② Precision (精确率)


衡量当你决定去上课时，老师真的点名的概率（查准率）。

$$Precision = \frac{TP}{TP + FP} = \frac{10}{10 + 5} = \frac{10}{15} \approx 0.67$$

③ Recall / Sensitivity (召回率 / 灵敏度)

衡量在所有点名的日子里，你成功“出席”到的比例（查全率）。

$$Recall = \frac{TP}{TP + FN} = \frac{10}{10 + 5} = \frac{10}{15} \approx 0.67$$



性能评价指标计算示例

④ Specificity (特异度)

衡量在所有不点名的日子里，你成功在寝室补觉的概率。

$$Specificity = \frac{TN}{TN + FP} = \frac{30}{30 + 5} = \frac{30}{35} \approx 0.86$$

TP: 10 次

FP: 5 次

FN: 5 次

TN: 30 次

⑤ F1-Measure (F1 值)

由于 Precision 和 Recall 此时相等且存在冲突，用调和平均数给出综合评分。

$$F1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall} = \frac{2 \cdot 0.67 \cdot 0.67}{0.67 + 0.67} = 0.67$$


识别系统的性能评价

■ PR 曲线

以召回率 (Recall) 为横轴、精确率 (Precision) 为纵轴绘制的曲线

旨在通过变动判定阈值来全面展示模型在查准与查全之间的权衡博弈关系

曲线越靠近右上角 (1,1) , 代表模型在保持高精确率的同时也能维持高召回率, 性能越优



PR Curve



曲线上的每一个点都对应一个特定的分类阈值

- 假设黄线为阈值
 - 黄线之上，识别为**正例**
 - 黄线之下为**负例**

- 假设当前阈值为 **0.05**

- $recall = TP / (TP + FN)$
 $= 5 / (5 + 0) = 1.0$


- $precision = TP / (TP + FP)$
 $= 5 / (5 + 5) = 0.5$



红色
为正
蓝色
为负



PR 曲线

- 假设黄线为阈值
 - 黄线之上，识别为正例
 - 黄线之下为反例
- 假设当前阈值为 **0.1**
 - $recall = TP/(TP+FN)$
 $= 5/(5+0) = 1.0$
 - $precision = TP/(TP+FP)$
 $= 5/(5+4) = 0.5556$





PR 曲线

- 假设黄线为阈值
 - 黄线之上，识别为正例
 - 黄线之下为反例
- 假设当前阈值为 **0.2**
 - $recall = TP/(TP+FN)$
 $= 5/(5+0) = 1.0$
 - $precision = TP/(TP+FP)$
 $= 5/(5+3) = 0.625$





PR 曲线

- 假设黄线为阈值
 - 黄线之上，识别为正例
 - 黄线之下为反例
- 假设当前阈值为 **0.3**
 - $recall = TP/(TP+FN)$
 $= 5/(5+0) = 1.0$
 - $Precision = TP/(TP+FP)$
 $= 5/(5+2) = 0.7143$





PR 曲线

- 假设黄线为阈值
 - 黄线之上，识别为正例
 - 黄线之下为反例
- 假设当前阈值为 **0.4**
 - $recall = TP/(TP+FN)$
 $= 4/(4+1) = 0.8$
 - $precision = TP/(TP+FP)$
 $= 4/(4+2) = 0.6667$





PR 曲线

- 假设黄线为阈值
 - 黄线之上，识别为正例
 - 黄线之下为反例
- 假设当前阈值为 **0.5**
 - $recall = TP/(TP+FN)$
 $= 3/(3+2) = 0.6$
 - $precision = TP/(TP+FP)$
 $= 3/(3+2) = 0.6$





PR 曲线

- 假设黄线为阈值
 - 黄线之上，识别为正例
 - 黄线之下为反例
- 假设当前阈值为 **0.6**
 - $recall = TP/(TP+FN)$
 $= 3/(3+2) = 0.6$
 - $precision = TP/(TP+FP)$
 $= 3/(3+1) = 0.75$





PR 曲线

- 假设黄线为阈值
 - 黄线之上，识别为正例
 - 黄线之下为反例
- 假设当前阈值为 **0.7**
 - $recall = TP/(TP+FN)$
 $= 2/(2+3) = 0.4$
 - $precision = TP/(TP+FP)$
 $= 2/(2+1) = 0.6667$



PR 曲线



- 假设黄线为阈值
 - 黄线之上，识别为正例
 - 黄线之下为反例
- 假设当前阈值为 **0.8**
 - $recall = TP/(TP+FN)$
 $= 2/(2+3) = 0.4$
 - $precision = TP/(TP+FP)$
 $= 2/(2+0) = 1.0$



红色
为正
蓝色
为负

PR 曲线



- 假设黄线为阈值
 - 黄线之上，识别为正例
 - 黄线之下为反例
- 假设当前阈值为 **0.9**
 - $recall = TP/(TP+FN)$
 $= 1/(1+4) = 0.2$
 - $precision = TP/(TP+FP)$
 $= 1/(1+0) = 1.0$



红色
为正
蓝色
为负

PR 曲线


- 假设黄线为阈值
 - 黄线之上，识别为正例
 - 黄线之下为反例
- 假设当前阈值为 **1.0**
 - $recall = TP/(TP+FN)$
 $= 0/(0+5) = 0.0$
 - $precision = TP/(TP+FP)$
 $= 0/(0+0) = ?$
 - Define $0/0$ to be 1.0



红色
为正
蓝色
为负

PR 曲线

- 连接这些点，生成PR curve
- 这里使用线性插值




ROC 曲线

以假阳性率 (1-Specificity) 为横轴、真阳性率 (Sensitivity/Recall) 为纵轴绘制的曲线

旨在通过变动判定阈值来全面展示模型在捕捉正类与误伤负类之间的权衡性能

其曲线下方的面积 (AUC) 介于 0.5 到 1.0 之间, 越接近于 1.0 模型分类性能越好; 若等于 0.5 说明模型对正样本和负样本的评分分布完全重合



PR 曲线 VS ROC 曲线

维度	AUC (Area Under ROC)	AUPR (Area Under PR)
主要坐标轴	TPR (Recall) vs. FPR (假阳性率)	Recall vs. Precision (精确率)
数据平衡性	适用于 类别均衡 的数据集。	专用于 类别极度不平衡 的数据集。
对负样本的敏感度	低 。当负样本数量剧增时，AUC 变化较小。	高 。能敏锐捕捉到负样本增加带来的误报压力。
性能侧重点	衡量模型的 排序能力 （能否将正类排在负类前面）。	衡量模型识别 稀有类别 的质量（查准与查全的平衡）。
虚警反映	反映的是“预测为正但实际为负”占 全负类 的比例。	反映的是“预测为正但实际为负”占 所有预测正类 的比例。
适用领域示例	通用二分类任务、医疗普筛。	欺诈检测、罕见病诊断、信息检索、广告点击率预测。