




第三章 概率密度函数 的估计






3.1 引言

- 贝叶斯决策需要已知：
 - 各类的先验概率 $P(\omega_i)$
 - 类条件概率密度 $p(x | \omega_i)$
 - 先验概率估计比较简单，只需根据大量样本计算出各占的比例
 - 本章重点介绍类条件概率密度的估计问题




3.1 引言

- 基于样本的两步贝叶斯决策：
 - 1. 利用样本集估计 $p(x | \omega_i)$ 和 $P(\omega_i)$, 得到估计量 $\hat{p}(x | \omega_i)$ 和 $\hat{P}(\omega_i)$
 - 为使基于样本的分类器能收敛于理论上的结果, 要求: 当样本集数目 $N \rightarrow \infty$ 时, $\hat{p}(x | \omega_i)$ 和 $\hat{P}(\omega_i)$ 收敛于 $p(x | \omega_i)$ 和 $P(\omega_i)$
 - 2. 将估计量带入贝叶斯决策规则




3.1 引言


- 利用同一类的样本估计本类的类条件概率密度 ($\hat{p}(x | \omega_i)$)
-  在本章后面的论述中，一概假定所有样本均来自同一类



3.1 引言


- 概率密度函数的估计方法分类






3.1 引言

- 概率密度函数的估计方法分类
 - **参数估计**：概率密度函数的形式**已知**，但其中部分或者全部参数未知，此时概率密度函数的估计问题就是用样本估计未知参数
 - **非参数估计**：概率密度函数的形式**未知**，或者概率密度函数不符合目前研究的任意分布模型




3.1 引言

- 参数估计中的基本概念
 - **统计量**：样本中包含着**总体**的信息，针对不同要求构造出样本的某种函数，将样本集中的**有关信息**提取出来，将该函数称之为统计量
 - 假设将 N 个同学的身高作为样本集 $\{x_1, x_2, \dots, x_N\}$
 - 构造一个函数 T ，把 N 个原始观测值表示为一个有意义的数值， $d = d(x_1, x_2, \dots, x_N)$
 - 经典统计量举例，**样本均值**、**样本方差**、**样本最大值**等



3.1 引言


- 参数估计中的基本概念
 - **参数空间**：将未知参数 θ 的可取值组成的集合称为参数空间，记作 Θ
 - **点估计**：构造一个统计量 $d = d(x_1, x_2, \dots, x_N)$ 作为参数 θ 的估计 $\hat{\theta}$
 - **估计量**：在统计学中称 $\hat{\theta}$ 是 θ 的估计量
 - **区间估计**：用区间 (d_1, d_2) 作为 θ 可能取值范围的一种估计。这个区间称为**置信区间**
 - **⚠ 本章介绍的内容均属于点估计方法**



3.1 引言

- 估计量评价标准

- **无偏性**：若参数 θ 的估计量 $\hat{\theta}$ 的数学期望等于 θ ，即 $E[\hat{\theta}] = \theta$ ，则称估计是无偏的
- **渐进无偏**：如果当样本数趋于无穷时估计才具有无偏性，即 $\lim_{n \rightarrow \infty} E[\hat{\theta}_n] = \theta$ ，则称为渐进无偏




3.1 引言

■ 估计量评价标准


- **有效性**：如果一种估计的方差比另一种估计的方差小，即 $\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2)$ ，则称方差小的估计更有效
- **一致性**：若对任意给定的正数 $\varepsilon > 0$ ，总有：


$$\lim_{n \rightarrow \infty} P\left(\left|\hat{\theta}_n - \theta\right| > \varepsilon\right) = 0$$

则称 $\hat{\theta}$ 是 θ 的一致估计。表明当样本量足够大时,估计值落在真值 $\pm\varepsilon$ 范围外的概率趋于0



参数估计方法






3.2 最大似然估计

■ 基本假设


- 类条件概率密度 $p(x | \omega_i)$ 具有某种确定的函数形式，只是其中的参数 θ 未知
- 参数 θ 是确定但未知的量（多个参数时是向量）（⚠ 与贝叶斯估计方法完全不同）
- 每类样本集记作 $\mathcal{X}_i$, $i = 1, 2, \dots, c$ ，其中每类样本都是从 $p(x | \omega_i)$ 中独立采样的，即满足独立同分布条件



3.2 最大似然估计

- 基本假设

- 为强调类条件概率密度 $p(x | \omega_i)$ 中待估计的参数，可将 $p(x | \omega_i)$ 记作 $p(x | \omega_i, \theta_i)$ 或 $p(x | \theta_i)$
- 各类样本只包含本类的分布信息，不同类别的参数是独立的，因而可以对每一类单独处理



3.2 最大似然估计


■ 似然函数

- 设样本集包含 N 个样本, $\mathcal{X} = \{x_1, x_2, \dots, x_N\}$
- 样本是独立地从 $p(x | \theta)$ 中采样得到的
- 在概率密度函数的参数为 θ 时, 取得当前样本集 X 中全部样本的概率:

$$l(\theta) = p(X | \theta) = p(x_1, x_2, \dots, x_N | \theta) = \prod_{i=1}^N p(x_i | \theta) \quad (3-2)$$

称作参数 θ 相对于样本集 X 的似然函数

$p(x | \theta)$ 的函数形式确定; 样本已知; 未知量仅有参数 θ




3.2 最大似然估计

- 最大似然估计量定义

- 如果 $\hat{\theta}$ 是参数空间 Θ 中使似然函数 $l(\theta)$ 极大化的 θ 值, 则 $\hat{\theta}$ 是 θ 的最大似然估计量:

$$\hat{\theta} = \underline{\arg \max} l(\theta) \quad (3-3)$$

使后面函数 $l(\theta)$ 取得最大值的变量对应的取值




3.2 最大似然估计

- 对数似然函数

$$H(\theta) = \ln l(\theta) = \ln \prod_{i=1}^N p(x_i | \theta) = \sum_{i=1}^N \ln p(x_i | \theta) \quad (3-4)$$

- 对数似然函数最大的 θ 值同样使得似然函数最大




3.2.2 最大似然估计的求解

- 若 θ 是一维变量

$$\frac{dl(\theta)}{d\theta} = 0 \quad \text{或} \quad \frac{dH(\theta)}{d\theta} = 0$$

- 若 θ 是由多个未知参数组成的向量
 - 对 θ 的每一维分别求偏导：

$$\nabla_{\theta} l(\theta) = 0 \quad \text{或} \quad \nabla_{\theta} H(\theta) = 0$$



3.2.2 最大似然估计的求解


■ 指数分布求解例子

设样本集 $\mathcal{X} = \{x_1, x_2, \dots, x_N\}$ 独立同分布，服从指数分布，其概率密度函数为：

$$p(x|\lambda) = \lambda e^{-\lambda x}, \quad x \geq 0, \lambda > 0$$

唯一未知参数： λ （可理解为"事件发生率"）

目标：用 MLE 估计 λ



3.2.2 最大似然估计的求解

■ 指数分布求解例子

Step 1: 构造似然函数

$$l(\lambda) = \prod_{i=1}^N p(x_i|\lambda) = \prod_{i=1}^N \lambda e^{-\lambda x_i} = \lambda^N \exp\left(-\lambda \sum_{i=1}^N x_i\right)$$

Step 2: 取对数似然

$$H(\lambda) = \ln l(\lambda) = N \ln \lambda - \lambda \sum_{i=1}^N x_i$$

3.2.2 最大似然估计的求解

■ 指数分布求解例子


Step 3: 对 λ 求导, 令其为零

$$H(\lambda) = \ln l(\lambda) = N \ln \lambda - \lambda \sum_{i=1}^N x_i$$

$$\frac{dH(\lambda)}{d\lambda} = \frac{N}{\lambda} - \sum_{i=1}^N x_i = 0$$

Step 4: 解方程

$$\frac{N}{\hat{\lambda}} = \sum_{i=1}^N x_i$$



3.2.2 最大似然估计的求解

- 指数分布求解例子

$$\hat{\lambda} = \frac{N}{\sum_{i=1}^N x_i}$$

- 若有五个样本 $\mathcal{X} = \{1, 2, 3, 4, 5\}$, 带入上述公式求得 λ 的估计量为:

$$\hat{\lambda} = \frac{5}{1 + 2 + 3 + 4 + 5} = \frac{1}{3}$$

3.2.2 最大似然估计的求解

泊松分布求解例子

设样本集 $\mathcal{X} = \{x_1, x_2, \dots, x_N\}$ 独立同分布，服从泊松分布，其概率质量函数为：


$$p(x|\lambda) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x = 0, 1, 2, \dots, \quad \lambda > 0$$

阶乘 $x! = x \times (x-1) \times (x-2) \times \dots \times 2 \times 1$

唯一未知参数： λ （可理解为“单位时间内事件平均发生次数”）

离散型随机变量

目标：用 MLE 估计 λ



3.2.2 最大似然估计的求解


■ 泊松分布求解例子

第一步：构建似然函数

$$L(\lambda) = \prod_{i=1}^N p(x_i|\lambda) = \prod_{i=1}^N \frac{\lambda^{x_i} e^{-\lambda}}{x_i!}$$

第二步：对数似然函数

$$\ln L(\lambda) = \sum_{i=1}^N (x_i \ln \lambda - \lambda - \ln x_i!) = \ln \lambda \sum_{i=1}^N x_i - N\lambda - \sum_{i=1}^N \ln x_i!$$



3.2.2 最大似然估计的求解


■ 泊松分布求解例子

第三步：对 λ 求导，令导数等于 0

$$\frac{d \ln L}{d \lambda} = \frac{1}{\lambda} \sum_{i=1}^N x_i - N = 0$$

第四步：解方程

$$\hat{\lambda}_{MLE} = \frac{1}{N} \sum_{i=1}^N x_i$$



3.2.2 最大似然估计的求解

■ 泊松分布求解例子

第五步：代入具体数值

观测某路口 5 分钟内每分钟的过车数为：

$$\mathcal{X} = \{2, 3, 5, 4, 1\}$$

$$\hat{\lambda}_{MLE} = \frac{2 + 3 + 5 + 4 + 1}{5} = 3$$

即估计该路口平均每分钟过车 **3** 辆。

3.2.3 正态分布下的最大似然估计

- 以单变量正态分布估计均值和方差为例

$$p(x | \theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right]$$

- 其中 均值 μ 和方差 σ^2 均为未知参数，待估计参数记作 $\boldsymbol{\theta} = [\theta_1, \theta_2]^T = [\mu, \sigma^2]^T$

3.2.3 正态分布下的最大似然估计

- 以单变量正态分布估计均值和方差为例
 - 对数似然函数求偏导：

$$\nabla_{\theta} H(\theta) = \sum_{k=1}^N \nabla_{\theta} \ln p(x_k | \theta) = 0$$

- 代入正态分布式：

$$\ln p(x_k | \theta) = \ln \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{x_k - \mu}{\sigma} \right)^2 \right]$$

替换成 θ_1, θ_2



$$= \ln \frac{1}{\sqrt{2\pi}\theta_2} \exp \left[-\frac{1}{2} \left(\frac{x_k - \theta_1}{\theta_2} \right)^2 \right]$$

整理



$$= -\frac{1}{2} \ln 2\pi\theta_2 - \frac{1}{2\theta_2} (x_k - \theta_1)^2$$

3.2.3 正态分布下的最大似然估计

- 以单变量正态分布估计均值和方差为例
 - 令偏导零 $\nabla_{\theta} H(\theta) = 0$ ，得到以下方程组：

$$\begin{cases} \sum_{k=1}^N \frac{1}{\hat{\theta}_2} (x_k - \hat{\theta}_1) = 0 \\ -\sum_{k=1}^N \frac{1}{\hat{\theta}_2} + \sum_{k=1}^N \frac{(x_k - \hat{\theta}_1)^2}{\hat{\theta}_2^2} = 0 \end{cases} \quad (3-21)$$

3.2.3 正态分布下的最大似然估计

- 以单变量正态分布估计均值和方差为例
 - 求得估计量：

$$\hat{\mu} = \hat{\theta}_1 = \frac{1}{N} \sum_{k=1}^N x_k \quad (3-22)$$

$$\hat{\sigma}^2 = \hat{\theta}_2 = \frac{1}{N} \sum_{k=1}^N (x_k - \hat{\mu})^2 \quad (3-23)$$

与我们日常使用的对均值和方差的估计方式完全一致！

3.2.3 正态分布下的最大似然估计

- 扩展到多元正态分布
 - 结论与单变量情况类似，均值和协方差的最大似然估计为：

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N x_i$$

$$\hat{\Sigma} = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T$$

【结论】均值向量 μ 的最大似然估计是样本均值；协方差矩阵 Σ 的最大似然估计是 N 个矩阵 $(x_i - \hat{\mu})(x_i - \hat{\mu})^T$ 的算术平均

3.2.3 正态分布下的最大似然估计

- 扩展到多元正态分布
 - 上式中的 $\hat{\mu}$ 是无偏估计，而 $\hat{\Sigma}$ 不是无偏估计
 - 无偏性：若参数 θ 的估计量 $\hat{\theta}$ 的数学期望等于 θ ，即 $E[\hat{\theta}] = \theta$ ，则称估计是无偏的
 - 对于 μ ：

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N x_i$$

$$E[\hat{\mu}] = E\left[\frac{1}{N} \sum_{i=1}^N x_i\right] = \frac{1}{N} \sum_{i=1}^N E[x_i] = \frac{1}{N} \cdot N\mu = \mu$$

3.2.3 正态分布下的最大似然估计

- 扩展到多元正态分布
 - 上式中的 $\hat{\mu}$ 是无偏估计，而 $\hat{\Sigma}$ 不是无偏估计

- 对于 $\hat{\Sigma}$:

$$\hat{\Sigma} = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T$$

- $\hat{\Sigma}$ 的无偏估计是: $\frac{1}{N-1} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T$
 - 需要证明的是:

$$E \left[\frac{1}{N-1} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T \right] = \Sigma$$

3.2.3 正态分布下的最大似然估计

- 扩展到多元正态分布

- 证明过程:

$$E \left[\frac{1}{N-1} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T \right] = \Sigma$$

- 将 $x_i - \hat{\mu}$ 加减真实均值 μ 进行分解:

$$x_i - \hat{\mu} = \underbrace{(x_i - \mu)}_{\text{真实偏差}} - \underbrace{(\hat{\mu} - \mu)}_{\text{估计误差}}$$

- 代入左侧求和，展开乘积:

$$\sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T = \sum_{i=1}^N [(x_i - \mu) - (\hat{\mu} - \mu)] [(x_i - \mu) - (\hat{\mu} - \mu)]^T$$

3.2.3 正态分布下的最大似然估计

■ 扩展到多元正态分布

■ 证明过程:

■ 展开得到四项:

令 $a = x_i - \mu$, $b = \hat{\mu} - \mu$, 则:

$$(a - b)(a - b)^T = aa^T - ab^T - ba^T + bb^T$$

$$\sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T = \sum_{i=1}^N [(x_i - \mu) - (\hat{\mu} - \mu)] [(x_i - \mu) - (\hat{\mu} - \mu)]^T$$

$$= \underbrace{\sum_{i=1}^N (x_i - \mu)(x_i - \mu)^T}_{\textcircled{1}} - \underbrace{\sum_{i=1}^N (x_i - \mu)(\hat{\mu} - \mu)^T}_{\textcircled{2}} - \underbrace{\sum_{i=1}^N (\hat{\mu} - \mu)(x_i - \mu)^T}_{\textcircled{3}} + \underbrace{\sum_{i=1}^N (\hat{\mu} - \mu)(\hat{\mu} - \mu)^T}_{\textcircled{4}}$$

3.2.3 正态分布下的最大似然估计

- 扩展到多元正态分布

- 证明过程:

- 展开得到四项:

$$E \left[\frac{1}{N-1} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T \right] = \Sigma$$

$$= \underbrace{\sum_{i=1}^N (x_i - \mu)(x_i - \mu)^T}_{①} - \underbrace{\sum_{i=1}^N (x_i - \mu)(\hat{\mu} - \mu)^T}_{②} - \underbrace{\sum_{i=1}^N (\hat{\mu} - \mu)(x_i - \mu)^T}_{③} + \underbrace{\sum_{i=1}^N (\hat{\mu} - \mu)(\hat{\mu} - \mu)^T}_{④}$$

其中，第二、三、四项均等于 $N(\hat{\mu} - \mu)(\hat{\mu} - \mu)^T$

WHY?

3.2.3 正态分布下的最大似然估计

- 扩展到多元正态分布

- 证明过程:

- 后三项相等:
$$\underbrace{\sum_{i=1}^N (x_i - \mu)(\hat{\mu} - \mu)^T}_{\textcircled{2}} - \underbrace{\sum_{i=1}^N (\hat{\mu} - \mu)(x_i - \mu)^T}_{\textcircled{3}} + \underbrace{\sum_{i=1}^N (\hat{\mu} - \mu)(\hat{\mu} - \mu)^T}_{\textcircled{4}}$$

第④项: $(\hat{\mu} - \mu)(\hat{\mu} - \mu)^T$ 与 i 无关, 直接提出求和:

$$\sum_{i=1}^N (\hat{\mu} - \mu)(\hat{\mu} - \mu)^T = N(\hat{\mu} - \mu)(\hat{\mu} - \mu)^T$$

3.2.3 正态分布下的最大似然估计

■ 扩展到多元正态分布

■ 证明过程:

■ 后三项相等: $\underbrace{\sum_{i=1}^N (x_i - \mu)(\hat{\mu} - \mu)^T}_{\textcircled{2}} - \underbrace{\sum_{i=1}^N (\hat{\mu} - \mu)(x_i - \mu)^T}_{\textcircled{3}} + \underbrace{\sum_{i=1}^N (\hat{\mu} - \mu)(\hat{\mu} - \mu)^T}_{\textcircled{4}}$

第②项: $(\hat{\mu} - \mu)^T$ 与 i 无关可提出, 利用 $\hat{\mu} = \frac{1}{N} \sum_{i=1}^N x_i$:

$$\sum_{i=1}^N (x_i - \mu)(\hat{\mu} - \mu)^T = \left(\sum_{i=1}^N (x_i - \mu) \right) (\hat{\mu} - \mu)^T$$

而 $\sum_{i=1}^N (x_i - \mu) = \sum_{i=1}^N x_i - N\mu = N\hat{\mu} - N\mu = N(\hat{\mu} - \mu)$, 所以:

$$= N(\hat{\mu} - \mu)(\hat{\mu} - \mu)^T$$

第三项与第二项同理!

3.2.3 正态分布下的最大似然估计

- 扩展到多元正态分布

- 证明过程:

- 展开得到四项:

$$E \left[\frac{1}{N-1} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T \right] = \Sigma$$

$$= \underbrace{\sum_{i=1}^N (x_i - \mu)(x_i - \mu)^T}_{\textcircled{1}} - \underbrace{\sum_{i=1}^N (x_i - \mu)(\hat{\mu} - \mu)^T}_{\textcircled{2}} - \underbrace{\sum_{i=1}^N (\hat{\mu} - \mu)(x_i - \mu)^T}_{\textcircled{3}} + \underbrace{\sum_{i=1}^N (\hat{\mu} - \mu)(\hat{\mu} - \mu)^T}_{\textcircled{4}}$$

第二、三、四项均等于 $N(\hat{\mu} - \mu)(\hat{\mu} - \mu)^T$

- 合并所有项:

$$\sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T = \sum_{i=1}^N (x_i - \mu)(x_i - \mu)^T - N(\hat{\mu} - \mu)(\hat{\mu} - \mu)^T$$

3.2.3 正态分布下的最大似然估计

■ 扩展到多元正态分布

■ 证明过程: $\sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T = \sum_{i=1}^N (x_i - \mu)(x_i - \mu)^T - N(\hat{\mu} - \mu)(\hat{\mu} - \mu)^T$

■ 上式两边除以 (N-1) 并取期望:

等号左侧 $E \left[\frac{1}{N-1} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T \right]$

等号右侧 $= E \left[\frac{1}{N-1} \sum_{i=1}^N (x_i - \mu)(x_i - \mu)^T - \frac{N}{N-1} (\hat{\mu} - \mu)(\hat{\mu} - \mu)^T \right]$

 $= \frac{1}{N-1} E \left[\sum_{i=1}^N (x_i - \mu)(x_i - \mu)^T \right] - \frac{N}{N-1} E [(\hat{\mu} - \mu)(\hat{\mu} - \mu)^T]$

拆成
两项

3.2.3 正态分布下的最大似然估计

- 扩展到多元正态分布

- 证明过程:

- 计算第一项:

$$E \left[\frac{1}{N-1} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T \right] = \Sigma$$

$$E \left[\sum_{i=1}^N (x_i - \mu)(x_i - \mu)^T \right]$$

期望与求和交换

$$\begin{aligned} &= \sum_{i=1}^N E \left[\underline{(x_i - \mu)(x_i - \mu)^T} \right] \\ &= N\Sigma \end{aligned}$$

正是 x_i 的协方差矩阵的定义, 每个 x_i 均从 $p(x | \omega_i)$ 中独立采样, 一个随机变量的协方差, 就等于它所服从的分布的协方差, 因此, $E[(x_i - \mu)(x_i - \mu)^T] = \Sigma, \forall i$

3.2.3 正态分布下的最大似然估计

- 扩展到多元正态分布

- 证明过程:

- 计算第二项:

$$\frac{N}{N-1} E[(\hat{\mu} - \mu)(\hat{\mu} - \mu)^T]$$

- $E[(\hat{\mu} - \mu)(\hat{\mu} - \mu)^T]$ 描述的是样本均值估计量围绕真实均值 μ 波动幅度, 恰好就是 $\hat{\mu}$ 的协方差矩阵定义:

$$E[(\hat{\mu} - \mu)(\hat{\mu} - \mu)^T] = \text{Cov}(\hat{\mu})$$

- 展开 $\hat{\mu}$ 的表达式:

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N x_i$$

3.2.3 正态分布下的最大似然估计

- 扩展到多元正态分布

- 证明过程:

- 计算第二项:

$$\frac{N}{N-1} E[(\hat{\mu} - \mu)(\hat{\mu} - \mu)^T]$$

- 利用协方差的标量缩放性质 $\text{Cov}(cX) = c^2 \text{Cov}(X)$:

$$\text{Cov}(\hat{\mu}) = \text{Cov}\left(\frac{1}{N} \sum_{i=1}^N x_i\right) = \frac{1}{N^2} \text{Cov}\left(\sum_{i=1}^N x_i\right)$$

- 样本 $x_1, x_2, \dots, x_N$ 相互独立, 协方差具有可加性:

$$\text{Cov}\left(\sum_{i=1}^N x_i\right) = \sum_{i=1}^N \text{Cov}(x_i) = \sum_{i=1}^N \Sigma = N\Sigma$$

3.2.3 正态分布下的最大似然估计

- 扩展到多元正态分布

- 证明过程:

- 计算第二项:

$$\frac{N}{N-1} E[(\hat{\mu} - \mu)(\hat{\mu} - \mu)^T]$$

- 样本 $x_1, x_2, \dots, x_N$ 相互独立, 协方差具有可加性:

$$\text{Cov} \left(\sum_{i=1}^N x_i \right) = \sum_{i=1}^N \text{Cov}(x_i) = \sum_{i=1}^N \Sigma = N\Sigma$$

- 合并:

$$\text{Cov}(\hat{\mu}) = \frac{1}{N^2} \cdot N\Sigma = \frac{\Sigma}{N}$$

3.2.3 正态分布下的最大似然估计

- 扩展到多元正态分布

- 证明过程:

- 合并结果:

相等

$$E \left[\frac{1}{N-1} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T \right] = \Sigma$$

$$\underbrace{\frac{1}{N-1} E \left[\sum_{i=1}^N (x_i - \mu)(x_i - \mu)^T \right]}_{= N\Sigma} - \underbrace{\frac{N}{N-1} E[(\hat{\mu} - \mu)(\hat{\mu} - \mu)^T]}_{= \frac{\Sigma}{N}}$$

3.2.3 正态分布下的最大似然估计

- 扩展到多元正态分布

- 证明过程:

- 合并结果:


$$E\left[\frac{1}{N-1} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T\right] = \Sigma$$

$$\begin{aligned} & \frac{1}{N-1} N \Sigma - \frac{N}{N-1} \frac{\Sigma}{N} \\ &= \frac{1}{N-1} N \Sigma - \frac{1}{N-1} \Sigma \\ &= \frac{1}{N-1} (N \Sigma - \Sigma) \\ &= \frac{1}{N-1} (N-1) \Sigma \\ &= \Sigma \end{aligned}$$


3.2.3 正态分布下的最大似然估计


- 扩展到多元正态分布

- $\hat{\Sigma}$ 的无偏估计是: $\frac{1}{N-1} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T$
- 造成 $\hat{\Sigma} = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{\mu})(x_i - \hat{\mu})^T$ 不是无偏估计的关键原因在于: 使用的是估计的均值 $\hat{\mu}$ 而非真实均值 μ , 导致低估了真实的方差




参数估计方法






3.3.1 贝叶斯估计

- 与最大似然估计的根本区别
 - 最大似然估计是将待估计的参数当作未知但固定的量，需要根据观测数据估计这个量的取值
 - 贝叶斯估计是将待估计的参数本身也看作是随机变量，需要根据观测数据对参数的分布进行估计



3.3.1 贝叶斯估计

- 在连续空间内进行决策
 - 将概率密度函数的参数估计问题 看作一个连续空间内的贝叶斯决策问题
 - 决策的不再是离散的类别，而是参数的取值



3.3.1 贝叶斯估计

■ 任务定义

- 将待估计参数 θ 看作具有先验分布 $p(\theta)$ 的随机变量，其取值与样本集 $\mathcal{X}$ 有关
- 任务目的：根据样本集 $\mathcal{X} = \{x_1, x_2, \dots, x_N\}$ 估计最优的参数 θ (记作 θ^*)
- 对于连续变量 θ ，将它估计为 $\hat{\theta}$ 所造成的损失记作 $\lambda(\hat{\theta}, \theta)$ ，也称作损失函数

3.3.1 贝叶斯估计

■ 总期望风险

- 样本 x_i 为 d 维特征向量, 取值空间记作 E^d , 连续变量 θ 的取值空间记作 Θ
- 利用 $\hat{\theta}$ 作为参数 θ 的估计时, 总期望风险为:

$$R = \int_{E^d} \int_{\Theta} \lambda(\hat{\theta}, \theta) p(x, \theta) d\theta dx$$

内层积分: 对于一个固定的样本 x , 在所有可能的参数 θ 的取值空间上求期望损失

外层积分: 对所有可能的样本取值空间求期望

3.3.1 贝叶斯估计

■ 总期望风险

$$R = \int_{E^d} \int_{\Theta} \lambda(\hat{\theta}, \theta) \underline{p(x, \theta)} d\theta dx \quad (3-26)$$

转换联合概率




$$= \int_{E^d} \int_{\Theta} \lambda(\hat{\theta}, \theta) \underline{p(\theta | x)p(x)} d\theta dx$$

- 定义在样本 x 下的条件风险:

$$R(\hat{\theta} | x) = \int_{\Theta} \lambda(\hat{\theta}, \theta) p(\theta | x) d\theta \quad (3-27)$$

- 将公式 3-26 改写为:

$$R = \int_{E^d} R(\hat{\theta} | x) p(x) dx \quad (3-28)$$




3.3.1 贝叶斯估计

■ 总期望风险

$$R = \int_{E^d} R(\hat{\boldsymbol{\theta}} \mid x) p(x) dx \quad (3-28)$$

- 目标：期望风险求最小
- 与最小风险贝叶斯决策类似， $p(x)$ 是已知的，且与决策无关，条件风险非负
- 求期望风险最小等价于对所有可能的样本 x 求条件风险最小



3.3.1 贝叶斯估计

■ 总期望风险

$$R = \int_{E^d} R(\hat{\theta} \mid x) p(x) dx \quad (3-28)$$

- 目标：期望风险求最小
- 求期望风险最小等价于对所有可能的样本 x 求条件风险最小
- 在有限样本集合 $\mathcal{X} = \{x_1, x_2, \dots, x_N\}$ 的情况下，对所有的样本求条件风险最小：

$$\theta^* = \arg \min_{\hat{\theta}} R(\hat{\theta} \mid \mathcal{X}) = \int_{\Theta} \lambda(\hat{\theta}, \theta) p(\theta \mid \mathcal{X}) d\theta \quad (3-29)$$