

3.3.1 贝叶斯估计

- 损失函数是平方误差


$$\theta^* = \arg \min_{\hat{\theta}} R(\hat{\theta} | \mathcal{X}) = \int_{\Theta} \lambda(\hat{\theta}, \theta) p(\theta | \mathcal{X}) d\theta \quad (3-29)$$



对于连续变量 θ ，需要定义损失函数 $\lambda(\hat{\theta}, \theta) = (\theta - \hat{\theta})^2$ (离散变量定义决策表)

- 如果采用平方误差损失函数，则在样本 x 条件下 θ 的贝叶斯估计量 θ^* 是在给定 x 下 θ 的条件期望：

$$\theta^* = E[\theta | x] = \int_{\Theta} \theta p(\theta | x) d\theta \quad (3-31)$$



3.3.1 贝叶斯估计

- 公式 3-31 证明过程


$$\theta^* = E[\theta | x] = \int_{\Theta} \theta p(\theta | x) d\theta \quad (3-31)$$

- 将平方误差 $\lambda(\hat{\theta}, \theta) = (\theta - \hat{\theta})^2$ 代入公式 3-27:

$$R(\hat{\theta} | x) = \int_{\Theta} \underline{(\theta - \hat{\theta})^2} p(\theta | x) d\theta$$

- 展开平方项:

$$R(\hat{\theta} | x) = \int_{\Theta} \underline{(\theta^2 - 2\theta\hat{\theta} + \hat{\theta}^2)} p(\theta | x) d\theta$$



3.3.1 贝叶斯估计

■ 公式 3-31 证明过程


$$\theta^* = E[\theta | x] = \int_{\Theta} \theta p(\theta | x) d\theta \quad (3-31)$$

■ 分项积分:

$$R(\hat{\theta} | x) = \int_{\Theta} \theta^2 p(\theta | x) d\theta - 2\hat{\theta} \int_{\Theta} \theta p(\theta | x) d\theta + \hat{\theta}^2 \int_{\Theta} p(\theta | x) d\theta$$

- 为使条件期望最小，对 $\hat{\theta}$ 求导并令其为零：等于1，概率密度归一化

$$\frac{\partial R(\hat{\theta} | x)}{\partial \hat{\theta}} = -2 \int_{\Theta} \theta p(\theta | x) d\theta + 2\hat{\theta} = 0$$



3.3.1 贝叶斯估计

- 公式 3-31 证明过程

$$\theta^* = E[\theta | x] = \int_{\Theta} \theta p(\theta | x) d\theta \quad (3-31)$$


- 解出最优估计量:

$$\hat{\theta} = \int_{\Theta} \theta p(\theta | x) d\theta = E[\theta | x]$$

- 给定样本集 $\mathcal{X}$ 的情况

- 同样, 在给定样本集 $\mathcal{X}$ 下, θ 的贝叶斯估计量为:

$$\theta^* = E[\theta | \mathcal{X}] = \int_{\Theta} \theta p(\theta | \mathcal{X}) d\theta \quad (3-32)$$



3.3.1 贝叶斯估计

- 损失函数为绝对值损失
 - 绝对值损失公式：


$$\lambda(\hat{\theta}, \theta) = \underline{|\theta - \hat{\theta}|}$$

- 此时条件风险为：

$$R(\hat{\theta} | x) = \int_{\Theta} \underline{|\theta - \hat{\theta}|} p(\theta | x) d\theta$$

- 可以证明，使条件风险最小的贝叶斯估计量 θ^* 是后验分布 $p(\theta|x)$ 的中位数，满足：

$$\int_{-\infty}^{\theta^*} p(\theta | x) d\theta = \frac{1}{2}$$



3.3.1 贝叶斯估计


- 损失函数为均匀损失

- 均匀损失公式:

$$\lambda(\hat{\theta}, \theta) = \begin{cases} 0, & |\theta - \hat{\theta}| \leq \delta \\ 1, & |\theta - \hat{\theta}| > \delta \end{cases}$$

- 可以证明, 使条件风险最小的贝叶斯估计量 θ^* 是后验分布 $p(\theta|x)$ 的**众数**, 即后验概率最大点:


$$\theta^* = \arg \max_{\theta} p(\theta | x)$$



3.3.1 贝叶斯估计

- 贝叶斯估计流程（最小平方差误差损失时）
 - 1. 确定待估计参数 θ 的先验分布 $p(\theta)$
 - 2. 由于样本是独立同分布的，样本的概率密度函数 $p(x|\theta)$ 的形式已知，求出样本集的联合分布：

$$p(\mathcal{X} | \theta) = p(\{x_1, x_2, \cdots, x_N\} | \theta) = \prod_{i=1}^N p(x_i | \theta) \quad (3-33)$$




3.3.1 贝叶斯估计

- 贝叶斯估计流程（最小平方误差损失时）
 - 3. 利用贝叶斯公式求 θ 的后验概率分布：

$$p(\theta | \mathcal{X}) = \frac{p(\mathcal{X} | \theta)p(\theta)}{\int_{\Theta} p(\mathcal{X} | \theta)p(\theta)d\theta} \quad (3-34)$$


- 4. 利用公式 3-32 计算贝叶斯估计量：

$$\theta^* = E[\theta | \mathcal{X}] = \int_{\Theta} \theta p(\theta | \mathcal{X})d\theta$$



3.3.1 贝叶斯估计

- 贝叶斯估计流程（最小平方误差损失时）
 -  第 2 步中，样本的概率密度函数 $p(x|\theta)$ 的形式已知，参数的先验分布 $p(\theta)$ 只有在某些特殊形式下才能使第 3 步后验概率方便计算
 - **共轭**：给定概率密度函数 $p(x|\theta)$ ，如果先验分布 $p(\theta)$ 能够使参数的后验分布 $p(\theta | \mathcal{X})$ 具有与 $p(x|\theta)$ 相同的形式，则称 $p(\theta)$ 与 $p(x|\theta)$ 共轭
 - 最为常用的共轭是 $p(x|\theta)$ 为正态分布时， $p(\theta)$ 同样为正态分布



3.3.2 贝叶斯学习

- 将贝叶斯估计流程第 2 步样本集联合分布的计算过程改为递推形式：

$$p(\mathcal{X} \mid \theta) = p(\{x_1, x_2, \dots, x_N\} \mid \theta) = \prod_{i=1}^N p(x_i \mid \theta) \quad (3-33)$$



$$p(\mathcal{X}^N \mid \theta) = p(x_N \mid \theta)p(\mathcal{X}^{N-1} \mid \theta) \quad (3-40)$$

3.3.2 贝叶斯学习

- 将公式 3-40 代入贝叶斯估计流程第 3 步后验概率计算中 (公式 3-34)

$$\underline{p(\mathcal{X}^N | \theta)} = p(x_N | \theta)p(\mathcal{X}^{N-1} | \theta) \quad (3-40)$$

$$p(\theta | \mathcal{X}) = \frac{\underline{p(\mathcal{X} | \theta)p(\theta)}}{\int_{\Theta} \underline{p(\mathcal{X} | \theta)p(\theta)} d\theta} \quad (3-34)$$



推导分子和分母中的后两项

$$p(\theta | \mathcal{X}^N) = \frac{p(x_N | \theta) \boxed{p(\mathcal{X}^{N-1} | \theta)p(\theta)}}{\int_{\Theta} p(x_N | \theta) \boxed{p(\mathcal{X}^{N-1} | \theta)p(\theta)} d\theta}$$

3.3.2 贝叶斯学习

- 将公式 3-40 代入贝叶斯估计流程第 3 步后验概率计算中 (公式 3-34)

$$p(\theta | \mathcal{X}^N) = \frac{p(x_N | \theta) p(\mathcal{X}^{N-1} | \theta) p(\theta)}{\int_{\Theta} p(x_N | \theta) p(\mathcal{X}^{N-1} | \theta) p(\theta) d\theta}$$

- 根据贝叶斯公式:

$$p(A | B)p(B) = p(A, B) = p(B | A)p(A)$$

- 因而:

$$p(\mathcal{X}^{N-1} | \theta) p(\theta) = p(\theta | \mathcal{X}^{N-1}) p(\mathcal{X}^{N-1})$$

是关于 θ 的常数, 可以提到积分号外面, 然后分子分母同时约掉

3.3.2 贝叶斯学习

- 将公式 3-40 代入贝叶斯估计流程第 3 步后验概率计算中 (公式 3-34)

$$p(\theta | \mathcal{X}) = \frac{p(\mathcal{X} | \theta)p(\theta)}{\int_{\Theta} p(\mathcal{X} | \theta)p(\theta)d\theta} \quad (3-34)$$




当前样本

上一步后验

$$\boxed{p(\theta | \mathcal{X}^N)} = \frac{\boxed{p(x_N | \theta)} \boxed{p(\theta | \mathcal{X}^{N-1})}}{\int p(x_N | \theta)p(\theta | \mathcal{X}^{N-1})d\theta} \quad (3-41)$$

当前后验

说明后验可以
仅凭上一步后
验+当前样本
递推得到!



3.3.2 贝叶斯学习

■ 优点

- 提供递推在线学习能力，提高计算效率。设已观测 $N-1$ 个样本，当第 N 个样本 x_N 到来时，根据公式 3-41:

$$p(\theta | \mathcal{X}^N) = \frac{p(x_N | \theta)p(\theta | \mathcal{X}^{N-1})}{\int p(x_N | \theta)p(\theta | \mathcal{X}^{N-1})d\theta} \quad (3-41)$$

仅需当前样本 x_N 以及上一步后验 $p(\theta | \mathcal{X}^{N-1})$ ，无需重复访问历史数据 $\{x_1, \dots, x_{N-1}\}$ (计算量随 N 线性增长，无法用于在线场景)

3.3.3 正态分布时的贝叶斯估计

- 以单变量正态分布为例

- 假设类条件概率的均值 μ 是待估计参数，方差 σ^2 :

$$p(x | \mu) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right)$$

- 假设均值 μ 的先验分布同样是正态分布，其均值为 μ_0 ，方差为 σ_0^2 ，即：

$$p(\mu) = \frac{1}{\sqrt{2\pi}\sigma_0} \exp\left(-\frac{1}{2\sigma_0^2}(\mu - \mu_0)^2\right)$$

3.3.3 正态分布时的贝叶斯估计

- 以单变量正态分布为例
 - 由于样本的条件概率密度函数 $p(x | \mu)$ 和参数先验概率 $p(\mu)$ 均满足正态分布，根据正态分布的共轭性质，后验分布 $p(\mu | \mathcal{X}^N)$ 仍然为正态分布 (均值为 μ_N ，方差为 σ_N^2 ， N 为样本数目):

$$p(\mu | \mathcal{X}) = \frac{1}{\sqrt{2\pi}\sigma_N} \exp\left(-\frac{1}{2} \left(\frac{\mu - \mu_N}{\sigma_N}\right)^2\right) \quad (3-48)$$

3.3.3 正态分布时的贝叶斯估计

- 以单变量正态分布为例
 - 如何计算后验正态分布 $p(\mu|\mathcal{X})$ 的参数 μ_N 和 σ_N^2 ?
 - 通过公式 3-34，对分子部分进行展开（分母是进行归一化的常数项）

$$p(\mu | \mathcal{X}) = \frac{p(\mathcal{X} | \mu)p(\mu)}{\int_{\Theta} p(\mathcal{X} | \mu)p(\mu)d\mu}$$

3.3.3 正态分布时的贝叶斯估计

- 以单变量正态分布为例
 - 如何计算后验正态分布 $p(\mu|\mathcal{X})$ 的参数 μ_N 和 σ_N^2 ?
 - 通过公式 3-34，对分子部分进行展开（分母是进行归一化的常数项）

$$\begin{aligned} p(\mathcal{X} | \mu)p(\mu) &= p(\mu) \prod_{i=1}^N p(x_i | \mu) \\ &= \frac{1}{\sqrt{2\pi}\sigma_0} \exp\left(-\frac{1}{2}\left(\frac{\mu - \mu_0}{\sigma_0}\right)^2\right) \prod_{i=1}^N \left(\frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2}\left(\frac{x_i - \mu}{\sigma}\right)^2\right)\right) \end{aligned}$$

- 将所有不依赖于 μ 的量写入一个常数中，对上式进行整理（详见教材公式 3-47）

3.3.3 正态分布时的贝叶斯估计

- 以单变量正态分布为例
 - 如何计算后验正态分布 $p(\mu|\mathcal{X})$ 的参数 μ_N 和 σ_N^2 ?
 - 最终得到:

$$\mu_N = \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} m_N + \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \mu_0 \quad (3-51)$$

$$\sigma_N^2 = \frac{\sigma_0^2 \sigma^2}{N\sigma_0^2 + \sigma^2} \quad (3-52)$$

其中, $m_N = \frac{1}{N} \sum_{i=1}^N x_i$ 是所有观测样本的算术平均

3.3.3 正态分布时的贝叶斯估计

- 以单变量正态分布为例
 - 利用公式 3-32 得到参数 μ 的贝叶斯估计值 $\hat{\mu}$:

$$\hat{\mu} = \underline{E[\mu | \mathcal{X}]} = \int \mu p(\mu | \mathcal{X}) d\mu = \underline{\mu_N}$$

后验分布 $p(\mu | \mathcal{X})$ 是一个正态分布,
正态分布的期望就是它的均值

3.3.3 正态分布时的贝叶斯估计

- 以单变量正态分布为例

- 参数 μ 的贝叶斯估计值 $\hat{\mu}$ 等于 μ_N

$$\mu_N = \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} m_N + \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \mu_0 \quad (3-51)$$

- μ_N 由两项组成: 第一项为样本的算术平均; 第二项是均值的先验
- 当样本数目 N 趋于无穷大时, 第一项的系数趋于 1 而第二项系数趋于 0, 此时估计值是样本的算术平均

3.3.3 正态分布时的贝叶斯估计

- 以单变量正态分布为例

- 参数 μ 的贝叶斯估计值 $\hat{\mu}$ 等于 μ_N

$$\mu_N = \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} m_N + \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \mu_0 \quad (3-51)$$

- 当样本数目有限时，如果先验知识非常确定，先验分布的方差 σ_0^2 很小，此时第一项系数接近于 0，而第二项的系数接近于 1，估计量由先验知识决定
- 一般情况下，均值的贝叶斯估计是在样本算术平均与先验分布均值之间进行加权平均

3.3.3 正态分布时的贝叶斯估计

■ 优势

- 不但能够使用样本中提供的信息进行估计
- 还能融合待估计参数的先验知识

3.3.3 正态分布时的贝叶斯估计

■ 例子

- 假设某班级学生身高服从正态分布，方差已知 $\sigma^2 = 100$ (即标准差 $\sigma = 10$ cm), 我们要估计均值 μ (平均身高)
- 先验知识: 根据历史经验, 我们认为平均身高约为 $\mu_0 = 170$ cm, 但不太确定, 设先验方差 $\sigma^2 = 25$ 。即先验分布为:

$$p(\mu) = \mathcal{N}(\mu_0, \sigma_0^2) = \mathcal{N}(170, 25)$$

- 观测数据: 随机测量 $N=5$ 名同学的身高 (样本):

$$x_1 = 175, \quad x_2 = 168, \quad x_3 = 172, \quad x_4 = 180, \quad x_5 = 165$$

3.3.3 正态分布时的贝叶斯估计

- 例子一求解

- 求出样本均值，即 m_N ：

$$m_N = \frac{1}{N} \sum_{i=1}^N x_i = \frac{175 + 168 + 172 + 180 + 165}{5} = \frac{860}{5} = 172$$

- 根据贝叶斯估计公式 3-51：

$$\mu_N = \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} m_N + \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \mu_0 \quad (3-51)$$

- 代入数值： $N = 5, \sigma_0^2 = 25, \sigma^2 = 100, m_N = 172, \mu_0 = 170$

3.3.3 正态分布时的贝叶斯估计

- 例子一求解

- 计算分母：

$$N\sigma_0^2 + \sigma^2 = 5 \times 25 + 100 = 125 + 100 = 225$$

- 计算两项系数：

$$w_{\text{data}} = \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} = \frac{125}{225} \approx 0.556$$


$$w_{\text{prior}} = \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} = \frac{100}{225} \approx 0.444$$

3.3.3 正态分布时的贝叶斯估计

- 例子一求解


- 得出贝叶斯估计量：

$$\begin{aligned}\hat{\mu} = \mu_N &= 0.556 \times 172 + 0.444 \times 170 = 95.6 + 75.5 \\ &= \mathbf{171.1cm}\end{aligned}$$




正态分布时的贝叶斯学习

- 以单变量正态分布为例
 - 假设模型的均值 μ 是待估计参数，方差 σ^2 已知
 - 假设均值 μ 的先验分布同样是正态分布，其均值为 μ_0 ，方差为 σ_0^2
 - 从章节“正态分布时的贝叶斯估计”已经得知：参数 μ 的贝叶斯估计值 $\hat{\mu}$ 等于 μ_N



正态分布时的贝叶斯学习


- 以单变量正态分布为例
 - 第 $N-1$ 时刻后验是正态分布，其均值记作 μ_{N-1} ，方差记作 σ_{N-1}^2 ，即：
 - 当前（第 N 时刻）样本为 x_N ，第 N 时刻的后验同样是正态分布，其均值记作 μ_N ，方差记作 σ_N^2



正态分布时的贝叶斯学习

- 以单变量正态分布为例
 - 由于参数 μ 的贝叶斯估计值 $\hat{\mu}$ 等于 μ_N
 - 🤔 如何利用贝叶斯学习的递推公式 3-41, 更新均值 μ_N 与方差 σ_N^2 ?

$$p(\mu \mid \mathcal{X}^N) = \frac{p(x_N \mid \mu)p(\mu \mid \mathcal{X}^{N-1})}{\int p(x_N \mid \mu)p(\mu \mid \mathcal{X}^{N-1})d\mu} \quad (3-41)$$



正态分布时的贝叶斯学习

- 以单变量正态分布为例
 - 🤔 如何利用贝叶斯学习的递推公式 3-41, 更新均值 μ_N 与方差 σ_N^2 ?
 - 💡 推导过程与“正态分布时的贝叶斯估计”章节类似, 不同之处在于后验公式中分子的计算方式

正态分布时的贝叶斯学习

- 以单变量正态分布为例
 - “正态分布时的贝叶斯估计”章节通过公式 3-34 的贝叶斯公式，对分子部分进行展开：

$$p(\mu | \mathcal{X}) = \frac{p(\mathcal{X} | \mu)p(\mu)}{\int_{\Theta} p(\mathcal{X} | \mu)p(\mu)d\mu} \quad (3-34)$$

- 本章节通过公式 3-41 的贝叶斯学习递推公式，对分子部分进行展开：

$$p(\mu | \mathcal{X}^N) = \frac{p(x_N | \mu)p(\mu | \mathcal{X}^{N-1})}{\int p(x_N | \mu)p(\mu | \mathcal{X}^{N-1})d\mu} \quad (3-41)$$

正态分布时的贝叶斯学习


- 以单变量正态分布为例

- 🤔 如何利用贝叶斯学习的递推公式 3-41, 更新均值 μ_N 与方差 σ_N^2 ?

- 将公式 3-41 分子展开

$$\begin{aligned} p(x_N | \mu)p(\mu | \mathcal{X}^{N-1}) &= \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x_N - \mu)^2}{2\sigma^2}\right) \frac{1}{\sqrt{2\pi}\sigma_{N-1}} \exp\left(-\frac{(\mu - \mu_{N-1})^2}{2\sigma_{N-1}^2}\right) \\ &= \frac{1}{2\pi\sigma\sigma_{N-1}} \exp\left\{-\frac{1}{2} \left[\frac{(x_N - \mu)^2}{\sigma^2} + \frac{(\mu - \mu_{N-1})^2}{\sigma_{N-1}^2} \right]\right\} \end{aligned}$$

- 与教材公式 3-47 类似, 对上式进行整理 (过程略)




正态分布时的贝叶斯学习

- 以单变量正态分布为例
 - 均值 μ_N 与方差 σ_N^2 的递推公式为：

$$\mu_N = \frac{\sigma_{N-1}^2}{\sigma_{N-1}^2 + \sigma^2} x_N + \frac{\sigma^2}{\sigma_{N-1}^2 + \sigma^2} \mu_{N-1}$$

$$\sigma_N^2 = \frac{\sigma_{N-1}^2 \cdot \sigma^2}{\sigma_{N-1}^2 + \sigma^2}$$



正态分布时的贝叶斯学习

■ 例子

- 假设某班级学生身高服从正态分布，方差已知 $\sigma^2 = 100$ (即标准差 $\sigma = 10$ cm), 我们要估计均值 μ (平均身高)

- **先验知识**: 根据历史经验, 我们认为平均身高约为 $\mu_0 = 170$ cm, 但不太确定, 设先验方差 $\sigma^2 = 25$ 。
即先验分布为:

$$p(\mu) = \mathcal{N}(\mu_0, \sigma_0^2) = \mathcal{N}(170, 25)$$

- **观测序列**:

$$x_1 = 175, x_2 = 168, x_3 = 172, x_4 = 180, x_5 = 165$$

正态分布时的贝叶斯学习

■ 例子一求解

初始状态（先验）


$$\mu_0 = 170, \quad \sigma_0^2 = 25$$

Step 1: 观测 $x_1 = 175$

$$\mu_N = \frac{\sigma_{N-1}^2}{\sigma_{N-1}^2 + \sigma^2} x_N + \frac{\sigma^2}{\sigma_{N-1}^2 + \sigma^2} \mu_{N-1}$$
$$\sigma_1^2 = \frac{25 \times 100}{25 + 100} = \frac{2500}{125} = 20$$
$$\sigma_N^2 = \frac{\sigma_{N-1}^2 \cdot \sigma^2}{\sigma_{N-1}^2 + \sigma^2}$$

$$\mu_1 = \frac{25}{25 + 100} \times 175 + \frac{100}{25 + 100} \times 170 = \frac{25}{125} \times 175 + \frac{100}{125} \times 170$$

$$= 0.2 \times 175 + 0.8 \times 170 = 35.0 + 136.0 = 171.00$$



正态分布时的贝叶斯学习

■ 例子一求解

Step 2: 观测 $x_2 = 168$

$$\sigma_2^2 = \frac{20 \times 100}{20 + 100} = \frac{2000}{120} = \mathbf{16.67}$$

$$\begin{aligned}\mu_2 &= \frac{20}{20 + 100} \times 168 + \frac{100}{20 + 100} \times 171.00 = \frac{20}{120} \times 168 + \frac{100}{120} \times 171.00 \\ &= 0.167 \times 168 + 0.833 \times 171.00 = 28.06 + 142.44 = \mathbf{170.50}\end{aligned}$$

依此类推，直到计算完全部 5 个样本

3.4 概率密度估计的非参数方法

- 为什么需要非参数估计？
 - 参数估计方法要求待估计的概率密度函数形式已知，利用样本估计函数中的未知参数
 - 大多数情况下，无法充分了解样本的分布，不能事先给出概率密度函数的具体形式
 - 因此，需要非参数估计，即不对概率密度函数的形式作任何假设，直接利用样本估计特征空间内任意点的概率密度值

3.4 概率密度估计的非参数方法

■ 非参数估计的问题定义

- 已知样本集 $\mathcal{X} = \{x_1, \dots, x_N\}$ 来自同一个类别，其中的样本是从概率密度函数为 $p(x)$ 的总体分布中独立采样的
- 求 $p(x)$ 的估计值 $\hat{p}(x)$

3.4 概率密度估计的非参数方法

■ 非参数估计的基本原理

- 考虑在样本所在空间的某个小区域 R , 某个随机向量 (变量) 落入这个小区域的概率:

$$P_R = \int_R p(x) dx \quad (3-55)$$

- 总共有 N 个样本, 而小区域 R 中实际落入了 k 个样本时, P_R 的一个很好的估计是:

$$\hat{P}_R = \frac{k}{N} \quad (3-59)$$


3.4 概率密度估计的非参数方法

■ 非参数估计的基本原理


- 当 $p(x)$ 连续且小区域 R 的体积 V 足够小时，可以假定在该小区域范围内 $p(x)$ 是常数 (⚠ 当 x 是 1 维时， V 是区间宽度；2 维时， V 是面积；3 维时， V 是体积)

当区域 V 足够小时：
$$P_R = \int_R p(x) dx \approx p(x_0) \cdot V$$


大区域 V (近似差)



中等区域 V (近似一般)



小区域 V (近似好)



3.4 概率密度估计的非参数方法


■ 非参数估计的基本原理

- 当 $p(x)$ 连续且小区域 R 的体积 (面积、宽度) V 足够小时, 可以假定在该小区域范围内 $p(x)$ 是常数
- 此时, 公式 3-55 $P_R = \int_R p(x)dx$ 近似为:


$$P_R = \int_R p(x)dx = p(x)V \quad (3-60)$$

- 将公式 3-59 $\hat{P}_R = \frac{k}{N}$ 代入上式:

$$\hat{p}(x) = \frac{k}{NV} \quad (3-61)$$




概率密度估计的非参数方法



3.4.1 直方图方法

■ 流程


- 1. 把样本 x 的每个分量在其取值范围内等分成 k 个等间隔的**小窗**（在样本取值范围内**等分**）
 - 如果 x 是 d 向量，则会得到 k^d 个小体积或称作小舱，每个小舱的体积记作 V



3.4.1 直方图方法

- 流程


- 2. 统计落入每个小舱内的样本数目 q_i




3.4.1 直方图方法

■ 流程


- 3. 把每个小舱内的概率密度看作常数，根据公式 3-61，将 $\frac{q_i}{NV}$ 作为其估计值， N 为样本总数





3.4.1 直方图方法

- 小舱大小对估计结果的影响
 - 如果小舱选择过大，假设 $p(x)$ 在小舱内为常数的做法十分粗糙，导致最终估计值同样粗糙
 - 如果小舱选择过小，则一些小舱内可能仅有很少样本，甚至没有样本，导致估计值不连续




3.4.1 直方图方法

- 小舱选择的原则
 - 假定样本总数是 n
 - 小舱的体积为 V_n
 - 在 x 附近位置上落入小舱的样本个数是 k_n
 - 当样本趋于无穷多时, $\hat{p}(x)$ 收敛于 $p(x)$ 的条件为:

$$(1) \lim_{n \rightarrow \infty} V_n = 0, (2) \lim_{n \rightarrow \infty} k_n = \infty, (3) \lim_{n \rightarrow \infty} \frac{k_n}{n} = 0$$

(3-62)




3.4.1 直方图方法

■ 小舱选择的原则

$$(1) \lim_{n \rightarrow \infty} V_n = 0, (2) \lim_{n \rightarrow \infty} k_n = \infty, (3) \lim_{n \rightarrow \infty} \frac{k_n}{n} = 0 \quad (3-62)$$

- 1. 随着样本数的增加，小舱体积应该尽可能小
- 2. 必须保证小舱内有充分多的样本
- 3. 每个小舱内的样本数必须是总样本数中很小的一部分



3.4.1 直方图方法

- 不足之处
 - 无法根据样本分布情况调整小舱体积
 - 小舱内有多少样本不但与小舱体积有关，还与样本的分布有关
 - 在有限数目的样本下，由于所有小舱的体积相同，在样本密度大的位置一个小舱里有很多样本，而在样本密度小的位置一个小舱里只有很少甚至没有样本
 - 导致估计值在样本密度不同的地方表现不一致


3.4.1 直方图方法

■ 不足之处

低密度区域
(样本少甚至为零)

高密度区域
(样本多)

如何解决?




3.4.2 k_N 近邻估计方法

■ 介绍

- 一种采用可变大小的小舱的概率密度估计方法
- 确定一个参数 k_N , 即在总样本数为 N 时要求每个小舱内拥有的样本个数
- 求 x 处的概率密度估计值 $\hat{p}(x)$ 时, 调整包含 x 的小舱体积, 直到小舱内恰好落入 k_N 个样本
- 计算公式:

$$\hat{p}(x) = \frac{\text{固定 } k_N / N}{V \text{ 改变!}} \quad (3-63)$$





3.4.2 k_N 近邻估计方法

- 优点


- 兼顾 在高密度区域估计的分辨率 和 在低密度区域估计的连续性
 - 在样本密度比较高的区域小舱的体积就会比较小
 - 在密度低的区域则小舱体积自动增大

3.4.2 k_N 近邻估计方法

■ 与直方图方法相比的不同之处



- 预先将 x 的取值空间划分为固定区域
- 小舱体积相等
- 同一区域内估计值相等
- 以每个查询点 x 为中心
- 自适应扩展小舱体积至包含 k_N 个样本
- 在高密度样本区域，小舱体积小



3.4.3 Parzen 窗法

- 介绍

- 固定小舱体积的情况下，像 k_N 近邻估计方法一样，用滑动小舱估计每个点上的概率密度
- 而非类似直方图方法在每个小舱内估计平均密度


- d 维单位方窗函数


- 以原点为中心的 d 维单位超正方体内取值为 1，而其它位置取值均为 0：

$$\varphi\left([u_1, u_2, \dots, u_d]^T\right) = \begin{cases} 1 & |u_j| \leq \frac{1}{2}, \quad j = 1, 2, \dots, d \\ 0 & \text{其他} \end{cases} \quad (3-65)$$

3.4.3 Parzen 窗法

- d 维单位方窗函数






3.4.3 Parzen 窗法

■ 计算方式

- 对于随机向量 $x \in R^d$ ，假设每个小舱是一个超立方体，棱长为 h ，则小舱体积为 $V = h^d$
- 通过计算 $\varphi\left(\frac{x-x_i}{h}\right)$ 判断某个样本 x_i 是否出现在以 x 为中心的 d 维单位超正方体内
- 存在 N 个观察样本 $\{x_1, x_2, \dots, x_N\}$ ，落入以 x 为中心的超立方体小舱内的样本数：

$$k_N = \sum_{i=1}^N \varphi\left(\frac{x - x_i}{h}\right) \quad (3-66)$$



3.4.3 Parzen 窗法


- 计算方式

- 将公式 3-66 代入公式 3-61 中:

$$\hat{p}(x) = \frac{k}{NV} \quad (3-61)$$

- 得到对于任意随机向量 x 的概率密度估计

$$\hat{p}(x) = \frac{1}{NV} \sum_{i=1}^N \varphi\left(\frac{x - x_i}{h}\right) \quad (3-67)$$



非参数方法的共同问题

- 对样本数目需求较大，只要样本数目足够大，可以收敛于任何复杂的未知概率密度
- 但所需的计算量和存储量都比较大
- 当样本数很少时，如果能够对概率密度函数有先验认识，则参数估计方法能取得更好的估计效果