



9.2.2 基于概率分布的可分性判据

- 两类完全可分与完全不可分的情况
 - 假定两类先验概率相等
 - 若对所有使 $p(x | \omega_2) \neq 0$ 的点有 $p(x | \omega_1) = 0$ ，则两类完全可分
 - 若对所有 x 都有 $p(x | \omega_1) = p(x | \omega_2)$ ，两类完全不可分

(a) 完全可分



(b) 完全不可分



9.2.2 基于概率分布的可分性判据

- 两类概率密度交叠程度的度量
 - 定义概率距离度量函数 J 衡量两类分布密度的交叠程度：
$$J = \int g[p(x | \omega_1), p(x | \omega_2), P(\omega_1), P(\omega_2)] dx$$
 - 其中 $g[.]$ 是某个关于类条件密度和先验概率的函数
 - 概率距离度量函数 J 作为一个合法的概率分布可分性判据需满足三个条件：
 - 非负性： $J \geq 0$
 - 两类完全可分时取最大值： $J = J_{\max}$
 - 两类完全不可分时为零： $J = 0$

9.2.2 基于概率分布的可分性 判据

- 常用的概率距离度量

- Bhattacharyya 距离

$$J_B = -\ln \int [p(x | \omega_1)p(x | \omega_2)]^{\frac{1}{2}} dx \quad (9-12)$$

- Chernoff 界限

$$J_c = -\ln \int p(x | \omega_1)^s p(x | \omega_2)^{1-s} dx \quad (9-14)$$

- 其中 $s \in [0,1]$, 当 $s = 0.5$ 时, Chernoff 界限与 Bhattacharyya 距离相同

9.2.2 基于概率分布的可分性 判据

- 常用的概率距离度量

- Jeffreys 散度

$$J_D = \int_x [p(x | \omega_1) - p(x | \omega_2)] \ln \frac{p(x | \omega_1)}{p(x | \omega_2)} dx \quad (9-15)$$

- 可展开为两个 KL 散度之和
 - 对于两个连续概率分布 p 和 q , KL 散度定义为:

$$KL(p||q) = \int p(\mathbf{x}) \ln \frac{p(\mathbf{x})}{q(\mathbf{x})} d\mathbf{x}$$

- 衡量的是用分布 q 去近似分布 p 时所损失的信息量
 - ⚠ KL 散度是非对称的, $KL(p||q) \neq KL(q||p)$

9.2.2 基于概率分布的可分性判据

- 常用的概率距离度量

- Jeffreys 散度

$$J_D = \int_x [p(x | \omega_1) - p(x | \omega_2)] \ln \frac{p(x | \omega_1)}{p(x | \omega_2)} dx \quad (9-15)$$

- 将公式 9-15 拆成两个积分：

$$J_D = \underbrace{\int p(\mathbf{x} | \omega_1) \ln \frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} d\mathbf{x}}_{\text{第一项}} - \underbrace{\int p(\mathbf{x} | \omega_2) \ln \frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} d\mathbf{x}}_{\text{第二项}}$$

- 第一项等于： $\text{KL}(p(\mathbf{x} | \omega_1) \| p(\mathbf{x} | \omega_2))$

- 第二项根据 $-\ln \frac{a}{b} = \ln \frac{b}{a}$ ，得到 $\text{KL}(p(\mathbf{x} | \omega_2) \| p(\mathbf{x} | \omega_1))$

9.2.2 基于概率分布的可分性 判据

- 常用的概率距离度量

- Jeffreys 散度

$$J_D = \int_x [p(x | \omega_1) - p(x | \omega_2)] \ln \frac{p(x | \omega_1)}{p(x | \omega_2)} dx \quad (9-15)$$

- 可展开为两个 KL 散度之和:

$$J_D = \text{KL}(p(x | \omega_1) \| p(x | \omega_2)) + \text{KL}(p(x | \omega_2) \| p(x | \omega_1))$$

9.2.2 基于概率分布的可分性判据

- 常用的概率距离度量

- Jeffreys 散度

- 在两类样本都服从正态分布的情况下，散度为：

$$J_D = \frac{1}{2} \text{tr}[\Sigma_1^{-1} \Sigma_2 + \Sigma_2^{-1} \Sigma_1 - 2\mathbf{I}] + \frac{1}{2} (\mu_1 - \mu_2)^T (\Sigma_1^{-1} + \Sigma_2^{-1}) (\mu_1 - \mu_2) \quad (9-16)$$

- 当两类协方差矩阵相等时 $\Sigma_1 = \Sigma_2 = \Sigma$:

$$J_D = \frac{1}{2} \text{tr}[\Sigma^{-1} \Sigma + \Sigma^{-1} \Sigma - 2\mathbf{I}] + \frac{1}{2} (\mu_1 - \mu_2)^T (\Sigma^{-1} + \Sigma^{-1}) (\mu_1 - \mu_2)$$

第一项等于 0

第二项等于均值向量马氏距离的平方

- 此时，与 Bhattacharyya 距离的关联：

$$J_D = (\mu_1 - \mu_2)^T \Sigma^{-1} (\mu_1 - \mu_2) = 8J_B$$

9.2.2 基于概率分布的可分性判据

- 常用的概率距离度量
 - Jeffreys 散度例题

设两类样本均服从二维正态分布，且协方差矩阵相等：

$$\boldsymbol{\mu}_1 = \begin{pmatrix} 1 \\ 3 \end{pmatrix}, \quad \boldsymbol{\mu}_2 = \begin{pmatrix} 4 \\ 1 \end{pmatrix}, \quad \boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_2 = \boldsymbol{\Sigma} = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$$

(1) 计算两类之间的 Jeffreys 散度 J_D 。

9.2.2 基于概率分布的可分性判据

- 常用的概率距离度量
 - Jeffreys 散度例题解答

$$J_D = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$$

Step 1: 求均值差

$$\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 = \begin{pmatrix} -3 \\ 2 \end{pmatrix}$$

Step 2: 求 $\boldsymbol{\Sigma}^{-1}$

2×2矩阵求逆

对于2×2矩阵，有固定公式：

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \implies A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

$$|\boldsymbol{\Sigma}| = 2 \times 3 - 1 \times 1 = 5$$

$$\boldsymbol{\Sigma}^{-1} = \frac{1}{5} \begin{pmatrix} 3 & -1 \\ -1 & 2 \end{pmatrix}$$

9.2.2 基于概率分布的可分性 判据


- 常用的概率距离度量
 - Jeffreys 散度例题解答

Step 3: 计算马氏距离平方

$$\Sigma^{-1}(\mu_1 - \mu_2) = \frac{1}{5} \begin{pmatrix} 3 & -1 \\ -1 & 2 \end{pmatrix} \begin{pmatrix} -3 \\ 2 \end{pmatrix} = \frac{1}{5} \begin{pmatrix} -9 - 2 \\ 3 + 4 \end{pmatrix} = \frac{1}{5} \begin{pmatrix} -11 \\ 7 \end{pmatrix}$$

$$J_D = (-3 \quad 2) \cdot \frac{1}{5} \begin{pmatrix} -11 \\ 7 \end{pmatrix} = \frac{1}{5}(33 + 14) = \frac{47}{5}$$

$$J_D = \frac{47}{5} = 9.4$$




9.2.3 基于熵的可分性判据

■ 动机

- 利用某个特征，若样本属于各类的后验概率越平均，则该特征越不利于分类
- 反之，若后验概率越集中于某一类，则该特征越有利于分类

■ 定义

- 将类别 $\omega_i, i = 1, \dots, c$ 看作是一系列随机事件，它的发生依赖于随机向量 x ，后验概率记作 $P(\omega_i|x)$
- 若根据 x 完全不能确定 ω_i ，则所属类别不确定性最大，此时熵最大，特征最不利于分类
- 若根据 x 能完全确定 ω_i ，则所属类别没有不确定性，此时熵为 0，特征最有利于分类



9.2.3 基于熵的可分性判据

- 香农熵

$$H = - \sum_{i=1}^c P(\omega_i | \mathbf{x}) \log_2 P(\omega_i | \mathbf{x}) \quad (9-20)$$


- 平方熵

! 等于 2 倍
Gini 不纯度

$$H = 2 \left[1 - \sum_{i=1}^c P^2(\omega_i | \mathbf{x}) \right] \quad (9-21)$$

- 对特征的所有取值积分，得到基于熵的可分性判据：

$$J_E = \int H(\mathbf{x}) p(\mathbf{x}) d\mathbf{x} \quad (9-22)$$




9.2.3 基于熵的可分性判据

■ 例题

设一个三类分类问题 ($c = 3$)，对于某个观测样本 $\mathbf{x}_0$ ，已知其后验概率为：

$$P(\omega_1|\mathbf{x}_0) = 0.8, \quad P(\omega_2|\mathbf{x}_0) = 0.15, \quad P(\omega_3|\mathbf{x}_0) = 0.05$$

- (1) 计算该观测点处的香农熵 $H(\mathbf{x}_0)$ 。
- (2) 计算该观测点处的平方熵 $H(\mathbf{x}_0)$ 。
- (3) 若另一个观测样本 $\mathbf{x}_1$ 的后验概率为 $P(\omega_1|\mathbf{x}_1) = P(\omega_2|\mathbf{x}_1) = P(\omega_3|\mathbf{x}_1) = \frac{1}{3}$ ，分别计算其香农熵和平方熵，并与 $\mathbf{x}_0$ 的结果比较，说明哪个观测点更有利于分类。




9.2.3 基于熵的可分性判据

■ 例题解答

第(1)小题：香农熵

$$\begin{aligned} H(\mathbf{x}_0) &= - \sum_{i=1}^3 P(\omega_i | \mathbf{x}_0) \log_2 P(\omega_i | \mathbf{x}_0) \\ &= - [0.8 \log_2 0.8 + 0.15 \log_2 0.15 + 0.05 \log_2 0.05] \\ &= - [0.8 \times (-0.3219) + 0.15 \times (-2.7370) + 0.05 \times (-4.3219)] \\ &= - [-0.2575 - 0.4106 - 0.2161] \\ &= 0.8842 \end{aligned}$$




9.2.3 基于熵的可分性判据

■ 例题解答

第(2)小题：平方熵

$$\begin{aligned} H(\mathbf{x}_0) &= 2 \left[1 - \sum_{i=1}^3 P^2(\omega_i | \mathbf{x}_0) \right] \\ &= 2 [1 - (0.8^2 + 0.15^2 + 0.05^2)] \\ &= 2 [1 - (0.64 + 0.0225 + 0.0025)] \\ &= 2 [1 - 0.665] = 2 \times 0.335 \end{aligned}$$

$$H(\mathbf{x}_0) = 0.67$$



9.2.3 基于熵的可分性判据

■ 例题解答


第(3)小题：均匀后验的情况

香农熵：

$$H(\mathbf{x}_1) = -3 \times \frac{1}{3} \log_2 \frac{1}{3} = \log_2 3 = 1.585$$

平方熵：

$$H(\mathbf{x}_1) = 2 \left[1 - 3 \times \left(\frac{1}{3} \right)^2 \right] = 2 \left[1 - \frac{1}{3} \right] = \frac{4}{3} \approx 1.333$$



9.2.3 基于熵的可分性判据

■ 例题解答

	香农熵	平方熵
x_0 (后验集中)	0.884	0.67
x_1 (后验均匀)	1.585	1.333

- x_0 处两种熵都更小，说明给定 x_0 后类别归属的不确定性更低，后验概率集中于 ω_1 ，因此 x_0 更有利于分类
- x_1 处后验完全均匀，熵取最大值，该观测点对分类毫无帮助

9.2.4 利用统计检验作为可分性判据

- 🤔 为什么需要统计检验?
 - 评估候选特征 f 对两类样本是否有区分能力
 - 从两类样本中计算出特征 f 的均值，发现均值不相等
 - 问题：能否直接认为该特征有区分力？
 - 观察到的差异有两种来源：
 - 两类总体均值确实不同（真实差异）
 - 样本量有限导致的随机波动（虚假差异）

9.2.4 利用统计检验作为可分性判据


- t -检验

- 双边 t 检验与单边 t 检验

- t 统计量公式相同，**区别**在于假设方向与拒绝域位置

- 基本概念：

- **零假设** H_0 ：假定两类均值无差异（即特征 f 无区分力），检验的**目标**是判断能否推翻这个假定
 - **备择假设** H_1 ：与 H_0 对立，即想要证明的结论
 - **显著性水平** α ：容忍的误判概率，常取 0.05 或 0.01
 - **拒绝域**： t 值落入该区域时，认为 H_0 不成立，拒绝 H_0




9.2.4 利用统计检验作为可分性判据

■ 双边 t -检验

- 零假设 $H_0: \mu_x = \mu_y$
- 备择假设 $H_1: \mu_x \neq \mu_y$
- 拒绝域：在 t 分布的**两端**， $|t| > t_{\alpha/2}$ 时拒绝 H_0

■ 单边 t -检验

- 零假设 $H_0: \mu_x \leq \mu_y$
- 备择假设 $H_1: \mu_x > \mu_y$
- 拒绝域：在 t 分布的**一端**， $t > t_\alpha$ 时拒绝 H_0



9.2.4 利用统计检验作为可分性判据

- 双边 t -检验与单边 t -检验
 - t 分布同样是关于零点对称的钟形曲线，由一个参数自由度 (df, 等于单类样本量减 1) 决定。自由度越大， t 分布越接近标准正态分布
 - $t_{\alpha/2}$ 和 t_{α} 是 t 分布上的临界值，就是从 t 分布表里查出来的一个数
 - $t_{\alpha/2}$: 满足 $P(t > t_{\alpha/2}) = \alpha/2$ 的那个值
 - t_{α} : 满足 $P(t > t_{\alpha}) = \alpha$ 的那个值

9.2.4 利用统计检验作为可分性判据

■ t -分布表


cum. prob	$t_{.50}$	$t_{.75}$	$t_{.80}$	$t_{.85}$	$t_{.90}$	$t_{.95}$	$t_{.975}$	$t_{.99}$	$t_{.995}$	$t_{.999}$	$t_{.9995}$
one-tail	0.50	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.001	0.0005
two-tails	1.00	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.002	0.001
df											
1	0.000	1.000	1.376	1.963	3.078	6.314	12.71	31.82	63.66	318.31	636.62
2	0.000	0.816	1.061	1.386	1.886	2.920	4.303	6.965	9.925	22.327	31.599
3	0.000	0.765	0.978	1.250	1.638	2.353	3.182	4.541	5.841	10.215	12.924
4	0.000	0.741	0.941	1.190	1.533	2.132	2.776	3.747	4.604	7.173	8.610
5	0.000	0.727	0.920	1.156	1.476	2.015	2.571	3.365	4.032	5.893	6.869
6	0.000	0.718	0.906	1.134	1.440	1.943	2.447	3.143	3.707	5.208	5.959
7	0.000	0.711	0.896	1.119	1.415	1.895	2.365	2.998	3.499	4.785	5.408
8	0.000	0.706	0.889	1.108	1.397	1.860	2.306	2.896	3.355	4.501	5.041
9	0.000	0.703	0.883	1.100	1.383	1.833	2.262	2.821	3.250	4.297	4.781
10	0.000	0.700	0.879	1.093	1.372	1.812	2.228	2.764	3.169	4.144	4.587

- 双边 t -检验, 显著性水平 $\alpha = 0.05$, 样本量 $n = 10$ (即 $df = 9$)
 - 找到 $df = 9$ 对应的行和双边 0.05 对应的列
 - 得到 $t = 2.262$


9.2.4 利用统计检验作为可分性判据

■ 双边 t -检验与单边 t -检验示意图

双边 t 检验 (two-tailed)



单边 t 检验 (one-tailed)



🤔 t 值如何计算?

9.2.4 利用统计检验作为可分性判据

■ t -检验统计量公式

- 假设两类样本都服从正态分布且方差相同
- 两类分别有 m 个和 n 个样本, $\{x_i, i = 1, \dots, m\}, x_i \sim N(\mu_x, \sigma^2), \{y_i, i = 1, \dots, n\}, y_i \sim N(\mu_y, \sigma^2)$
- 总体样本方差:

$$s_p^2 = \frac{(m-1)S_x^2 + (n-1)S_y^2}{m+n-2} \quad (9-23)$$

- 其中, S_x^2 和 S_y^2 分别为两类样本各自的估计方差, 两类样本的估计均值记作 $\bar{x}$ 和 $\bar{y}$

9.2.4 利用统计检验作为可分性判据

- t -检验统计量公式

- 公式 9-23 推导

$$s_p^2 = \frac{(m-1)S_x^2 + (n-1)S_y^2}{m+n-2} \quad (9-23)$$

- 每类样本各自的无偏方差估计为：

$$S_x^2 = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{x})^2, \quad S_y^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$$

- 两组估计的是同一个方差 σ^2 ，将两组样本的离差平方和直接相加，再除以总自由度：

$$s_p^2 = \frac{\sum_{i=1}^m (x_i - \bar{x})^2 + \sum_{i=1}^n (y_i - \bar{y})^2}{(m-1) + (n-1)}$$

两组数据共 $m+n$ 个观测值，各自估计了一个均值，所以减去 2

9.2.4 利用统计检验作为可分性判据

- t -检验统计量公式

- 公式 9-23 推导

$$s_p^2 = \frac{(m-1)S_x^2 + (n-1)S_y^2}{m+n-2} \quad (9-23)$$

- 注意到:

$$\sum_{i=1}^m (x_i - \bar{x})^2 = (m-1)S_x^2, \sum_{i=1}^n (y_i - \bar{y})^2 = (n-1)S_y^2$$

- 代入到上一页最下式的分子中, 得到公式 9-23

9.2.4 利用统计检验作为可分性判据

- t -检验统计量公式
 - 公式 9-23 无偏性证明

$$\begin{aligned} E[s_p^2] &= \frac{(m-1)E[S_x^2] + (n-1)E[S_y^2]}{m+n-2} \\ &= \frac{(m-1)\sigma^2 + (n-1)\sigma^2}{m+n-2} \\ &= \frac{(m+n-2)\sigma^2}{m+n-2} \\ &= \sigma^2 \end{aligned}$$

9.2.4 利用统计检验作为可分性判据


■ t -检验

■ t -检验统计量:

$$t = \frac{\bar{x} - \bar{y}}{s_p \sqrt{\frac{1}{n} + \frac{1}{m}}} \quad (9-24)$$

■ 检验步骤

- 1. 建立假设: 根据双边 t -检验, 零假设 $H_0: \mu_x = \mu_y$; 备择假设 $H_1: \mu_x \neq \mu_y$ (原因: 关心的是某个特征上两类的均值是否有差异, 而不关心两类均值哪个更大)
- 2. 选定显著性水平 α (如0.05 或 0.01)
- 3. 根据公式 9-24 计算 t -检验统计量



9.2.4 利用统计检验作为可分性判据

- t -检验

- 检验步骤

- 4. 计算 p 值：根据 t 分布表查出在 H_0 下取得该 t 值对应的 p 值
 - 5. 做出判断：比较 p 值与显著性水平 α ，决定是否拒绝 H_0 ，推断在该特征下两类样本的均值是否有显著差异


9.2.4 利用统计检验作为可分性判据

■ t -检验例题

已知两类样本，每类各 3 个样本，每个样本有两个特征 $x^{(1)}$ 和 $x^{(2)}$ 。数据如下：

	$x^{(1)}$	$x^{(2)}$
ω_1 样本 1	2	1
ω_1 样本 2	4	4
ω_1 样本 3	6	7
ω_2 样本 1	8	4
ω_2 样本 2	10	7
ω_2 样本 3	12	10

请使用双边 t 检验，在显著性水平 $\alpha = 0.05$ 下，判断哪个特征更适合用于区分两类样本。



9.2.4 利用统计检验作为可分性判据

- t -检验例题解答

第1步：建立假设

$$H_0 : \mu_x = \mu_y, \quad H_1 : \mu_x \neq \mu_y$$

第2步：选定显著性水平

$$\alpha = 0.05$$

第3步：计算t统计量

ω_1 的均值: $\bar{x} = \frac{2+4+6}{3} = 4$

ω_2 的均值: $\bar{y} = \frac{8+10+12}{3} = 10$

ω_1 的样本方差:

$$S_x^2 = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{x})^2, \quad S_y^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$$

$$S_x^2 = \frac{(2-4)^2 + (4-4)^2 + (6-4)^2}{3-1} = \frac{4+0+4}{2} = 4$$

ω_2 的样本方差:

$$S_y^2 = \frac{(8-10)^2 + (10-10)^2 + (12-10)^2}{3-1} = \frac{4+0+4}{2} = 4$$

池化方差:

$$s_p^2 = \frac{(n-1)S_x^2 + (m-1)S_y^2}{m+n-2} \quad (9-23)$$

$$s_p^2 = \frac{(n-1)S_x^2 + (m-1)S_y^2}{m+n-2} = \frac{2 \times 4 + 2 \times 4}{4} = 4, \quad s_p = 2$$

t统计量:

$$t = \frac{\bar{x} - \bar{y}}{s_p \sqrt{\frac{1}{n} + \frac{1}{m}}} \quad (9-24)$$

$$t = \frac{\bar{x} - \bar{y}}{s_p \sqrt{\frac{1}{n} + \frac{1}{m}}} = \frac{4 - 10}{2 \sqrt{\frac{1}{3} + \frac{1}{3}}} = \frac{-6}{2 \times 0.8165} = \frac{-6}{1.633} = -3.674$$

检验第一个特征 $x^{(1)}$

9.2.4 利用统计检验作为可分性判据

■ t -检验例题解答

■ 检验第一个特征 $x^{(1)}$

第4步：查P值

自由度 $df = m + n - 2 = 4$, $|t| = 3.674$ 。

查 t 分布表 $df = 4$ 行: $t_{.975} = 2.776$, $t_{.99} = 3.747$ 。

因为 $2.776 < 3.674 < 3.747$, 所以双尾P值满足 $0.02 < P < 0.05$ 。

第5步：做出判断

$P < \alpha = 0.05$, 拒绝 H_0 。特征 $x^{(1)}$ 上两类均值有显著差异, 具有区分能力。

■ 双边 t -检验

■ 零假设 $H_0: \mu_x = \mu_y$

■ 备择假设 $H_1: \mu_x \neq \mu_y$

■ 拒绝域: 在 t 分布的两端, $|t| > t_{\alpha/2}$ 时拒绝 H_0

9.2.4 利用统计检验作为可分性判据

- t -检验例题解答
 - 检验第一个特征 $x^{(1)}$

cum. prob	$t_{.50}$	$t_{.75}$	$t_{.80}$	$t_{.85}$	$t_{.90}$	$t_{.95}$	$t_{.975}$	$t_{.99}$	$t_{.995}$	$t_{.999}$	$t_{.9995}$
one-tail	0.50	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.001	0.0005
two-tails	1.00	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.002	0.001
df											
1	0.000	1.000	1.376	1.963	3.078	6.314	12.71	31.82	63.66	318.31	636.62
2	0.000	0.816	1.061	1.386	1.886	2.920	4.303	6.965	9.925	22.327	31.599
3	0.000	0.765	0.978	1.250	1.638	2.353	3.182	4.541	5.841	10.215	12.924
4	0.000	0.741	0.941	1.190	1.533	2.132	2.776	3.747	4.604	7.173	8.610
5	0.000	0.727	0.920	1.156	1.476	2.015	2.571	3.365	4.032	5.893	6.869
6	0.000	0.718	0.906	1.134	1.440	1.943	2.447	3.143	3.707	5.208	5.959
7	0.000	0.711	0.896	1.119	1.415	1.895	2.365	2.998	3.499	4.785	5.408
8	0.000	0.706	0.889	1.108	1.397	1.860	2.306	2.896	3.355	4.501	5.041
9	0.000	0.703	0.883	1.100	1.383	1.833	2.262	2.821	3.250	4.297	4.781
10	0.000	0.700	0.879	1.093	1.372	1.812	2.228	2.764	3.169	4.144	4.587

第3步：计算t统计量

ω_1 的均值: $\bar{x} = \frac{1+4+7}{3} = 4$

ω_2 的均值: $\bar{y} = \frac{4+7+10}{3} = 7$

ω_1 的样本方差:

$$S_x^2 = \frac{1}{m-1} \sum_{i=1}^m (x_i - \bar{x})^2, \quad S_y^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$$

$$S_x^2 = \frac{(1-4)^2 + (4-4)^2 + (7-4)^2}{3-1} = \frac{9+0+9}{2} = 9$$

ω_2 的样本方差:

$$S_y^2 = \frac{(4-7)^2 + (7-7)^2 + (10-7)^2}{3-1} = \frac{9+0+9}{2} = 9$$

池化方差:

$$s_p^2 = \frac{(n-1)S_x^2 + (m-1)S_y^2}{m+n-2} \quad (9-23)$$

$$s_p^2 = \frac{2 \times 9 + 2 \times 9}{4} = 9, \quad s_p = 3$$

t 统计量:

$$t = \frac{\bar{x} - \bar{y}}{s_p \sqrt{\frac{1}{n} + \frac{1}{m}}} \quad (9-24)$$

$$t = \frac{4-7}{3\sqrt{\frac{1}{3} + \frac{1}{3}}} = \frac{-3}{3 \times 0.8165} = \frac{-3}{2.449} = -1.225$$

检验第二个特征 $x^{(2)}$

9

性

t-1

9.2.4 利用统计检验作为可分性判据

- t -检验例题解答
 - 检验第二个特征 $x^{(2)}$

第4步：查P值

自由度 $df = 4$, $|t| = 1.225$ 。

查 t 分布表 $df = 4$ 行: $t_{.85} = 1.190$, $t_{.90} = 1.533$ 。

因为 $1.190 < 1.225 < 1.533$, 所以双尾 P 值满足 $0.20 < P < 0.30$ 。


第5步：做出判断

$P > \alpha = 0.05$, 不拒绝 H_0 。特征 $x^{(2)}$ 上两类均值差异不显著, 区分能力不足。

9.2.4 利用统计检验作为可分性判据

- t -检验例题解答
 - 检验第一个特征 $x^{(1)}$

cum. prob	$t_{.50}$	$t_{.75}$	$t_{.80}$	$t_{.85}$	$t_{.90}$	$t_{.95}$	$t_{.975}$	$t_{.99}$	$t_{.995}$	$t_{.999}$	$t_{.9995}$
one-tail	0.50	0.25	0.20	0.15	0.10	0.05	0.025	0.01	0.005	0.001	0.0005
two-tails	1.00	0.50	0.40	0.30	0.20	0.10	0.05	0.02	0.01	0.002	0.001
df											
1	0.000	1.000	1.376	1.963	3.078	6.314	12.71	31.82	63.66	318.31	636.62
2	0.000	0.816	1.061	1.386	1.886	2.920	4.303	6.965	9.925	22.327	31.599
3	0.000	0.765	0.978	1.250	1.638	2.353	3.182	4.541	5.841	10.215	12.924
4	0.000	0.741	0.941	1.190	1.533	2.132	2.776	3.747	4.604	7.173	8.610
5	0.000	0.727	0.920	1.156	1.476	2.015	2.571	3.365	4.032	5.893	6.869
6	0.000	0.718	0.906	1.134	1.440	1.943	2.447	3.143	3.707	5.208	5.959
7	0.000	0.711	0.896	1.119	1.415	1.895	2.365	2.998	3.499	4.785	5.408
8	0.000	0.706	0.889	1.108	1.397	1.860	2.306	2.896	3.355	4.501	5.041
9	0.000	0.703	0.883	1.100	1.383	1.833	2.262	2.821	3.250	4.297	4.781
10	0.000	0.700	0.879	1.093	1.372	1.812	2.228	2.764	3.169	4.144	4.587




9.2.4 利用统计检验作为可分性判据

- t -检验例题解答

- 结论

- 选择特征 $x^{(1)}$ 。该特征通过了 $\alpha = 0.05$ 的显著性检验 ($|t| = 3.674, P < 0.05$)
 - 而特征 $x^{(2)}$ 未通过检验 ($|t| = 1.225, P > 0.20$)



9.2.4 利用统计检验作为可分性判据

- 秩和检验与 t -检验的区别
 - t -检验
 - 属于参数化检验方法，对数据分布有假设
 - 目的是检验两类样本在特征的均值上是否有系统差别
 - 秩和检验
 - 属于非参数检验方法，不对数据分布作特殊假设
 - 不但受两类分布的均值影响，也受到分布形状的影响

9.2.4 利用统计检验作为可分性判据

秩和检验

■ 具体做法

- 首先把两类样本（样本数分别为 n_1 和 n_2 ）混合在一起
- 对所有样本按照所考查的特征从小到大排序，第一名排序为 1，第二名排序为 2，依次类推
- 若出现特征取值相等的样本时则并列采用中间的排序（如果，第 2、3、4 名并列，则排序为 $\frac{2+3+4}{3} = 3$ ）
- 在两类样本中分别计算所得排序序号之和称作秩和（记作 T_1 和 T_2 ）

■ 基本思想

- 若一类样本的秩显著地比另一类样本的秩小（或大）
- 则两类样本在所考查的特征上有显著差异

9.2.4 利用统计检验作为可分性判据

■ 秩和检验的零假设与检验统计量

- 零假设 H_0 : 两类样本在该特征上无显著差异
- 显著性水平 α : 等于0.05
- 在 H_0 下, 当两类样本数 n_1 和 n_2 较大 (> 10) 时, T_1 近似服从正态分布 $T_1 \sim N(\mu_1, \sigma_1^2)$:

$$\mu_1 = \frac{n_1(n_1 + n_2 + 1)}{2}, \quad \sigma_1 = \sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}} \quad (9-25)$$

-  只算一类秩和 T_1 的原因在于, T_1 和 T_2 存在恒等关系, 所有 $n_1 + n_2$ 个样本的秩就是 $1, 2, \dots, n_1 + n_2$, 它们的总和固定, 用 T_1 做检验和用 T_2 做检验结论一致

$$T_1 + T_2 = \frac{(n_1 + n_2)(n_1 + n_2 + 1)}{2}$$


9.2.4 利用统计检验作为可分性判据

■ 秩和检验的零假设与检验统计量

- 零假设 H_0 : 两类样本在该特征上无显著差异
- 显著性水平 α : 等于0.05
- 在 H_0 下, 当两类样本数 n_1 和 n_2 较大时, T_1 近似服从正态分布 $T_1 \sim N(\mu_1, \sigma_1^2)$
- 转化为标准正态分布:
 - $z = \frac{T_1 - \mu_1}{\sigma_1} \sim N(0,1)$, z 服从标准正态分布
- 判决规则: 若 $|z| > z_{\alpha/2}$ ($P(z > z_{\alpha/2}) = \alpha/2$, 查表), 则拒绝 H_0 , 认为该特征有显著区分力

回顾2.6.1 正态分布且各类协方差矩阵相等情况下错误率的计算

- 错误率计算步骤
 - 标准正态累积分布表



小于 Z 的面积占总体的比例

回顾2.6.1 正态分布且各类协方差矩阵相等情况下错误率的计算

- 错误率计算步骤
 - 标准正态累计分布表

Z	+0.00	+0.01	+0.02	+0.03	+0.04	+0.05	+0.06	+0.07	+0.08	+0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319

9.2.4 利用统计检验作为可分性判据

■ 标准正态累计分布表

Z	+0.00	+0.01	+0.02	+0.03	+0.04	+0.05	+0.06	+0.07	+0.08	+0.09
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916

$\alpha = 0.05$, $P(z > z_{\alpha/2}) = \alpha/2 = 0.025$, 查表找到累积概率等于 $1 - 0.025 = 0.9750$ 对应的行列, 行列相加, $z_{\alpha/2} = 1.96$

9.2.4 利用统计检验作为可分性判据

■ 秩和检验例题

已知两类样本在特征 x 上的观测值如下：

ω_1 ($n_1 = 5$)	2	5	8	11	13
ω_2 ($n_2 = 6$)	1	4	6	15	18

请使用秩和检验，在显著性水平 $\alpha = 0.05$ 下，判断特征 x 是否能够有效区分两类样本。

⚠ 题目中 $n_1 = 5, n_2 = 6$ 严格来说没有达到 "都大于 10" 的正态近似条件

9.2.4 利用统计检验作为可分性判据

■ 秩和检验例题解答

第一步：混合排序赋秩

值	1	2	4	5	6	8	11	13	15	18	20
秩	1	2	3	4	5	6	7	8	9	10	11
类别	ω_2	ω_1	ω_2	ω_1	ω_2	ω_1	ω_1	ω_1	ω_2	ω_2	ω_2

第二步：计算 ω_1 的秩和 T_1

$$T_1 = 2 + 4 + 6 + 7 + 8 = 27$$

9.2.4 利用统计检验作为可分性判据

■ 秩和检验例题解答

第三步：计算零假设下的期望和标准差

$$\mu_1 = \frac{n_1(n_1 + n_2 + 1)}{2} = \frac{5 \times 12}{2} = 30$$

$$\sigma_1 = \sqrt{\frac{5 \times 6 \times 12}{12}} = \sqrt{30} \approx 5.48$$

第四步：标准化检验

$$z = \frac{T_1 - \mu_1}{\sigma_1} = \frac{27 - 30}{\sqrt{30}} = \frac{-3}{5.48} \approx -0.55$$

9.2.4 利用统计检验作为可分性判据

■ 秩和检验例题解答

第五步：判决

双侧检验， $\alpha = 0.05$ ，临界值 $z_{\alpha/2} = 1.96$ 。

$$|z| = 0.55 < 1.96$$

不能拒绝零假设 H_0 。


结论

在 $\alpha = 0.05$ 的显著性水平下， $|z| = 0.55 < 1.96$ ，不能拒绝零假设。特征 x 在两类样本间无显著差异，该特征不适合用于区分两类样本。

9.2.4 利用统计检验作为可分性判据

- 总结

- 统计检验方法与其它类别可分性判据的区别
 - 统计检验判据只能逐一考虑每个单独的特征
 - 其它类别可分性判据能够从给定的 D 个特征中选出最优的 d ($1 \leq d < D$) 个特征子集



9.3 特征选择的最优算法

- 搜索空间


- 在给定的 D 个特征中选出 d 个，共有 $C_D^d = \frac{D!}{(D-d)!d!}$ 种可能

- 搜索方法

- 穷举法

- 穷举所有这些可能，从中选择判据最优的组合

- **缺点**：当 D 和 d 较大时，出现组合爆炸的情况



9.3 特征选择的最优算法

■ 基本假设


- 如果有互相包含的特征组的序列 $\bar{X}_1 \supset \bar{X}_2 \supset \dots \supset \bar{X}_i$, 则:
$$J(\bar{X}_1) \geq J(\bar{X}_2) \geq \dots \geq J(\bar{X}_i)$$

- 即特征增多时判据值不会减小

- ⚠ 前面介绍的基于距离的可分性判据和基于概率密度函数距离的判据都满足这一性质

■ 目的

- 从总共 D 个特征中选出判据值 J 最大的 d 个特征, 即去掉 $D' = D - d$ 个特征



9.3 特征选择的最优算法

- 分枝定界法

- 是一种自顶向下的方法，即从包含所有候选特征开始，逐步去掉不被选中的特征
- 利用一棵树组织搜索：
 - 根节点：全部 D 个特征
 - 每往下一层：去掉一个特征
 - 共经历 $D' = D - d$ 层
 - 叶节点：刚好剩 d 个特征

9.3 特征选择的最优算法


■ 分枝定界法

■ $D = 6$, $d = 2$ 的情况

第一层为什么只有三个节点，且
节点编号是 1, 2, 3?

根节点是6个特征的集合

经历 $D' = D - d = 4$ 层





9.3 特征选择的最优算法

分枝定界法

- 去重规则：
 - 去掉特征的编号必须严格递增（先去小编号，再去大编号）
- 每层保留节点数目：
 - 假设当前在第 l 层（已经去掉了 l 个特征），还需要再去掉 $D' - l$ 个
 - 当前节点通过去掉特征 k 产生，子节点去掉的特征编号必须 $> k$ ，可选范围是 $k + 1, k + 2, \dots, D$ ，共 $D - k$ 个
 - 要从中凑出 $D' - l$ 个严格递增的编号，需要满足：

$$D - k \geq D' - l$$

9.3 特征选择的最优算法


■ 分枝定界法

■ $D = 6, d = 2$ 的情况

第一层为什么只有三个节点，且
节点编号是 1, 2, 3?

$$D - k \geq \boxed{D'} - \boxed{l}$$

等于4 等于1





9.3 特征选择的最优算法

分枝定界法

- 排序:

- 在同一层中要按去掉该特征后剩余特征判据值 (J 值) 从小到大排列, J 最小的放最左边 (损失最大, 最不该去掉), J 最大的放最右边 (损失最小, 最该去掉)





9.3 特征选择的最优算法

■ 分枝定界法

■ 算法流程：


- 1. 从最右侧分枝开始深度优先搜索，向下直到叶节点
 - 原因：最右侧的分枝去掉的是损失最小的特征 (J 下降最少)，所以它的叶节点中保留特征 J 值倾向于比较大，先搜索，回溯时就能剪掉更多分枝
- 2. 到达第一个叶节点计算它的 J 值，记为当前界限 B
- 3. 回溯，遇到一个节点时：
 - 如果该节点的 $J > B$ ：它下面可能有更好的叶节点，必须展开
 - 如果该节点的 $J \leq B$ ：由单调性，它下面所有叶节点的判据值同样满足 $J \leq B$ ，剪枝

9.3 特征选择的最优算法

■ 分枝定界法

■ 算法流程：


- 4. 每发现一个 $J > B$ 的叶子节点，就更新 B
- 5. 所有分枝处理完毕， B 对应的叶节点就是全局最优



9.3 特征选择的最优算法

■ 分枝定界法

■ $D = 4$, $d = 2$ 示意图




- 边表示去掉的某个特征
- 根据 $D - k \geq D' - l$, 第一层保留 3 个节点
- 同一层中要按去掉该特征后的判据值 J 值从小到大排列

9.3 特征选择的最优算法

分枝定界法

■ $D = 4$, $d = 2$ 示意图




■ 从最右侧开始深度优先搜索，子节点只能去编号 >3

9.3 特征选择的最优算法

分枝定界法

■ $D = 4$, $d = 2$ 示意图




■ 到达第一个叶子节点，当前界限 $B = 6$ ，回溯

9.3 特征选择的最优算法

分枝定界法

■ $D = 4$, $d = 2$ 示意图




■ 对于第一层节点 $\{1,3,4\}$, $j = 7 > 6$, 所以展开


9.3 特征选择的最优算法

分枝定界法

■ $D = 4$, $d = 2$ 示意图



■ 更新当前最优界限 $B = 7$, 回溯到第一层 $\{2,3,4\}$, $j = 5 < 7$, 剪枝




9.4 特征选择的次优算法

- 单独最优特征的组合

- 基本假设

- 单独作用时性能最优的特征，将它们组合起来也是性能最优的
 - 对每一个特征单独计算类别可分性判据，根据单个特征的判据值大小排序，选择其中前 d 个特征
 - 章节 9.2.4 介绍的统计检验准则采用了该策略




9.4 特征选择的次优算法

- 顺序前进法

- 流程


- 第一个特征选择单独最优的特征
 - 第二个特征从其余所有特征中选择与第一个特征组合在一起后准则最优的特征
 - 后面每一个特征都选择与已经入选的特征组合起来最优的特征



9.4 特征选择的次优算法

- 顺序前进法


- 与单独最优特征选择方法的区别
 - 第一个特征仍然仅依靠单独最优特征进行选择
 - 考虑了一定的特征间组合因素
 - 每个特征一旦入选后就无法再剔除



9.4 特征选择的次优算法

■ 顺序后退法

- 从所有特征开始逐一剔除不被选中的特征
- 一旦剔除了某一特征后就无法再将其选入



9.4 特征选择的次优算法

■ 增 l 减 r 法

■ 介绍

- 对顺序前进法和顺序后退法进行改进
- 在选择或剔除过程中引入一个回溯的步骤
- 使得之前被选择或剔除的某个特征可以重新被考虑

■ 分类

- 自底向上: $l > r$, 首先逐步增选 l 个特征, 再逐步剔除 r 个与其它特征组合起来准则最差的特征, 以此类推
- 自顶向上: $l < r$, 首先逐步剔除 r 个特征, 再从已经被剔除的特征中逐步选择 l 个与其它特征组合起来准则最优的特征, 以此类推



9.5 遗传算法

■ 基本思想

- 模仿生物进化过程
- 生物染色体随机发生的突变和重组
- 环境对变异结果进行选择，适应性强的物种快速繁衍
- 将特征选择问题比作在无数可能的重组和突变组合中发现适应性最强的特征组合的问题



9.5 遗传算法

■ 问题定义

- 从 D 个特征中选择 d 个，将该问题描述为一条由 D 个 0/1 字符组成的字符串
- 0 代表该特征没有被选中，1 代表该特征被选中
- 每条字符串即为一条染色体，记作 m
- 目的：找到一条有且仅有 d 个 1 染色体（共 C_D^d 条）
- 每条染色体对应一个适应度值 $f(m)$ (⚠️ 可以用之前介绍的类别可分性判据作为适应度)
- 针对不同的适应度有不同的选择概率 $p(f(m))$



9.5 遗传算法

步骤

- 1. $t = 0$, 随机地产生一个包含 L 条不同染色体的种群 $M(0)$
- 2. 计算当前时刻种群 $M(t)$ 中每一条染色体的适应度 $f(m)$
- 3. 按选择概率 $p(f(m))$ 对种群中的染色体进行采样



9.5 遗传算法

■ 步骤

- 4. 采样出的染色体经过两个最基本的操作繁殖出下一代染色体，构成下一代的种群 $M(t + 1)$
 - **重组**：两条染色体配对，并在某个随机的位置上以一定的重组概率进行交叉，互换部分染色体
 - **突变**：每条染色体的每一个位置都有一定的突变概率，从 0 变为 1 或从 1 变为 0
- 5. 返回步骤 2，直到达到终止条件（某条染色体的适应度达到设定的阈值），输出适应度最大的染色体作为找到的最优解



9.5 遗传算法

■ 优点

- 虽然不能保证收敛到全局最优解，但在多数情况下可以至少得到很好的次优解
- 当特征维数较高且对特征间的关系缺乏认识时，尝试使用遗传算法会得到不错的效果