

2.7 离散时间序列样本的统计决策

■ 基因组序列的例子

- 人的基因组单链是由 A、T、C、G 四种核苷酸构成的一个超长序列
- 研究表明，基因组同一条链上相连的 C 和 G 的概率要比随机情况小
- 将相连的 C 和 G 称作一个 CpG 双核苷酸
- 将基因组上 CpG 相对富集的区域称作 CpG 岛
- 二分类任务：给定一段 DNA 序列，判断其是否来自 CpG 岛



说明相邻位置间存在依赖关系，每个位置不再独立

2.7 离散时间序列样本的统计决策

■ 马尔可夫模型

- 为表示相邻位置间的依赖关系，需要使用马尔可夫模型
- 将 DNA 序列看作一串由符号组成的时间序列 $x_1, x_2, \dots, x_L$ ，每一时刻（位置）上的取值为 $x_i = \{A, T, G, C\}$
- 若第 i 时刻上的取值仅依赖于上一时刻（第 $i - 1$ 时刻）的取值，即：

$$P(x_i \mid x_{i-1}, x_{i-2}, \dots, x_1) = P(x_i \mid x_{i-1}) \quad (2-114)$$

则将这个序列称为一阶马尔可夫链 或 一阶马尔可夫模型

2.7 离散时间序列样本的统计决策

■ 马尔可夫模型

- 若第 i 时刻上的取值仅依赖于第 $i - k$ 时刻到第 $i - 1$ 时刻的取值，则将这个序列称为 **k 阶马尔可夫链**

$$P(x_i | x_{i-1}, x_{i-2}, \dots, x_1) = P(x_i | x_{i-1}, x_{i-2}, \dots, x_{i-k})$$

- 对于 CpG 岛 识别任务，只需同时考虑相邻两个位置上的核苷酸，用一阶马尔可夫链进行描述
- 从公式 2-114 可知需要计算前一时刻到当前时刻取值的条件概率，称作**转移概率**

$$P(x_i | x_{i-1}, x_{i-2}, \dots, x_1) = \underline{P(x_i | x_{i-1})} \quad (2-114)$$

2.7 离散时间序列样本的统计决策

- 马尔可夫模型

- 转移概率

$$a_{st} = P(x_i = t \mid x_{i-1} = s) \quad (2-115)$$

- 表示当上一时刻取值为 s 时，当前时刻取值为 t 的条件概率

- 对一个长度为 L 的序列 $\mathbf{x} = \{x_1, x_2, \dots, x_L\}$ ，该序列出现的概率：

$$P(\mathbf{x}) = P(x_1, x_2, \dots, x_L) = P(x_1) \prod_{i=2}^L a_{x_{i-1}x_i} = \prod_{i=1}^L a_{x_{i-1}x_i} \quad (2-116)$$

$$\text{令 } a_{x_0 x_1} = P(x_1)$$

2.7 离散时间序列样本的统计决策

- 马尔可夫模型

- 状态转移矩阵

- 对于 DNA 序列，每一位置的取值有四种 (A, T, C, G), 状态转移是一个 4×4 的矩阵

行表示前一时刻取值,
列表示当前时刻取值

(2, 3) 的值 0.078 表示:
 $P(x_i = G \mid x_{i-1} = C) = 0.078$

—	<i>A</i>	<i>C</i>	<i>G</i>	<i>T</i>
<i>A</i>	0.300	0.205	0.285	0.210
<i>C</i>	0.322	0.298	0.078	0.302
<i>G</i>	0.248	0.246	0.298	0.208
<i>T</i>	0.177	0.239	0.292	0.292

2.7 离散时间序列样本的统计决策

- 马尔可夫模型

- 回顾之前的决策规则

- 最小错误率贝叶斯决策 (公式 2-12)

若 $l(x) = \frac{p(x|\omega_1)}{p(x|\omega_2)} \geq \lambda = \frac{P(\omega_2)}{P(\omega_1)}$, 则 $x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$

对于一个特定样本 x , 根据类条件概率密度计算似然比 $l(x)$, 并与一定的阈值比较进行判别

- 最小风险贝叶斯决策 (公式 2-31)

若 $l(x) = \frac{p(x | \omega_1)}{p(x | \omega_2)} \geq \frac{P(\omega_2)}{P(\omega_1)} \cdot \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}}$, 则 $x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$

- 聂曼-皮尔逊准则 (公式 2-43)

若 $l(x) = \frac{p(x | \omega_1)}{p(x | \omega_2)} \geq \lambda$, 则 $x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$

2.7 离散时间序列样本的统计决策

- 马尔可夫模型下的贝叶斯决策
 - 相同的思想适用于离散时间序列
 - 将 CpG 岛一类记作“+”，CpG 岛情况下的马尔可夫转移概率记作 $a_{x_{i-1}x_i}^+$
 - 将非 CpG 岛一类记作“-”，非 CpG 岛情况下的马尔可夫转移概率记作 $a_{x_{i-1}x_i}^-$
 - 定义对数似然比进行判别：公式 2-116

$$S(x) = \log \frac{P(x \mid +)}{P(x \mid -)} = \log \frac{\prod_{i=1}^L a_{x_{i-1}x_i}^+}{\prod_{i=1}^L a_{x_{i-1}x_i}^-} = \sum_{i=1}^L \log \frac{a_{x_{i-1}x_i}^+}{a_{x_{i-1}x_i}^-} \quad (2-117)$$



如何计算两个类别的状态转移概率？

2.7 离散时间序列样本的统计决策

■ 马尔可夫模型下的贝叶斯决策流程

■ 1. 确定模型形式

- 例如 CpG 岛识别任务，采用一阶马尔可夫链描述

■ 2. 根据训练样本分别估计各类的状态转移矩阵

- 收集大量 CpG 岛序列片段 以及 非CpG岛序列片段
- 在每一类样本中，统计所有位置上出现 A、C、G、T 的次数，以及每个位置后面出现 A、C、G、T 的次数

- 分别利用 $a_{st}^+ = \frac{c_{st}^+}{\sum_{t'} c_{st'}^+}$ 和 $a_{st}^- = \frac{c_{st}^-}{\sum_{t'} c_{st'}^-}$ 两类的状态转移概率

分子：从状态 s 转移到状态 t 的出现次数

分母：对状态 s 后所有可能出现的状态次数求和，用于归一化

2.7 离散时间序列样本的统计决策

- 马尔可夫模型下的贝叶斯决策流程
 - 2. 根据训练样本分别估计各类的状态转移矩阵
 - 【例子】 CpG 岛与 非 CpG 岛各自的状态转移矩阵

+	<i>A</i>	<i>C</i>	<i>G</i>	<i>T</i>
<i>A</i>	0.180	0.274	0.426	0.120
<i>C</i>	0.171	0.368	0.274	0.188
<i>G</i>	0.161	0.339	0.375	0.125
<i>T</i>	0.079	0.355	0.384	0.182

CpG 岛

—	<i>A</i>	<i>C</i>	<i>G</i>	<i>T</i>
<i>A</i>	0.300	0.205	0.285	0.210
<i>C</i>	0.322	0.298	0.078	0.302
<i>G</i>	0.248	0.246	0.298	0.208
<i>T</i>	0.177	0.239	0.292	0.282

非 CpG 岛

2.7 离散时间序列样本的统计决策

- 马尔可夫模型下的贝叶斯决策流程

- 3. 计算对数似然比

- 根据第 2 步得到的状态转移矩阵，代入公式 2-117，计算对数似然比

$$S(x) = \log \frac{P(x \mid +)}{P(x \mid -)} = \sum_{i=1}^L \log \frac{a_{x_{i-1}x_i}^+}{a_{x_{i-1}x_i}^-} = \sum_{i=1}^L \beta_{x_{i-1}x_i} \quad (2-118)$$

$\beta_{x_{i-1}x_i}$ 为 $a_{x_{i-1}x_i}^+$ 与 $a_{x_{i-1}x_i}^-$ 比值的对数 (以 2 为底)
可以通过两个类别的状态转移矩阵中相应单元的比值计算

2.7 离散时间序列样本的统计决策

- 马尔可夫模型下的贝叶斯决策流程
 - 3. 计算对数似然比
 - 根据第 2 步得到的状态转移矩阵，代入公式 2-117，计算对数似然比

beta	A	C	G	T
A	-0.740	0.419	0.580	-0.803
C	-0.913	0.302	1.812	-0.685
G	-0.624	0.461	0.331	-0.730
T	-1.169	0.573	0.393	-0.679

对数似然比矩阵 β

⚠ 状态转移矩阵以及对数似然比矩阵均没有考虑起始和终止状态！

2.7 离散时间序列样本的统计决策

- 马尔可夫模型下的贝叶斯决策流程
 - 4. 与阈值比较 进行决策
 - 例子

给定两条长度为 4 的 DNA 序列，设判别阈值 $\theta = \underline{0.5}$:

$$S(x) = \sum_{i=1}^L \beta_{x_{i-1}x_i} \begin{cases} > \theta & \Rightarrow \text{判为 CpG 岛 (+)} \\ \leq \theta & \Rightarrow \text{判为非 CpG 岛 (-)} \end{cases}$$

2.7 离散时间序列样本的统计决策

- 马尔可夫模型下的贝叶斯决策流程

- 4. 与阈值比较 进行决策

- 例子

例1: 序列 $x = \text{C-G-C-G}$ (典型 CpG 富集序列)

转移对依次为: $\text{C} \rightarrow \text{G}$, $\text{G} \rightarrow \text{C}$, $\text{C} \rightarrow \text{G}$, 共 $L = 3$ 个转移:

$$S(x) = \beta_{CG} + \beta_{GC} + \beta_{CG}$$

$$= 1.812 + 0.461 + 1.812 = 4.085$$

! 不考虑
起始和终
止状态

$$S(x) = 4.085 > 0.5 \Rightarrow \text{判为 CpG 岛} \checkmark$$

2.7 离散时间序列样本的统计决策

- 马尔可夫模型下的贝叶斯决策流程

- 4. 与阈值比较 进行决策

- 例子

例2：序列 $x = \text{A-T-G-A}$ （典型非 CpG 序列）

转移对依次为：A→T, T→G, G→A:

⚠ 不考虑
起始和终
止状态

$$S(x) = \beta_{AT} + \beta_{TG} + \beta_{GA}$$

$$= (-0.803) + 0.393 + (-0.624) = -1.034$$

$$S(x) = -1.034 \leq 0.5 \Rightarrow \text{判为非 CpG 岛} \checkmark$$