



第五章线性学习机器 与线性分类器





5.2 线性回归

- 简单线性回归

- 学习两个取值为标量的随机变量之间的线性关系

$$y = w_0 + w_1 x$$

- y : 一个变量称作响应变量或依赖变量
 - x : 一个变量称作解释变量或独立变量


- 多元线性回归

$$y = w_0 + w_1 x_1 + \cdots + w_d x_d = \sum_{i=0}^d w_i x_i = w^T x$$

- 响应变量依赖于多个解释变量

5.2 线性回归

- 机器学习中的线性回归问题



5.2 线性回归

■ 机器学习中的线性回归问题

- 给定训练样本集: $\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$
- 第 i 个样本的增广特征向量: $\mathbf{x}_i = (1, x_{i,1}, x_{i,2}, \dots, x_{i,d})^\top \in \mathbb{R}^{d+1}$
- 第 i 个样本对应的标签: y_i , 取值为任意实数 $y_i \in \mathbb{R}$
- 待学习权重参数: $\mathbf{w} = (w_0, w_1, \dots, w_d)^\top \in \mathbb{R}^{d+1}$
- 线性模型: $f(\mathbf{x}_i) = w_0 + w_1 x_{i,1} + \dots + w_d x_{i,d}$ 向量展开形式

$$= \sum_{j=0}^d w_j x_{i,j} \quad \text{增广求和形式}$$

$$= w_0 + \sum_{j=1}^d w_j x_{i,j} \quad \text{普通求和形式}$$

$$= \mathbf{w}^\top \mathbf{x}_i \quad \text{向量内积形式}$$

5.2 线性回归

- 机器学习中的线性回归问题
 - 根据训练样本，评估模型中的未知参数 $\mathbf{w}$
 - 定义最小平方误差：

$$\min_w E = \frac{1}{N} \sum_{i=1}^N (f(\mathbf{x}_i) - y_i)^2 \quad (5-5)$$

- 改写成矩阵形式：


$$\min_w E = \frac{1}{N} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 = \frac{1}{N} (\mathbf{X}\mathbf{w} - \mathbf{y})^T (\mathbf{X}\mathbf{w} - \mathbf{y}) \quad (5-6)$$

全部训练样本
的解释变量向
量组成的矩阵
(维度 $N \times d$)

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_N^T \end{bmatrix}$$

$$\mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_N \end{bmatrix}$$

全部训练样本
的响应变量组
成的向量 (维
度 $N \times 1$)



5.2 线性回归

- 机器学习中的线性回归问题

- 对公式 5-6 的目标函数求导

$$\min_w E = \frac{1}{N} \|X\mathbf{w} - \mathbf{y}\|^2 = \frac{1}{N} (X\mathbf{w} - \mathbf{y})^T (X\mathbf{w} - \mathbf{y}) \quad (5-6)$$

- 将最右侧式子展开：

$$E(w) = \frac{1}{N} [(Xw)^T (Xw) - \underbrace{(Xw)^T y}_{\text{标量}} - \underbrace{y^T (Xw)}_{\text{标量}} + y^T y]$$

标量 $(Xw)^T y = y^T (Xw)$

- 整理得到：

$$E(w) = \frac{1}{N} [w^T X^T X w - 2y^T X w + y^T y]$$

5.2 线性回归

- 机器学习中的线性回归问题

- 对公式 5-6 的目标函数求导

$$E(w) = \frac{1}{N} [w^T \underline{X^T X w} - 2y^T X w + y^T y]$$


- 矩阵求导公式:

$$\frac{\partial}{\partial \mathbf{w}} (\mathbf{w}^\top A \mathbf{w}) = 2A\mathbf{w} \quad (A \text{ 对称})$$

$$\frac{\partial}{\partial \mathbf{w}} (\mathbf{b}^\top \mathbf{w}) = \mathbf{b}$$

- 对参数 $\mathbf{w}$ 求导:

$$\frac{\partial E(w)}{\partial w} = \frac{1}{N} [2X^T X w - 2X^T y] = \frac{2}{N} X^T (X w - y) \quad (5-7)$$



5.2 线性回归

- 机器学习中的线性回归问题

- 对公式 5-6 的目标函数求导

$$\frac{\partial E(w)}{\partial w} = \frac{1}{N} [2X^T Xw - 2X^T y] = \frac{2}{N} X^T (Xw - y) \quad (5-7)$$

- 令导数为零，由公式 5-7 可得：

$$X^T Xw = X^T y \quad (5-8)$$

- 当矩阵 $X^T X$ 可逆时，最优参数的解为：

$$w^* = (X^T X)^{-1} X^T y \quad (5-9)$$

5.2 线性回归

■ 例题


已知4个训练样本，每个样本维度为2：

样本	$x_{i,1}$	$x_{i,2}$	y_i
$\mathbf{x}_1$	1	1	3
$\mathbf{x}_2$	1	2	4
$\mathbf{x}_3$	2	1	4
$\mathbf{x}_4$	2	2	5

线性模型为 $\hat{y}_i = w_1 x_{i,1} + w_2 x_{i,2}$ （不含偏置项），设计矩阵为：

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 2 & 1 \\ 2 & 2 \end{pmatrix}, \quad y = \begin{pmatrix} 3 \\ 4 \\ 4 \\ 5 \end{pmatrix}$$

请用最小二乘法公式 $w^* = (X^T X)^{-1} X^T y$ 求解最优参数 $w^* = (w_1, w_2)^T$ 。



5.2 线性回归


- 例题求解 $w^* = (X^T X)^{-1} X^T y$

第一步：计算 $X^T X$

$$X^T X = \begin{pmatrix} 1 & 1 & 2 & 2 \\ 1 & 2 & 1 & 2 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 2 & 1 \\ 2 & 2 \end{pmatrix} = \begin{pmatrix} 10 & 9 \\ 9 & 10 \end{pmatrix}$$

第二步：计算 $X^T y$

$$X^T y = \begin{pmatrix} 1 & 1 & 2 & 2 \\ 1 & 2 & 1 & 2 \end{pmatrix} \begin{pmatrix} 3 \\ 4 \\ 4 \\ 5 \end{pmatrix} = \begin{pmatrix} 25 \\ 25 \end{pmatrix}$$



5.2 线性回归

- 例题求解 $w^* = (X^T X)^{-1} X^T y$

第三步：求 $(X^T X)^{-1}$


行列式 $\det(X^T X) = 10 \times 10 - 9 \times 9 = 19$

$$(X^T X)^{-1} = \frac{1}{19} \begin{pmatrix} 10 & -9 \\ -9 & 10 \end{pmatrix}$$

2×2矩阵求逆

对于2×2矩阵，有固定公式：

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \implies A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$



5.2 线性回归

■ 例题求解 $w^* = (X^T X)^{-1} X^T y$

第四步：求 w^*

$$w^* = \frac{1}{19} \begin{pmatrix} 10 & -9 \\ -9 & 10 \end{pmatrix} \begin{pmatrix} 25 \\ 25 \end{pmatrix} = \frac{1}{19} \begin{pmatrix} 25 \\ 25 \end{pmatrix} = \begin{pmatrix} 25/19 \\ 25/19 \end{pmatrix}$$

**结论： ** $w_1^* = w_2^* = \frac{25}{19} \approx 1.3158$ ，即 $\hat{y}_i = \frac{25}{19} x_{i,1} + \frac{25}{19} x_{i,2}$ 。

回顾 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策

■ 判别函数推导过程

- 假设类条件概率密度函数 $p(x|\omega_i)$ 满足多元正态分布, 即 $p(\mathbf{x} | \omega_i) \sim N(\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i), i = 1, \dots, c)$
- 二分类问题, 最小错误率贝叶斯决策公式 2-8:

如果 $P(\omega_1 | \mathbf{x}) \geq P(\omega_2 | \mathbf{x})$, 则 $\mathbf{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$

- 根据贝叶斯公式:

如果 $p(\mathbf{x}|\omega_1)P(\omega_1) \geq p(\mathbf{x}|\omega_2)P(\omega_2)$, 则 $\mathbf{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$

回顾 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策

- 判别函数推导过程

- 根据贝叶斯公式：

如果 $\underline{p(x|\omega_1)P(\omega_1)} \geq \underline{p(x|\omega_2)P(\omega_2)}$, 则 $x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$

令 $g_1(x) = p(x | w_1)P(w_1)$ 令 $g_2(x) = p(x | w_2)P(w_2)$

- 扩展到多分类问题, 令 $g_i(x) = p(x | w_i)P(w_i)$

- 对判别函数取对数 (简化计算, 且不改变大小)

$$g_i(x) = \ln[p(x | w_i)P(w_i)] = \ln p(x | w_i) + \ln P(w_i)$$

回顾 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策

■ 判别函数推导过程

- 由于 $p(\mathbf{x} | \omega_i) \sim N(\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i), i = 1, \dots, c)$, 将类条件概率代入到 $g_i(\mathbf{x})$ 中:

$$p(\mathbf{x} | \omega_i) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}_i|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) \right\}$$

- 最终得到的判别函数 $g_i(\mathbf{x})$:

$$g_i(\mathbf{x}) = -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i)$$

(2-66)

回顾 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策

- 判别规则

如果 $g_i(x) = \max_j g_j(x)$, $j = 1, \dots, c$, 则 $x \in \omega_i$

- 决策面

- 当 $g_i(x) = g_j(x)$ 时, 样本 x 恰好在 i, j 两类的分界线上, 这条分界线就叫做决策面

$$-\frac{1}{2} \left[(x - \mu_i)^T \Sigma_i^{-1} (x - \mu_i) - (x - \mu_j)^T \Sigma_j^{-1} (x - \mu_j) \right] - \frac{1}{2} \ln \frac{|\Sigma_i|}{|\Sigma_j|} + \ln \frac{P(\omega_i)}{P(\omega_j)} = 0$$

(2-67)

回顾 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策

- 情况1: $\Sigma_i = \sigma^2 I, i = 1, 2, \dots, c$
 - (1) 先验概率 $P(\omega_i)$ 与 $P(\omega_j)$ 不相等

$$g_i(x) = -\frac{1}{2\sigma^2} (-2\mu_i^T x + \mu_i^T \mu_i) + \ln P(\omega_i) = \boxed{w_i^T x + w_{i0}} \quad (2-75)$$

公式含义: 判别函数 $g_i(x)$ 是样本 x 的线性函数

- 线性分类器的决策面是由线性方程 $g_i(x) - g_j(x) = 0$ 所确定的一个超平面

回顾 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策

■ 情况1: $\Sigma_i = \sigma^2 I, i = 1, 2, \dots, c$

■ (1) 先验概率 $P(\omega_i)$ 与 $P(\omega_j)$ 不相等

■ 线性分类器的决策面是由线性方程 $g_i(x) - g_j(x) = 0$ 所确定的一个超平面

$$\underline{g_i(x)} - \underline{g_j(x)} = 0$$

代入公式 2-75

$$\underline{\mathbf{w}_i^T x + w_{i0}} = \underline{\mathbf{w}_j^T x + w_{j0}}$$

移项整理

$$(\mathbf{w}_i - \mathbf{w}_j)^T x + (w_{i0} - w_{j0}) = 0$$

回顾 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策

■ 情况1: $\Sigma_i = \sigma^2 I, i = 1, 2, \dots, c$

■ (1) 先验概率 $P(\omega_i)$ 与 $P(\omega_j)$ 不相等

■ 线性分类器的决策面是由线性方程 $g_i(x) - g_j(x) = 0$ 所确定的一个超平面

$$(\mathbf{w}_i - \mathbf{w}_j)^T \mathbf{x} + (w_{i0} - w_{j0}) = 0$$

■ 超平面的一般式

■ 在 d 维空间中，超平面是满足以下线性方程的所有点 $\mathbf{x}$ 的集合

$$w_1 x_1 + w_2 x_2 + \dots + w_d x_d + w_0 = 0$$

成立

符合
超平面
定义

回顾 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策

- 情况1: $\Sigma_i = \sigma^2 I, i = 1, 2, \dots, c$
 - (1) 先验概率 $P(\omega_i)$ 与 $P(\omega_j)$ 不相等

- 超平面的点法式

$$\mathbf{w}^T (x - x_0) = 0$$

其中, $\mathbf{w}^T$ 是超平面的法向量, x_0 为超平面上的一个特定点

- 由于超平面的点法式与一般式等价, 可以将 $(\mathbf{w}_i - \mathbf{w}_j)^T x + (w_{i0} - w_{j0}) = 0$ 转化为点法式, 并求出 $\mathbf{w}$ 和 x_0 (推导过程略)

回顾 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策

- 情况1: $\Sigma_i = \sigma^2 I, i = 1, 2, \dots, c$
 - (1) 先验概率 $P(\omega_i)$ 与 $P(\omega_j)$ 不相等
 - 超平面的点法式

$$\mathbf{w}^T (x - x_0) = 0$$

■ 求得:

$$\mathbf{w} = \boldsymbol{\mu}_i - \boldsymbol{\mu}_j \quad (2-80)$$

$$\mathbf{x}_0 = \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) - \frac{\sigma^2}{\|\boldsymbol{\mu}_i - \boldsymbol{\mu}_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j) \quad (2-80)$$

回顾 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策

- 情况1: $\Sigma_i = \sigma^2 I, i = 1, 2, \dots, c$
 - (1) 先验概率 $P(\omega_i)$ 与 $P(\omega_j)$ 不相等

$$\boldsymbol{w} = \boldsymbol{\mu}_i - \boldsymbol{\mu}_j$$

- 公式含义：决策面的法向量为 $\boldsymbol{\mu}_i - \boldsymbol{\mu}_j$ ，因此，决策面垂直于 i, j 两类均值向量之差

$$\boldsymbol{x}_0 = \frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j) - \frac{\sigma^2}{\|\boldsymbol{\mu}_i - \boldsymbol{\mu}_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)} (\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)$$


- 公式含义：决策面经过 $\boldsymbol{x}_0$ ， $\frac{1}{2}(\boldsymbol{\mu}_i + \boldsymbol{\mu}_j)$ 为两类均值向量的中点，后一项表示偏移量，与先验概率有关，偏移规律为：决策面向先验概率小的类偏移，使先验概率大的类获得更大的决策空间

回顾 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策


■ 情况1: $\Sigma_i = \sigma^2 I, i = 1, 2, \dots, c$


■ (1) 先验概率 $P(\omega_i)$ 与 $P(\omega_j)$ 不相等

情况1: $P(\omega_i) > P(\omega_j)$



情况2: $P(\omega_j) > P(\omega_i)$






5.3 线性判别函数的基本概念

- 线性判别函数

- 第 i 类对应的判别函数: $g_i(x) = w_i^T x + w_{i,0}$, 其中 x 为 d 维征向量, w_i 为 d 维权重向量, $w_{i,0}$ 为 1 维阈值

- 二分类决策规则

- 令 $g(x) = g_1(x) - g_2(x)$, 则:
$$\begin{cases} \text{如果 } g(x) > 0, \text{ 则决策 } x \in \omega_1 \\ \text{如果 } g(x) < 0, \text{ 则决策 } x \in \omega_2 \\ \text{如果 } g(x) = 0, \text{ 可将 } x \text{ 任意分到某一类, 或拒绝} \end{cases} \quad (5-11)$$



5.3 线性判别函数的基本概念

- 二分类决策面

- ω_1 类和 ω_2 类的判别函数值相等：

$$\underline{g_1(x)} = \underline{g_2(x)}$$

$$\mathbf{w}_1^\top \mathbf{x} + w_{1,0} \quad \mathbf{w}_2^\top \mathbf{x} + w_{2,0}$$

- 根据 $g(x) = g_1(x) - g_2(x)$ ：

$$g(\mathbf{x}) = g_1(\mathbf{x}) - g_2(\mathbf{x}) = \underbrace{(\mathbf{w}_1 - \mathbf{w}_2)^\top}_{\text{令其等于}\mathbf{w}} \mathbf{x} + \underbrace{(w_{1,0} - w_{2,0})}_{\text{令其等于}w_0}$$

- 将 $g(x)$ 记作： $g(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + w_0$
- $\mathbf{w}$ 是决策面的法向量


5.3 线性判别函数的基本概念

■ 二分类决策面

- 将特征空间任意点 x 分解为两个部分：

$$\mathbf{x} = \mathbf{x}_p + r \frac{\mathbf{w}}{\|\mathbf{w}\|} \quad (5-14)$$

- $\mathbf{x}_p$ 是 $\mathbf{x}$ 在决策面上的垂直投影点（即从 $\mathbf{x}$ 向 H 做垂线，垂足就是 $\mathbf{x}_p$ ）
- $\frac{\mathbf{w}}{\|\mathbf{w}\|}$ 是法向量 $\mathbf{w}$ 方向上的单位向量
- r 是 $\mathbf{x}$ 到决策面的有符号距离




5.3 线性判别函数的基本概念

■ 二分类决策面

- 将特征空间任意点 x 分解为两个部分：

$$\mathbf{x} = \mathbf{x}_p + r \frac{\mathbf{w}}{\|\mathbf{w}\|} \quad (5-14)$$

- **几何意义**：从投影点 $\mathbf{x}_p$ 出发，沿着法方向走 r 个单位长度，就到达了 $\mathbf{x}$ 。 $r > 0$ 说明 $\mathbf{x}$ 在 $\mathbf{w}$ 所指的一侧 ($\mathcal{R}_1$)， $r < 0$ 说明在 $\mathbf{w}$ 反方向一侧 ($\mathcal{R}_2$)




5.3 线性判别函数的基本概念

■ 二分类决策面

- 将公式 5-14 代入决策面函数 $g(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + w_0$:

$$\begin{aligned} g(\mathbf{x}) &= \mathbf{w}^\top \mathbf{x} + w_0 \\ &= \mathbf{w}^\top \left(\mathbf{x}_p + r \frac{\mathbf{w}}{\|\mathbf{w}\|} \right) + w_0 \\ &= \underbrace{(\mathbf{w}^\top \mathbf{x}_p + w_0)}_{=0} + r \frac{\boxed{\mathbf{w}^\top \mathbf{w}}}{\|\mathbf{w}\|} \text{ 等于 } \|\mathbf{w}\|^2 \\ &= r \|\mathbf{w}\| \end{aligned}$$

- 公式意义：任意点 $\mathbf{x}$ 到决策面的距离 r 与 $g(\mathbf{x})$ 值成正比。即 $g(\mathbf{x})$ 值不仅能说明分类结果（根据正负号），还能反映样本点 $\mathbf{x}$ 距离决策边界的远近（根据绝对值大小）



5.3 线性判别函数的基本概念


■ 例题

- 决策面函数 $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$, 样本 $\mathbf{x}_A$ 属于正类且 $g(\mathbf{x}_A) = 6$, 样本 $\mathbf{x}_B$ 属于负类且 $g(\mathbf{x}_B) = -3$, 则 $\mathbf{x}_A$ 到决策面的距离是 $\mathbf{x}_B$ 的_____倍

样本 $\mathbf{x}$ 到决策面 $g(\mathbf{x}) = 0$ 的有符号距离为:

$$r = \frac{g(\mathbf{x})}{\|\mathbf{w}\|}$$

其中 $r > 0$ 表示样本在 $\mathbf{w}$ 所指的一侧, $r < 0$ 表示在 $\mathbf{w}$ 反方向一侧。



5.3 线性判别函数的基本概念

■ 例题求解

对 $\boldsymbol{x}_A$:

$$r_A = \frac{g(\boldsymbol{x}_A)}{\|\boldsymbol{w}\|} = \frac{6}{\|\boldsymbol{w}\|}$$

对 $\boldsymbol{x}_B$:

$$r_B = \frac{g(\boldsymbol{x}_B)}{\|\boldsymbol{w}\|} = \frac{-3}{\|\boldsymbol{w}\|}$$


几何距离之比:

$$\frac{|r_A|}{|r_B|} = \frac{6/\|\boldsymbol{w}\|}{3/\|\boldsymbol{w}\|} = 2$$

5.4 Fisher 线性判别分析



■ 动机


- 两类的线性判别问题可以看作是将所有样本投影到一个方向上
- 在这个一维空间中确定一个分类的阈值
- 过阈值点且与投影方向垂直的超平面就是两类的决策面



5.4 Fisher 线性判别分析


■ 如何确定投影方向?





5.4 Fisher 线性判别分析

- 如何确定投影方向?
 - 使投影后的两类样本相隔尽可能远
 - 而每一类样本尽可能聚集




5.4 Fisher 线性判别分析

■ 基本概念

- N 个训练样本构成的样本集记作 $\mathcal{X} = \{x_1, \dots, x_N\}$
- 每个样本是一个 d 维向量
- ω_1 类的样本记作 $\mathcal{X}_1 = \{x_1^1, \dots, x_{N_1}^1\}$
- ω_2 类的样本记作 $\mathcal{X}_2 = \{x_1^2, \dots, x_{N_2}^2\}$
- 目的：寻找一个投影方向 w (d 维向量)
- 投影后的样本为：

$$y_i = \mathbf{w}^\top \mathbf{x}_i, \quad i = 1, 2, \dots, N \quad (5-18)$$



5.4 Fisher 线性判别分析

- 基本概念


- 原样本空间中

- 类均值向量为:

$$\mathbf{m}_i = \frac{1}{N_i} \sum_{\mathbf{x}_j \in \mathcal{X}_i} \mathbf{x}_j, \quad i = 1, 2 \quad (5-19)$$

- 各类的类内离散度矩阵为:

$$\mathbf{S}_i = \sum_{\mathbf{x}_j \in \mathcal{X}_i} (\mathbf{x}_j - \mathbf{m}_i)(\mathbf{x}_j - \mathbf{m}_i)^T, \quad i = 1, 2 \quad (5-20)$$



5.4 Fisher 线性判别分析

- 基本概念


- 原样本空间中

- 总类内离散度矩阵为：

$$\mathbf{S}_w = \mathbf{S}_1 + \mathbf{S}_2 \quad (5-22)$$

- 类间离散度矩阵为：

$$\mathbf{S}_b = (\mathbf{m}_1 - \mathbf{m}_2)(\mathbf{m}_1 - \mathbf{m}_2)^T \quad (5-23)$$



5.4 Fisher 线性判别分析

- 基本概念


- 投影后的一维空间中

- 类均值为:

$$\tilde{m}_i = \frac{1}{N_i} \sum_{\mathbf{x}_j \in \mathcal{X}_i} \mathbf{w}^T \mathbf{x}_j = \mathbf{w}^T \mathbf{m}_i, \quad i = 1, 2 \quad (5-24)$$

- 各类的类内离散度值为:

$$\tilde{S}_i^2 = \sum_{\mathbf{x}_j \in \mathcal{X}_i} (\mathbf{w}^T \mathbf{x}_j - \tilde{m}_i)^2, \quad i = 1, 2 \quad (5-25)$$



5.4 Fisher 线性判别分析

- 基本概念

- 投影后的一维空间中

- 总类内离散度值为:

$$\tilde{S}_w = \tilde{S}_1^2 + \tilde{S}_2^2 \quad (5-26)$$

- 类间离散度值为两类均值差的平方

$$\tilde{S}_b = (\tilde{m}_1 - \tilde{m}_2)^2 \quad (5-27)$$

5.4 Fisher 线性判别分析

■ 如何确定投影方向？

- 使投影后的两类样本相隔尽可能远 (对应公式5-28 的分子)
- 而每一类样本尽可能聚集 (对应公式 5-28 的分母)

■ Fisher 准则函数

$$\max J_F(w) = \frac{\tilde{S}_b}{\tilde{S}_w} = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2} \quad (5-28)$$


- 让分子 (类间离散度值) 越大, 让分母 (总类内离散度值) 越小

5.4 Fisher 线性判别分析

■ Fisher 准则函数

- 对分子 类间离散度值 进行推导：

$$\tilde{S}_b = (\tilde{m}_1 - \tilde{m}_2)^2$$

代入公式 5-24



$$= (w^T m_1 - w^T m_2)^2$$

提取公因子



$$= (w^T (m_1 - m_2))^2$$

(5-29)

令 $a = w^T v$, 有



$$= w^T (m_1 - m_2) (m_1 - m_2)^T w$$

$$a^2 = a \cdot a =$$


$$(w^T v)(w^T v) =$$

$$(w^T v)(v^T w) =$$

$$w^T (v v^T) w$$

$$= w^T \underline{S_b} w$$

代入公式 5-23, 得到原样本
空间对应的类间离散度矩阵



5.4 Fisher 线性判别分析

- Fisher 准则函数

- 对分母 总类内离散度值 进行推导：


$$\tilde{S}_w = \tilde{S}_1^2 + \tilde{S}_2^2 \quad \text{公式 5-26}$$

$$= \sum_{x_j \in \mathcal{X}_1} (w^T x_j - w^T m_1)^2 + \sum_{x_j \in \mathcal{X}_2} (w^T x_j - w^T m_2)^2 \quad \text{公式 5-24, 5-25}$$

$$= \sum_{x_j \in \mathcal{X}_1} w^T (x_j - m_1)(x_j - m_1)^T w + \sum_{x_j \in \mathcal{X}_2} w^T (x_j - m_2)(x_j - m_2)^T w \quad (5-30)$$

$$= w^T S_1 w + w^T S_2 w \quad \text{公式 5-20}$$

$$= w^T S_w w \quad \text{公式 5-22}$$



5.4 Fisher 线性判别分析

- Fisher 准则函数

- 代入分子分母:

$$\max_w J_F(w) = \frac{w^T S_b w}{w^T S_w w} \quad (5-31)$$

- 优化目标: 求使得公式 5-31 取得最大的投影方向 w
( 对 w 幅值的调节不会影响其方向, 同样不会影响 $J_F(w)$)
 - 问题转化: 令公式 5-31 中的分母为非零常数, 并最大化分子:

$$\begin{aligned} \max \quad & w^T S_b w \\ \text{s.t.} \quad & w^T S_w w = c \neq 0 \end{aligned} \quad (5-32)$$

5.4 Fisher 线性判别分析

- Fisher 准则函数

- 引入拉格朗日乘子转化为无约束极值问题：


$$L(w, \lambda) = w^T S_b w - \lambda (w^T S_w w - c) \quad (5-33)$$

- 对 w 求偏导，令偏导为零：

$$\frac{\partial L(w, \lambda)}{\partial w} = 0 \quad (5-34)$$

对于二次型 $w^T A w$ 关于向量 w 的导数，当 A 是对称矩阵时，有标准结果：

散度矩阵 S_b 和 S_w 都是对称矩阵 $\frac{\partial (w^T A w)}{\partial w} = 2Aw$



5.4 Fisher 线性判别分析

- Fisher 准则函数

- 极值解 w^* 满足:


$$\mathbf{S}_b w^* - \lambda \mathbf{S}_w w^* = 0 \quad (5-35)$$

- 当 $\mathbf{S}_w$ 是非奇异的 (样本数大于维数时通常是非奇异的), 可得:

$$\mathbf{S}_w^{-1} \mathbf{S}_b w^* = \lambda w^* \quad (5-36)$$

- 根据公式 5-23, 替换 $\mathbf{S}_b$:

$$\lambda w^* = \mathbf{S}_w^{-1} (\mathbf{m}_1 - \mathbf{m}_2)(\mathbf{m}_1 - \mathbf{m}_2)^T w^* \quad (5-37)$$



5.4 Fisher 线性判别分析

- Fisher 准则函数

- 根据公式 5-23, 替换 S_b :

$$\lambda \mathbf{w}^* = \mathbf{S}_w^{-1}(\mathbf{m}_1 - \mathbf{m}_2) \underbrace{(\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{w}^*}_{\text{标量}} \quad (5-37)$$

-  $(\mathbf{m}_1 - \mathbf{m}_2)^T \mathbf{w}^*$ 是标量, 不影响 $\mathbf{w}^*$ 的方向
- $\mathbf{w}^*$ 的方向是由 $\mathbf{S}_w^{-1}(\mathbf{m}_1 - \mathbf{m}_2)$ 决定的, 我们只关心 $\mathbf{w}^*$ 的方向:


$$\mathbf{w}^* = \mathbf{S}_w^{-1}(\mathbf{m}_1 - \mathbf{m}_2) \quad (5-38)$$


5.4 Fisher 线性判别分析

■ Fisher 准则函数

-  公式 5-38 得到的是最优投影方向，若要得到分类决策面，还需要在投影后的方向（一维空间）上确定一个分类阈值 w_0

紫色线表示最优投影方向 w^* ，
只有确定绿色棱形块阈值 w_0 ，
才能得到绿色虚线对应的决策面





5.4 Fisher 线性判别分析

- 与 章节 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策 的联系
 - 当样本是正态分布且两类协方差矩阵相同时，决策面的一般式为 $g(x) = w^T x + w_0$ ，其中：

$$w = \Sigma^{-1}(\mu_1 - \mu_2)$$

$$w_0 = -\frac{1}{2}(\mu_1 + \mu_2)^T \Sigma^{-1}(\mu_1 - \mu_2) - \ln \frac{P(w_2)}{P(w_1)}$$

-  **产生联系的主要原因在于：** Fisher 线性判别并不对样本的分布作任何假设。但当样本维数比较高且样本数比较多时，投影到一维空间后样本接近正态分布

5.4 Fisher 线性判别分析

- 与 章节 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策 的联系

- 贝叶斯决策的决策面法向量：

$$w = \Sigma^{-1}(\mu_1 - \mu_2)$$

- Fisher 判别准则下的最优投影方向：

$$w^* = S_w^{-1}(m_1 - m_2) \quad (5-38)$$

- 若将样本的算术平均作为对正态分布真实均值的估计、将样本协方差矩阵作为对真实协方差矩阵的估计，则 Fisher 线性判别所得的最优投影方向就是贝叶斯决策的法向量方向！

5.4 Fisher 线性判别分析

- 与 章节 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策 的联系

- 贝叶斯决策的决策面偏置项:

$$w_0 = -\frac{1}{2}(\mu_1 + \mu_2)^T \Sigma^{-1}(\mu_1 - \mu_2) - \ln \frac{P(w_2)}{P(w_1)}$$

- 根据上式, 确定 Fisher 判别准则下的分类阈值 (利用 m_i 代替 μ_i , 利用 S_w^{-1} 代替 Σ^{-1})

$$w_0 = -\frac{1}{2}(m_1 + m_2)^T S_w^{-1}(m_1 - m_2) - \ln \frac{P(w_2)}{P(w_1)}$$

(5-45)

5.4 Fisher 线性判别分析

- 与 章节 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策 的联系

- 当不考虑先验概率差异, 即 $P(\omega_1) = P(\omega_2)$:

$$w_0 = -\frac{1}{2}(\tilde{m}_1 + \tilde{m}_2) \quad (5-46)$$


- 从公式 5-45 到 5-46 推导过程:

代入公式 5-38

$$w^* = S_w^{-1}(m_1 - m_2) \quad \tilde{m}_1 + \tilde{m}_2 = w^T m_1 + w^T m_2 = w^T(m_1 + m_2)$$
$$= (m_1 - m_2)^T S_w^{-1}(m_1 + m_2)$$

同时乘
以 $-\frac{1}{2}$

$$-\frac{1}{2}(\tilde{m}_1 + \tilde{m}_2) = -\frac{1}{2}(m_1 + m_2)^T S_w^{-1}(m_1 - m_2) = w_0$$



5.4 Fisher 线性判别分析

- 与 章节 2.5.2 正态分布概率模型下的最小错误率贝叶斯决策 的联系

- 当不考虑先验概率差异, 即 $P(\omega_1) = P(\omega_2)$:

- 二分类决策规则

$$\text{若 } g(x) = \mathbf{w}^{*\text{T}}x + \mathbf{w}_0 \geq 0, \text{ 则 } x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases} \quad (5-42)$$

- 其中:

$$\mathbf{w}^* = \mathbf{S}_{\mathbf{w}}^{-1}(\mathbf{m}_1 - \mathbf{m}_2) \quad (5-38)$$

$$\mathbf{w}_0 = -\frac{1}{2}(\tilde{\mathbf{m}}_1 + \tilde{\mathbf{m}}_2) \quad (5-46)$$

5.4 Fisher 线性判别分析


■ 例题

已知两类样本，每类各3个，样本维度为2：

样本	类别	$x_{i,1}$	$x_{i,2}$
$\mathbf{x}_1$	ω_1	1	0
$\mathbf{x}_2$	ω_1	0	1
$\mathbf{x}_3$	ω_1	-1	-1
$\mathbf{x}_4$	ω_2	5	2
$\mathbf{x}_5$	ω_2	4	3
$\mathbf{x}_6$	ω_2	3	1

设两类先验概率相等 $P(\omega_1) = P(\omega_2)$ ，且两类协方差矩阵相等。试：

1. 求各类均值向量 $\mathbf{m}_1, \mathbf{m}_2$
2. 求总类内离散度矩阵 $\mathbf{S}_w$ 及其逆矩阵
3. 求Fisher最优投影方向 $\mathbf{w}^*$
4. 求投影后各类均值 $\tilde{\mathbf{m}}_1, \tilde{\mathbf{m}}_2$ 及阈值 w_0
5. 写出判别函数 $g(\mathbf{x})$ 及决策规则



5.4 Fisher 线性判别分析

■ 例题求解

第一步：求各类均值向量

$$\mathbf{m}_1 = \frac{1}{3} \begin{pmatrix} 1 + 0 + (-1) \\ 0 + 1 + (-1) \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\mathbf{m}_2 = \frac{1}{3} \begin{pmatrix} 5 + 4 + 3 \\ 2 + 3 + 1 \end{pmatrix} = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$$

$$\mathbf{m}_i = \frac{1}{N_i} \sum_{\mathbf{x}_j \in \mathcal{X}_i} \mathbf{x}_j, \quad i = 1, 2 \quad (5-19)$$

5.4 Fisher 线性判别分析

■ 例题求解

$$\mathbf{S}_i = \sum_{\mathbf{x}_j \in \mathcal{X}_i} (\mathbf{x}_j - \mathbf{m}_i)(\mathbf{x}_j - \mathbf{m}_i)^T, \quad i = 1, 2$$

(5-20)

$$\mathbf{S}_w = \mathbf{S}_1 + \mathbf{S}_2 = \begin{pmatrix} 4 & 2 \\ 2 & 4 \end{pmatrix}$$

$$\mathbf{S}_w = \mathbf{S}_1 + \mathbf{S}_2 \quad (5-22)$$

第二步：求总类内离散度矩阵


$\mathbf{S}_1$: (各样本减 $\mathbf{m}_1 = (0, 0)^T$ 后就是自身)

$$\begin{aligned} \mathbf{S}_1 &= \begin{pmatrix} 1 \\ 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \end{pmatrix} + \begin{pmatrix} 0 \\ 1 \end{pmatrix} \begin{pmatrix} 0 & 1 \end{pmatrix} + \begin{pmatrix} -1 \\ -1 \end{pmatrix} \begin{pmatrix} -1 & -1 \end{pmatrix} \\ &= \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} + \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \end{aligned}$$

$\mathbf{S}_2$ 的完整计算过程

$$\mathbf{x}_4 - \mathbf{m}_2 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \mathbf{x}_5 - \mathbf{m}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad \mathbf{x}_6 - \mathbf{m}_2 = \begin{pmatrix} -1 \\ -1 \end{pmatrix}$$

$$\begin{aligned} \mathbf{S}_2 &= \begin{pmatrix} 1 \\ 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \end{pmatrix} + \begin{pmatrix} 0 \\ 1 \end{pmatrix} \begin{pmatrix} 0 & 1 \end{pmatrix} + \begin{pmatrix} -1 \\ -1 \end{pmatrix} \begin{pmatrix} -1 & -1 \end{pmatrix} \\ &= \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} + \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \end{aligned}$$



5.4 Fisher 线性判别分析

■ 例题求解

第三步：求 S_w^{-1}


$$|S_w| = 4 \times 4 - 2 \times 2 = 12$$

$$S_w^{-1} = \frac{1}{12} \begin{pmatrix} 4 & -2 \\ -2 & 4 \end{pmatrix} = \begin{pmatrix} \frac{1}{3} & -\frac{1}{6} \\ -\frac{1}{6} & \frac{1}{3} \end{pmatrix}$$

2×2矩阵求逆

对于2×2矩阵，有固定公式：

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \implies A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$




5.4 Fisher 线性判别分析

■ 例题求解

第四步：求最优投影方向（式5-38）

$$\begin{aligned} \mathbf{w}^* &= \mathbf{S}_w^{-1}(\mathbf{m}_1 - \mathbf{m}_2) = \begin{pmatrix} \frac{1}{3} & -\frac{1}{6} \\ -\frac{1}{6} & \frac{1}{3} \end{pmatrix} \begin{pmatrix} -4 \\ -2 \end{pmatrix} \\ &= \begin{pmatrix} \frac{1}{3} \times (-4) + (-\frac{1}{6}) \times (-2) \\ (-\frac{1}{6}) \times (-4) + \frac{1}{3} \times (-2) \end{pmatrix} = \begin{pmatrix} -\frac{4}{3} + \frac{1}{3} \\ \frac{2}{3} - \frac{2}{3} \end{pmatrix} = \begin{pmatrix} -1 \\ 0 \end{pmatrix} \end{aligned}$$

$$\mathbf{w}^* = \mathbf{S}_w^{-1}(\mathbf{m}_1 - \mathbf{m}_2) \quad (5-38)$$



5.4 Fisher 线性判别分析

■ 例题求解

第五步：投影后各类均值及阈值


$$\tilde{m}_i = \frac{1}{N_i} \sum_{\mathbf{x}_j \in \mathcal{X}_i} \mathbf{w}^T \mathbf{x}_j = \mathbf{w}^T \mathbf{m}_i, \quad i = 1, 2$$

(5-24)

$$\tilde{m}_1 = \mathbf{w}^{*T} \mathbf{m}_1 = (-1, 0) \begin{pmatrix} 0 \\ 0 \end{pmatrix} = 0$$

$$w_0 = -\frac{1}{2}(\tilde{m}_1 + \tilde{m}_2) \quad (5-46)$$

$$w_0 = -\frac{1}{2}(\tilde{m}_1 + \tilde{m}_2) = -\frac{1}{2}(0 + (-4)) = 2$$



5.4 Fisher 线性判别分析


- 例题求解

第六步：判别函数与决策规则

$$g(\mathbf{x}) = \mathbf{w}^{*\mathrm{T}} \mathbf{x} + w_0 = -x_1 + 2$$

$$g(\mathbf{x}) = -x_1 + 2 \begin{cases} \geq 0 \Rightarrow \mathbf{x} \in \omega_1 \\ < 0 \Rightarrow \mathbf{x} \in \omega_2 \end{cases}$$

$$\text{若 } g(x) = \mathbf{w}^{*\mathrm{T}} x + \mathbf{w}_0 \geq 0, \text{ 则 } x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases} \quad (5-42)$$



5.4 Fisher 线性判别分析

■ 例题求解

验证

样本	x_1	$g(\mathbf{x}) = -x_1 + 2$	判别	正确?
$\mathbf{x}_1$	1	1	ω_1	✓
$\mathbf{x}_2$	0	2	ω_1	✓
$\mathbf{x}_3$	-1	3	ω_1	✓
$\mathbf{x}_4$	5	-3	ω_2	✓
$\mathbf{x}_5$	4	-2	ω_2	✓
$\mathbf{x}_6$	3	-1	ω_2	✓