


5.5 感知器

- 与 Fisher 线性判别的不同
 - Fisher 线性判别将线性分类器的设计分为两步
 - 1. 确定最优投影方向
 - 2. 确定分类阈值
 - 感知器
 - 一步得到完整的决策面函数 $g(x) = w^T x + w_0$
- 本小节使用增广向量形式
 - 第 i 个样本的增广特征向量: $\mathbf{x}_i = (1, x_{i,1}, x_{i,2}, \dots, x_{i,d})^T \in \mathbb{R}^{d+1}$
 - 待学习权重参数: $\mathbf{w} = (w_0, w_1, \dots, w_d)^T \in \mathbb{R}^{d+1}$





5.5 感知器


- 样本集可分性
 - 给定二分类样本集 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$
 - 若存在权重向量 $\mathbf{w}$, 使得对于样本集中的任一个样本 $\mathbf{x}_i, i = 1, 2, \dots, N$, 若 $\mathbf{x}_i \in \omega_1$, 则 $\mathbf{w}^T \mathbf{x}_i > 0$, 若 $\mathbf{x}_i \in \omega_2$, 则 $\mathbf{w}^T \mathbf{x}_i < 0$
 - 即在样本的特征空间中, 至少存在一个线性决策面能够把两类样本没有错误地分开
 - 则样本集线性可分

5.5 感知器

■ 样本集可分性

■ 左侧线性可分，右侧线性不可分






5.5 感知器

■ 样本集可分性

- 定义一个新的变量 $\mathbf{x}'_i$ ，对于第一类的样本 $\mathbf{x}'_i = \mathbf{x}_i$ ；对于第二类样本，则 $\mathbf{x}'_i = -\mathbf{x}_i$ ：

$$\mathbf{x}'_i = \begin{cases} \mathbf{x}_i, & \text{若 } \mathbf{x}_i \in \omega_1 \\ -\mathbf{x}_i, & \text{若 } \mathbf{x}_i \in \omega_2 \end{cases} \quad i = 1, 2, \dots, N \quad (5-52)$$

- 此时线性可分情况统一为：
 - 对于样本集中的任意一个样本 $\mathbf{x}_i, i = 1, 2, \dots, N$ ，使得 $\mathbf{w}^T \mathbf{x}'_i > 0$
- $\mathbf{x}'_i$ 称作规范化增广样本向量
- ⚠ 本小节仅讨论样本线性可分的情况



5.5 感知器

■ 解向量


- 对于线性可分的一组样本 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$, 若一个权重向量 $\mathbf{w}^*$ 满足:

$$\mathbf{w}^{*\text{T}} \mathbf{x}'_i > 0, i = 1, 2, \dots, N$$

- 则称 $\mathbf{w}^*$ 为一个解向量

■ 解区

- 在权重空间中, 所有解向量组成的区域称作解区
- 解区中的任意一个向量都是解向量, 都能把样本没有错误地区分开



5.5 感知器

■ 余量

- 如果一个解向量靠近解区的边缘，虽然所有样本都能满足 $\mathbf{w}^{*T} \mathbf{x}'_i > 0$ ，但对于某些样本，该值可能刚刚大于 0
- 考虑到噪声、数值计算误差等因素，需要将解区向中间缩小，不取靠近边缘的解
- 引入余量 $b > 0$:

$$\mathbf{w}^{*T} \mathbf{x}'_i > b, i = 1, 2, \dots, N \quad (5-55)$$


5.5 感知器

■ 感知器准则函数

- 对于权重向量 $\mathbf{w}$ ，如果某个样本 $\mathbf{x}_i$ 被错误分类，则 $\mathbf{w}^T \mathbf{x}'_i \leq 0$
- 利用对所有错分样本求和作为对其的惩罚：

$$J_P(\mathbf{w}) = \sum_{\mathbf{w}^T \mathbf{x}'_i \leq 0} (-\mathbf{w}^T \mathbf{x}'_i) \quad (5-56)$$

- 当且仅当 $J_p(\mathbf{w}^*) = \min J_p(\mathbf{w}) = 0$ 时 $\mathbf{w}^*$ 是解向量 (⚠️ 等于 0 是因为前面假设了样本集线性可分)
- 利用梯度下降法迭代求解



5.5 感知器

- 梯度下降


- 参数更新公式:

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \rho_t \nabla J_p(\mathbf{w}) \quad (5-57)$$

- $\mathbf{w}_{t+1}$: 更新后的下一时刻权重向量
 - $\mathbf{w}_t$: 更新前的当前时刻权重向量
 - ρ_t : 步长, 学习率
 - $\nabla J_p(\mathbf{w})$: 准则函数 J_p 对 $\mathbf{w}$ 求偏导

- 偏导计算:

$$\nabla J_P(\mathbf{w}) = \frac{\partial J_P(\mathbf{w})}{\partial \mathbf{w}} = \frac{\partial \sum_{\mathbf{w}^T \mathbf{x}'_i \leq 0} (-\mathbf{w}^T \mathbf{x}'_i)}{\partial \mathbf{w}} = \sum_{\mathbf{w}^T \mathbf{x}'_i \leq 0} (-\mathbf{x}'_i) \quad (5-58)$$




5.5 感知器

- 梯度下降

- 将公式 5-58 代入 公式 5-57:

$$\boldsymbol{w}_{t+1} = \boldsymbol{w}_t + \rho_t \sum_{\boldsymbol{w}^T \boldsymbol{x}'_i \leq 0} \boldsymbol{x}'_i \quad (5-59)$$


- 上述做法是一次性将所有错误样本都进行修正
 - 更常用的是每次只修正一个样本的固定增量法



5.5 感知器

- 固定增量法算法流程

- 1. $t = 0$, 任意选择初始的权重向量 $\mathbf{w}_0$
- 2. 考察样本 $\mathbf{x}_i$, 若 $\mathbf{w}_t^T \mathbf{x}_i' \leq 0$, 则 $\mathbf{w}_{t+1} = \mathbf{w}_t + \rho_t \mathbf{x}_i'$
- 3. 考查另一个样本, 重复步骤 (2), 直至对所有样本均满足 $\mathbf{w}_t^T \mathbf{x}_i' > 0$
-  如果考虑余量 b , 只需将 $\mathbf{w}_t^T \mathbf{x}_i' \leq 0$ 改为 $\mathbf{w}_t^T \mathbf{x}_i' \leq b$



5.5 感知器

■ 注意事项

- 在感知器准则中，要求全部样本是线性可分的
- 对于线性可分的样本集，采用梯度下降迭代算法，经过有限次修正后一定会收敛到一个解向量
- 当样本不是线性可分时，如果仍然使用感知器算法，则算法不会收敛
- 由于感知器只能解决线性可分的问题，因而在实际应用中，直接使用感知器算法的场合并不多
- 但它是很多更复杂的算法的基础，例如支持向量机和多层感知器



5.5 感知器

已知二分类问题的训练样本集如下，其中每个样本为二维特征向量：

第一类 ω_1 包含 2 个样本： $\mathbf{x}_1 = (1, 1)^\top$ ， $\mathbf{x}_2 = (2, 0)^\top$

第二类 ω_2 包含 2 个样本： $\mathbf{x}_3 = (0, 2)^\top$ ， $\mathbf{x}_4 = (-1, 1)^\top$


增广向量（首位补1）：

$$\mathbf{x}_1 = (1, 1, 1)^\top, \quad \mathbf{x}_2 = (1, 2, 0)^\top, \quad \mathbf{x}_3 = (1, 0, 2)^\top, \quad \mathbf{x}_4 = (1, -1, 1)^\top$$

规范化增广向量（ ω_2 取反）：

$$\mathbf{x}'_1 = (1, 1, 1)^\top, \quad \mathbf{x}'_2 = (1, 2, 0)^\top, \quad \mathbf{x}'_3 = (-1, 0, -2)^\top, \quad \mathbf{x}'_4 = (-1, 1, -1)^\top$$

设初始权重向量 $\mathbf{w}_0 = (0, 0, 0)^\top$ ，学习率 $\rho = 1$ 。请用感知器固定增量法，按 $\mathbf{x}'_1 \rightarrow \mathbf{x}'_2 \rightarrow \mathbf{x}'_3 \rightarrow \mathbf{x}'_4$ 的顺序循环检查，逐步迭代求解权重向量 $\mathbf{w}^*$ ，使得对所有样本均满足 $\mathbf{w}^{*\top} \mathbf{x}'_i > 0$ 。



5.5 感知器

■ 例题求解

下一轮，继续依次重复检查每个样本，直至对所有样本均满足

$$\mathbf{w}_t^T \mathbf{x}'_i > 0$$

第1轮

步骤1: 检查 $\mathbf{x}'_1 = (1, 1, 1)^T$

$$\mathbf{w}_0^T \mathbf{x}'_1 = (0, 0, 0)(1, 1, 1)^T = 0 \times 1 + 0 \times 1 + 0 \times 1 = 0 \leq 0 \quad (\text{错分, 更新})$$

$$\mathbf{w}_1 = \mathbf{w}_0 + \rho \mathbf{x}'_1 = (0, 0, 0)^T + 1 \times (1, 1, 1)^T = (1, 1, 1)^T$$

步骤2: 检查 $\mathbf{x}'_2 = (1, 2, 0)^T$

$$\mathbf{w}_1^T \mathbf{x}'_2 = (1, 1, 1)(1, 2, 0)^T = 1 \times 1 + 1 \times 2 + 1 \times 0 = 3 > 0 \quad (\text{正确, 不更新})$$

步骤3: 检查 $\mathbf{x}'_3 = (-1, 0, -2)^T$

$$\mathbf{w}_1^T \mathbf{x}'_3 = (1, 1, 1)(-1, 0, -2)^T = 1 \times (-1) + 1 \times 0 + 1 \times (-2) = -3 \leq 0 \quad (\text{错分, 更新})$$

$$\mathbf{w}_2 = \mathbf{w}_1 + \rho \mathbf{x}'_3 = (1, 1, 1)^T + 1 \times (-1, 0, -2)^T = (0, 1, -1)^T$$

步骤4: 检查 $\mathbf{x}'_4 = (-1, 1, -1)^T$

$$\mathbf{w}_2^T \mathbf{x}'_4 = (0, 1, -1)(-1, 1, -1)^T = 0 \times (-1) + 1 \times 1 + (-1) \times (-1) = 2 > 0 \quad (\text{正确, 不更新})$$

5.6 最小平方误差判别

■ 介绍


- ! 这一小节考虑线性不可分样本集的分类方法
- 在线性不可分的情况下，以下不等式组不能同时满足

$$\mathbf{w}^T \mathbf{x}'_i > 0, i = 1, 2, \dots, N \quad (5-61)$$

■ 动机

- 求解一个解向量 $\mathbf{w}^*$ 使被错分的样本尽可能少，即不满足不等式 5-61 的样本尽可能
- 然而直接求解不等式计算上并不方便，因此引入一系列待定的常数，将不等式组 (5-61) 转成下列方程组：

$$\mathbf{w}^T \mathbf{x}'_i = b_i > 0, i = 1, 2, \dots, N \quad (5-62)$$



5.6 最小平方误差判别


- 将公式 5-62 转成矩阵形式：

$$X' \mathbf{w} = \mathbf{b} \quad (5-63)$$

- 其中, $X' \in \mathbb{R}^{N \times (d+1)}$, $\mathbf{b} \in \mathbb{R}^N$

$$X' = \begin{pmatrix} \mathbf{x}'_1{}^\top \\ \mathbf{x}'_2{}^\top \\ \vdots \\ \mathbf{x}'_N{}^\top \end{pmatrix} = \begin{pmatrix} x'_{1,0} & x'_{1,1} & \cdots & x'_{1,d} \\ x'_{2,0} & x'_{2,1} & \cdots & x'_{2,d} \\ \vdots & \vdots & \ddots & \vdots \\ x'_{N,0} & x'_{N,1} & \cdots & x'_{N,d} \end{pmatrix}$$

$$\mathbf{b} = (b_1, b_2, \cdots, b_N)^\top \in \mathbb{R}^N, \quad b_i > 0$$



5.6 最小平方误差判别

- 利用章节 5.2 线性回归 介绍的方法进行求解

- 定义最小平方误差：

$$\min_{\mathbf{w}} E = \frac{1}{N} \|X'\mathbf{w} - \mathbf{b}\|^2 = \frac{1}{N} (X'\mathbf{w} - \mathbf{b})^\top (X'\mathbf{w} - \mathbf{b}) \quad (5-6)$$


- 对权重向量 $\mathbf{w}$ 求导：

$$\frac{\partial E(\mathbf{w})}{\partial \mathbf{w}} = \frac{1}{N} [2X'^\top X'\mathbf{w} - 2X'^\top \mathbf{b}] = \frac{2}{N} X'^\top (X'\mathbf{w} - \mathbf{b}) \quad (5-7)$$

- 令导数值为零，求出最优权重向量 $\mathbf{w}^*$ ：

$$\mathbf{w}^* = (X'^\top X')^{-1} X'^\top \mathbf{b} \quad (5-9)$$

⚠ 同样可以利用梯度下降法迭代求解，详见教材 公式 5-70



5.6 最小平方误差判别

■ 常数 b_i 的选择


- 如果同一类样本的 b_i 选择为相同的值，则最小平方误差判别方法的解等价于 Fisher 线性判别的解
- 将样本和权重向量均还原成增广以前的形式，则最优权重向量 $\mathbf{w}^*$:

$$\mathbf{w}^* \propto \mathbf{S}_W^{-1}(\mathbf{m}_1 - \mathbf{m}_2) \quad (5-72)$$

- 进一步地，若第一类样本对应的 b_i 都等于 $\frac{N}{N_1}$ ，第二类样本对应的 b_i 都等于 $\frac{N}{N_2}$ 时，阈值 w_0^* 等于：

$$w_0^* = -\mathbf{m}^T \mathbf{w}^* \quad (5-73)$$

- 其中， N_1 和 N_2 分别是第一类和第二类的样本数， N 是样本总数， $\mathbf{m}$ 是全部样本的均值，即 $\mathbf{m} = \frac{1}{N}(N_1 \mathbf{m}_1 + N_2 \mathbf{m}_2)$



5.4

例题

已知两类样本， ω_1 类3个， ω_2 类2个，样本维度为2：

样本	类别	$x_{i,1}$	$x_{i,2}$
$\mathbf{x}_1$	ω_1	0	2
$\mathbf{x}_2$	ω_1	2	1
$\mathbf{x}_3$	ω_1	1	0
$\mathbf{x}_4$	ω_2	2	2
$\mathbf{x}_5$	ω_2	2	3

将每个样本构造规范化增广向量 $\mathbf{x}'_i = y_i(1, x_{i,1}, x_{i,2})^\top$ ，其中 ω_1 类 $y_i = 1$ ， ω_2 类 $y_i = -1$ 。
 设 ω_1 类 $b_i = \frac{N}{N_1}$ ， ω_2 类 $b_i = \frac{N}{N_2}$ 。已知：

$$(X'^\top X')^{-1} = \begin{pmatrix} \frac{9}{8} & -\frac{3}{8} & -\frac{1}{4} \\ -\frac{3}{8} & \frac{13}{40} & -\frac{1}{20} \\ -\frac{1}{4} & -\frac{1}{20} & \frac{1}{5} \end{pmatrix}$$

试：

1. 写出规范化增广样本矩阵 X' (5×3) 及目标向量 $\mathbf{b}$
2. 计算 $X'^\top X'$ 与 $X'^\top \mathbf{b}$
3. 求最优增广权向量 $\mathbf{w}^* = (w_0^*, w_1^*, w_2^*)^\top$
4. 写出判别函数 $g(\mathbf{x})$ 及决策规则，并对 $\mathbf{x} = (1, 1)^\top$ 和 $\mathbf{x} = (3, 3)^\top$ 进行分类
5. 验证： $\mathbf{w}^*$ 的方向部分与 $S_W^{-1}(\mathbf{m}_1 - \mathbf{m}_2)$ 成正比，且 $w_0^* = -\mathbf{m}^\top \mathbf{w}^*$ （其中 $\mathbf{w}^*$ 取方向部分， $\mathbf{m} = \frac{1}{N}(N_1 \mathbf{m}_1 + N_2 \mathbf{m}_2)$ ）

5.6 最小平方误差判别

■ 解答

第1题

$N = 5$, $N_1 = 3$, $N_2 = 2$, 故 ω_1 类 $b_i = \frac{5}{3}$, ω_2 类 $b_i = \frac{5}{2}$ 。

$$X' = \begin{pmatrix} 1 & 0 & 2 \\ 1 & 2 & 1 \\ 1 & 1 & 0 \\ -1 & -2 & -2 \\ -1 & -2 & -3 \end{pmatrix}, \quad \mathbf{b} = \left(\frac{5}{3}, \frac{5}{3}, \frac{5}{3}, \frac{5}{2}, \frac{5}{2} \right)^T$$

第2题

$$X'^T X' = \begin{pmatrix} 5 & 7 & 8 \\ 7 & 13 & 12 \\ 8 & 12 & 18 \end{pmatrix}$$

$$X'^T \mathbf{b} = \begin{pmatrix} 0 \\ -5 \\ -\frac{15}{2} \end{pmatrix}$$

5.6 最小平方误差判别

■ 解答

第3题

$$\mathbf{w}^* = (X'^\top X')^{-1} X'^\top \mathbf{b} = \begin{pmatrix} \frac{9}{8} & -\frac{3}{8} & -\frac{1}{4} \\ -\frac{3}{8} & \frac{13}{40} & -\frac{1}{20} \\ -\frac{1}{4} & -\frac{1}{20} & \frac{1}{5} \end{pmatrix} \begin{pmatrix} 0 \\ -5 \\ -\frac{15}{2} \end{pmatrix} = \begin{pmatrix} \frac{15}{4} \\ -\frac{5}{4} \\ -\frac{5}{4} \end{pmatrix}$$

第4题

$$g(\mathbf{x}) = \frac{15}{4} - \frac{5}{4}x_1 - \frac{5}{4}x_2$$

决策规则: $g(\mathbf{x}) > 0 \Rightarrow \omega_1$, $g(\mathbf{x}) \leq 0 \Rightarrow \omega_2$ 。

$$g(1, 1) = \frac{15}{4} - \frac{5}{4} - \frac{5}{4} = \frac{5}{4} > 0 \Rightarrow \omega_1$$

$$g(3, 3) = \frac{15}{4} - \frac{15}{4} - \frac{15}{4} = -\frac{15}{4} < 0 \Rightarrow \omega_2$$

5.6 最小平方误差判别

■ 解答 第5题

两类均值: $\mathbf{m}_1 = (1, 1)^\top$, $\mathbf{m}_2 = (2, \frac{5}{2})^\top$, 全局均值 $\mathbf{m} = \frac{1}{5}(3\mathbf{m}_1 + 2\mathbf{m}_2) = (\frac{7}{5}, \frac{8}{5})^\top$ 。

类内散布矩阵:

$$S_W = \sum_{i:\omega_1} (\mathbf{x}_i - \mathbf{m}_1)(\mathbf{x}_i - \mathbf{m}_1)^\top + \sum_{i:\omega_2} (\mathbf{x}_i - \mathbf{m}_2)(\mathbf{x}_i - \mathbf{m}_2)^\top = \begin{pmatrix} 2 & -1 \\ -1 & \frac{5}{2} \end{pmatrix}$$

$$S_W^{-1} = \begin{pmatrix} \frac{5}{8} & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{2} \end{pmatrix}$$

$$S_W^{-1}(\mathbf{m}_1 - \mathbf{m}_2) = \begin{pmatrix} \frac{5}{8} & \frac{1}{4} \\ \frac{1}{4} & \frac{1}{2} \end{pmatrix} \begin{pmatrix} -1 \\ -\frac{3}{2} \end{pmatrix} = \begin{pmatrix} -1 \\ -1 \end{pmatrix}$$


$\mathbf{w}^*$ 的方向部分为 $(-\frac{5}{4}, -\frac{5}{4})^\top = \frac{5}{4} \cdot (-1, -1)^\top$, 与 $S_W^{-1}(\mathbf{m}_1 - \mathbf{m}_2)$ 成正比。✓


$$w_0^* = -\mathbf{m}^\top \mathbf{w}^* = -\begin{pmatrix} \frac{7}{5} & \frac{8}{5} \end{pmatrix} \begin{pmatrix} -\frac{5}{4} & -\frac{5}{4} \end{pmatrix}^\top = -\left(-\frac{7}{4} - 2\right) = \frac{15}{4} \quad \checkmark$$

! 要将样本和权重向量均还原成增广以前的形式

5.8 最优分类超平面与线性支持向量机

- 一个样本集线性可分，则存在无数多个解向量，那么，哪一个解更好？





5.8.1 最优分类超平面

- 问题定义

- 给定训练样本集 $(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N), x_i \in \mathbb{R}^d, y_i \in \{+1, -1\}$
- 由于样本集线性可分，则存在决策超平面 $g(x) = \mathbf{w} \cdot \mathbf{x} + b = 0$ 能够将所有 N 个样本都没有错误地分开
 - $\mathbf{w} \in \mathbb{R}^d$
 - $\mathbf{w} \cdot \mathbf{x}$ 表示向量 $\mathbf{w}$ 与 $\mathbf{x}$ 的内积，即 $\mathbf{w}^T \mathbf{x}$
 -  为了与其它支持向量机的文献一致，将偏置项写作 b 而非 w_0

5.8.1 最优分类超平面


■ 问题定义

■ 最优超平面

- 能够将训练样本没有错误地分开
- 两类训练样本中离超平面最近的样本与超平面之间的距离是最大的

■ 分类间隔

- 两类样本中离分类面最近的样本到分类面的距离




回顾 5.3 线性判别函数的基本概念

■ 二分类决策面

- 将特征空间任意点 x 分解为两个部分：

$$x = x_p + r \frac{w}{\|w\|} \quad (5-14)$$

- x_p 是 x 在决策面上的垂直投影点（即从 x 向 H 做垂线，垂足就是 x_p ）
- $\frac{w}{\|w\|}$ 是法向量 w 方向上的单位向量
- r 是 x 到决策面的有符号距离



回顾 5.3 线性判别函数的基本概念

■ 二分类决策面


- 将公式 5-14 代入决策面函数 $g(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + w_0$:


$$\begin{aligned} g(\mathbf{x}) &= \mathbf{w}^\top \mathbf{x} + w_0 \\ &= \mathbf{w}^\top \left(\mathbf{x}_p + r \frac{\mathbf{w}}{\|\mathbf{w}\|} \right) + w_0 \\ &= \underbrace{\left(\mathbf{w}^\top \mathbf{x}_p + w_0 \right)}_{=0} + r \frac{\boxed{\mathbf{w}^\top \mathbf{w}}}{\|\mathbf{w}\|} \text{ 等于 } \|\mathbf{w}\|^2 \\ &= r \|\mathbf{w}\| \end{aligned}$$

- 公式意义：任意点 $\mathbf{x}$ 到决策面的距离 r 与 $g(\mathbf{x})$ 值成正比。即 $g(\mathbf{x})$ 值不仅能说明分类结果（根据正负号），还能反映样本点 $\mathbf{x}$ 距离决策边界的远近（根据绝对值大小）

5.8.1 最优分类超平面

- 样本点 x 到分类超平面的距离是： $\frac{|g(x)|}{\|w\|}$
 - $\|\cdot\|$ 表示计算向量模长， $\|w\| = (w^T w)^{1/2}$
 - **!** 分子取了绝对值，与 r 表示的有符号距离不同





5.8.1 最优分类超平面

- 样本集线性可分使得对所有样本均满足：

$$\begin{cases} (\mathbf{w} \cdot \mathbf{x}_i) + b > 0, & y_i = +1 \\ (\mathbf{w} \cdot \mathbf{x}_i) + b < 0, & y_i = -1 \end{cases} \quad (5-92)$$

- 将 $\mathbf{w}$, $\mathbf{b}$ 同时乘以任意正常数 α 依然满足公式 5-92:

$$\begin{cases} \alpha((\mathbf{w} \cdot \mathbf{x}_i) + b) > 0, & y_i = +1 \\ \alpha((\mathbf{w} \cdot \mathbf{x}_i) + b) < 0, & y_i = -1 \end{cases}$$

- **公式含义**：满足公式 5-92 严格不等式的解有**无穷多**组——它们只是彼此的尺度缩放

5.8.1 最优分类超平面

- 如何固定 $\mathbf{w}$ 和 b 的尺度?

- 让离分类超平面最近的样本 x 恰好满足: $|g(x)| = 1$
- 由此, 将 公式 5-92 的条件变为:

$$\begin{cases} (\mathbf{w} \cdot \mathbf{x}_i) + b \geq 1, & y_i = +1 \\ (\mathbf{w} \cdot \mathbf{x}_i) + b \leq -1, & y_i = -1 \end{cases} \quad (5-93)$$

- 即要求第一类样本中 $g(x)$ 最小等于 1
- 第二类样本中 $g(x)$ 最大等于 -1
- 合并成一个统一的形式:

$$y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] \geq 1, \quad i = 1, 2, \dots, N \quad (5-94)$$

5.8.1 最优分类超平面

- 关于公式 5-93 的另一种解释
 - 回顾余量的概念
 - 如果一个解向量靠近解区的边缘，虽然所有样本都能满足 $\mathbf{w}^* \mathbf{T} \mathbf{x}'_i > 0$ ，但对于某些样本，该值可能刚刚大于 0
 - 考虑到噪声、数值计算误差等因素，需要将解区向中间缩小，不取靠近边缘的解
 - 引入 余量 $b > 0$:

$$\mathbf{w}^* \mathbf{T} \mathbf{x}'_i > b, i = 1, 2, \dots, N \quad (5-55)$$

- 常数“1”就是这个余量，减少误分类


$$\begin{cases} (\mathbf{w} \cdot \mathbf{x}_i) + b \geq 1, & y_i = +1 \\ (\mathbf{w} \cdot \mathbf{x}_i) + b \leq -1, & y_i = -1 \end{cases} \quad (5-93)$$


5.8.1 最优分类超平面

■ 几何意义

- $g(x) = 1$ 和 $g(x) = -1$ 是过两类中各自离分类面最近的样本且与分类面平行的两个边界超平面
- 由于样本点 x 到分类超平面的距离是： $\frac{|g(x)|}{\|w\|}$
- 因此两类分类间隔为：

$$M = \frac{2}{\|w\|}$$





5.8.1 最优分类超平面


- 最优超平面求解

- 根据两类分类间隔 $M = \frac{2}{\|w\|}$
 - 最大化 M 等价于最小化分母 $\|w\|$
 - 最小化分母 $\|w\|$ 等价于最小化 $\|w\|^2$
 - 最小化 $\|w\|^2$ 等价于最小化 $\frac{1}{2} \|w\|^2$
- 求解最优超平面的问题等价于：

$$\min_{w,b} \quad \frac{1}{2} \|\mathbf{w}\|^2$$

$$\text{s. t.} \quad y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1 \geq 0, \quad i = 1, 2, \dots, N$$

公式 5-94，让 N 个样本都可以被超平面没有错误地分开



5.8.1 最优分类超平面


- 最优超平面求解

- 求解最优超平面的问题等价于：

$$\min_{\mathbf{w}, b} \quad \frac{1}{2} \|\mathbf{w}\|^2$$

$$\text{s. t.} \quad y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1 \geq 0, \quad i = 1, 2, \dots, N$$

- 在不等式约束下的优化问题，可以通过拉格朗日法求解



5.8.1 最优分类超平面

- 经典拉格朗日乘子法

- 核心思想

- 将有约束优化问题转化为无约束优化问题求解
 - 原始有约束问题的一般形式为：

$$\min f(x) \quad \text{s.t.} \quad g(x) = 0$$

- 构造拉格朗日函数：约束条件是等式！

$$L(x, \lambda) = f(x) + \lambda \cdot g(x)$$

5.8.1 最优分类超平面

- KKT 条件下的广义拉格朗日函数
 - KKT全称是 Karush–Kuhn–Tucker 条件
 - 核心思想
 - 将含不等式约束的优化问题转化为无约束优化问题求解
 - 原始有约束问题的一般形式为：
$$\min f(\mathbf{x}) \quad \text{s.t.} \quad g_i(\mathbf{x}) \geq 0, \quad i = 1, \dots, m$$
 - 构建广义拉格朗日函数：

$$L(\mathbf{x}, \boldsymbol{\alpha}) = f(\mathbf{x}) - \sum_{i=1}^m \alpha_i g_i(\mathbf{x}), \quad \boxed{\alpha_i} \geq 0$$

拉格朗日算子

5.8.1 最优分类超平面


- KKT 条件下的广义拉格朗日函数

- 核心思想

- 转化为鞍点问题 (极小极大问题):

$$\min_x \max_{\alpha \geq 0} L(x, \alpha)$$

运算顺序: 从内往外, 先对
内层求 L 对于 α 的最大值
(固定 x), 再对外层的 x 取
最小



5.8.1 最优分类超平面

- KKT 条件下的广义拉格朗日函数
 - KKT 条件（最优解的必要条件）
 - $\mathbf{x}^*$ 为最优解， α^* 为最优拉格朗日乘子
 - **稳定性条件**：目标函数与约束的梯度在最优点平衡


$$\nabla_{\mathbf{x}} L = \nabla f(\mathbf{x}^*) - \sum_{i=1}^m \alpha_i^* \nabla g_i(\mathbf{x}^*) = 0$$

梯度 = 全部偏
导数组成的向量



$$\boxed{\nabla f(\mathbf{x}^*)} = \sum_{i=1}^m \alpha_i^* \nabla g_i(\mathbf{x}^*)$$

- **公式含义**：在最优点 $\mathbf{x}^*$ 处，目标函数的梯度等于各个起作用约束 ($\alpha_i^* > 0$) 梯度的线性组合



5.8.1 最优分类超平面

- KKT 条件下的广义拉格朗日函数

- KKT 条件（最优解的必要条件）

- $\mathbf{x}^*$ 为最优解， α^* 为最优拉格朗日乘子

- **原始可行性**：最优解必须满足原始约束


$$g_i(\mathbf{x}^*) \geq 0, \quad i = 1, \dots, m$$

- **对偶可行性**：每个拉格朗日乘子必须非负

$$\alpha_i^* \geq 0, \quad i = 1, \dots, m$$

- **互补松弛条件**：对每个约束，乘子与约束函数值至少有一个为零

$$\alpha_i^* g_i(\mathbf{x}^*) = 0, \quad i = 1, \dots, m$$



5.8.1 最优分类超平面

- 最优超平面求解


- 求解最优超平面的问题等价于：

$$\min_{\mathbf{w}, b} \quad \frac{1}{2} \|\mathbf{w}\|^2$$

$$\text{s. t.} \quad y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1 \geq 0, \quad i = 1, 2, \dots, N$$

- 在不等式约束下的优化问题，可以通过 KKT 条件下的广义拉格朗日方法求解
- 转化为鞍点问题：

$$\min_{\mathbf{w}, b} \max_{\alpha} L(\mathbf{w}, b, \alpha) = \frac{1}{2} (\mathbf{w} \cdot \mathbf{w}) - \sum_{i=1}^N \alpha_i \{y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\} \quad (5-98)$$



5.8.1 最优分类超平面

■ 鞍点问题例题

$$\min_{\mathbf{w}, b} \max_{\alpha} L(\mathbf{w}, b, \alpha) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) - \sum_{i=1}^N \alpha_i \{y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\} \quad (5-98)$$

- 【题目】若某个 $\mathbf{w}, b$ 使得存在一个样本违反约束（即 $y_i(\mathbf{w} \cdot \mathbf{x}_i + b) < 1$ ），则内层 $\max_{\alpha \geq 0} L$ 的值为 _____。
- 【解析】若第 i 个样本违反约束（分类错误），拉格朗日函数 L 的第二项 $-\alpha_i \{y_i(\mathbf{w} \cdot \mathbf{x}_i + b) - 1\}$ 随 $\alpha_i \rightarrow +\infty$ 而趋向 $+\infty$ 。因此内层最大值为 $+\infty$

5.8.1 最优分类超平面

- 根据公式 5-98 说明互补松弛条件

$$\min_{\mathbf{w}, b} \max_{\alpha} L(\mathbf{w}, b, \alpha) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) - \sum_{i=1}^N \alpha_i \{y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\} \quad (5-98)$$

- 第 i 个约束条件是：

$$y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1 \geq 0$$

- 互补松弛条件为：

- 对每个约束，乘子与约束函数值至少有一个为零

$$\alpha_i^* \{y_i[(\mathbf{w}^* \cdot \mathbf{x}_i) + b^*] - 1\} = 0, \quad i = 1, \dots, N$$

5.8.1 最优分类超平面

- 根据公式 5-98 说明互补松弛条件

- 互补松弛条件为：

- 对每个约束，乘子与约束函数值至少有一个为零

$$\alpha_i^* \{y_i[(\mathbf{w}^* \cdot \mathbf{x}_i) + b^*] - 1\} = 0, \quad i = 1, \dots, N$$

- 对每个样本 x_i 分为两种情况：

- 情况1: $y_i[(\mathbf{w}^* \cdot \mathbf{x}_i) + b^*] - 1 > 0$

- 样本远离边界超平面， $\alpha_i^* = 0$ ，此时约束不起作用

- 情况2: $y_i[(\mathbf{w}^* \cdot \mathbf{x}_i) + b^*] - 1 = 0$

- 样本恰好落在边界超平面上， $\alpha_i^* \geq 0$

5.8.1 最优分类超平面


■ 互补松弛条件例题

■ 互补松弛条件为：

- 对每个约束，乘子与约束函数值至少有一个为零

$$\alpha_i^* \{y_i[(\mathbf{w}^* \cdot \mathbf{x}_i) + b^*] - 1\} = 0, \quad i = 1, \dots, N$$

- 【题目】训练好一个线性支持向量机后，某样本 $\mathbf{x}_k$ 满足 $y_k(\mathbf{w}^* \cdot \mathbf{x}_k + b^*) = 3$ ，则该样本对应的拉格朗日乘子 α_k^* 为 _____。
- 【解析】已知 $y_k(\mathbf{w}^* \cdot \mathbf{x}_k + b^*) = 3$ ，则约束函数值为 $3 - 1 = 2 > 0$ ，由于乘子与约束函数值至少有一个为零，所以 $\alpha_k^* = 0$



5.8.1 最优分类超平面

- 根据公式 5-98 对 $\mathbf{w}$ 和 b 求偏导

$$\min_{\mathbf{w}, b} \max_{\alpha} L(\mathbf{w}, b, \alpha) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) - \sum_{i=1}^N \alpha_i \{y_i [(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\} \quad (5-98)$$

- 令偏导为零，得到：

$$\mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \qquad \sum_{i=1}^N y_i \alpha_i = 0$$

- 根据 KKT 稳定性条件，最优解处必须满足的条件为：

$$\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i \quad (5-99)$$

$$\sum_{i=1}^N y_i \alpha_i^* = 0 \quad (5-100)$$

5.8.1 最优分类超平面

- 公式 5-99 推导


$$\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i \quad (5-99)$$

- 根据 KKT 稳定性条件：

$$\nabla f(\mathbf{x}^*) = \sum_{i=1}^m \alpha_i^* \nabla g_i(\mathbf{x}^*)$$

- 在支持向量机中的对应关系：

$$\min_{\mathbf{w}, b} \max_{\alpha} L(\mathbf{w}, b, \alpha) = \underbrace{\frac{1}{2}(\mathbf{w} \cdot \mathbf{w})}_{\text{目标函数 } f(\mathbf{w}, b)} - \sum_{i=1}^N \alpha_i \underbrace{\{y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\}}_{\text{约束函数 } g_i(\mathbf{w}, b)} \quad (5-98)$$



5.8.1 最优分类超平面

- 公式 5-99 推导

- 目标函数 $f(\mathbf{w}, b)$ 对 $\mathbf{w}$ 求偏导：

$$\nabla_{\mathbf{w}} f(\mathbf{w}, b) = \nabla_{\mathbf{w}} \frac{1}{2} (\mathbf{w} \cdot \mathbf{w}) = \mathbf{w}$$

- KKT 稳定性条件在最优点满足，因此将 $\mathbf{w}$ 改写为 $\mathbf{w}^*$ ，由此得到 公式 5-99 等号左侧

$$\boxed{\mathbf{w}^*} = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i \quad (5-99)$$

5.8.1 最优分类超平面

- 公式 5-99 推导

- 约束函数 $g_i(\mathbf{w}, b)$ 对 $\mathbf{w}$ 求偏导：


$$\nabla_{\mathbf{w}} g_i(\mathbf{w}, b) = \nabla_{\mathbf{w}} \{y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\} = y_i \mathbf{x}_i$$

- 根据 KKT 稳定性条件 $\nabla f(\mathbf{x}^*) = \sum_{i=1}^m \alpha_i^* \nabla g_i(\mathbf{x}^*)$ ，对约束函数偏导进行线性组合得到：

$$\sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i$$

- 由此得到 公式 5-99 等号右侧

$$\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i \quad (5-99)$$



5.8.1 最优分类超平面

- 公式 5-100 推导

- 目标函数 $f(\mathbf{w}, b)$ 对 b 求偏导：

$$\nabla_b f(\mathbf{w}, b) = \nabla_b \frac{1}{2} (\mathbf{w} \cdot \mathbf{w}) = 0$$

- 由此可得公式 5-100 等号右侧

$$\sum_{i=1}^N y_i \alpha_i^* = 0 \quad (5-100)$$

5.8.1 最优分类超平面

- 公式 5-100 推导

- 约束函数 $g_i(\mathbf{w}, b)$ 对 b 求偏导：

$$\nabla_b g_i(\mathbf{w}, b) = \nabla_b \{y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\} = y_i$$


- 根据 KKT 稳定性条件 $\nabla f(\mathbf{x}^*) = \sum_{i=1}^m \alpha_i^* \nabla g_i(\mathbf{x}^*)$ ，对约束函数偏导进行线性组合得到：

$$\sum_{i=1}^N \alpha_i^* y_i$$

- 由此可得公式 5-100 等号左侧

$$\sum_{i=1}^N y_i \alpha_i^* = 0$$

(5-100)




5.8.1 最优分类超平面

- 公式 5-100 的含义

$$\sum_{i=1}^N y_i \alpha_i^* = 0 \quad (5-100)$$

- 由于 y_i 只能取 +1 或 -1，因此要求正类样本的拉格朗日算子 α_i^* 之和必须等于负类样本的 α_i^* 之和



5.8.1 最优分类超平面

- 对偶问题

- 原问题

$$\min_{\mathbf{w}, b} \max_{\boldsymbol{\alpha}} L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) - \sum_{i=1}^N \alpha_i \{y_i [(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\} \quad (5-98)$$

- 交换 min 和 max 的顺序，得到对偶问题：

$$\max_{\boldsymbol{\alpha} \geq 0} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha})$$

- 目的：先对内层求 L 对于 $\mathbf{w}, b$ 的最小值，然后将这两个变量消掉，只剩关于 $\boldsymbol{\alpha}$ 的函数

5.8.1 最优分类超平面

■ 对偶问题

- 将拉格朗日函数 L 展开：

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) - \sum_{i=1}^N \alpha_i \{y_i[(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\}$$



$$L = \frac{1}{2} \mathbf{w} \cdot \mathbf{w} - \sum_{i=1}^N \alpha_i y_i (\mathbf{w} \cdot \mathbf{x}_i) - b \sum_{i=1}^N \alpha_i y_i + \sum_{i=1}^N \alpha_i$$

- 对 $\mathbf{w}$ 和 b 求偏导，令偏导为 0：

$$\mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \quad \sum_{i=1}^N y_i \alpha_i = 0$$

5.8.1 最优分类超平面

■ 对偶问题

- 将拉格朗日函数 L 整理为：

$$\begin{aligned} L &= \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) - \sum_{i,j} \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) + \sum_{i=1}^N \alpha_i \\ &= \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) \end{aligned}$$

- 最优超平面问题的解等价于下面的优化问题的解：

$$\max_{\alpha} Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) \quad (5-101)$$

$$\text{s.t. } \sum_{i=1}^N y_i \alpha_i = 0, \quad \alpha_i \geq 0$$

对 b 求偏导

5.8.1 最优分类超平面

■ 对偶问题求解

$$\max_{\alpha} \quad Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) \quad (5-101)$$

$$\text{s.t.} \quad \sum_{i=1}^N y_i \alpha_i = 0, \quad \alpha_i \geq 0$$

- 是关于 α 的 凸二次规划问题，目标函数是二次的，约束是线性的
- 小规模问题可以直接用 KKT 条件手动求解
- 大规模实际问题用的是 SMO (Sequential Minimal Optimization) 算法

5.8.1 最优分类超平面

■ 原问题求解

- 通过对上述对偶问题求解，得到 $\alpha_i^*, i = 1, \dots, N$ ，可以原问题的解

- 根据公式 5-99 求出 w^*

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

! 没必要计算全部 N 个样本的加权求和，仅关注支持向量即可
(5-99)

- 无法根据公式 5-100 求出 b^*

$$\sum_{i=1}^N y_i \alpha_i^* = 0 \quad (5-100)$$

- 要考虑处于边界超平面 ($g(x) = 1$ 和 $g(x) = -1$) 上的样本，这些样本称作支持向量

5.8.1 最优分类超平面

- b^* 求解

- 根据情况2，对于支持向量满足：

$$y_i[(\mathbf{w}^* \cdot \mathbf{x}_i) + b^*] - 1 = 0 \quad (5-107)$$

- 互补松弛条件为：

- 对每个约束，乘子与约束函数值至少有一个为零

$$\alpha_i^* \{y_i[(\mathbf{w}^* \cdot \mathbf{x}_i) + b^*] - 1\} = 0, \quad i = 1, \dots, N$$


- 对每个样本 x_i 分为两种情况：

- 情况1: $y_i[(\mathbf{w}^* \cdot \mathbf{x}_i) + b^*] - 1 > 0$

- 样本远离边界超平面， $\alpha_i^* = 0$ ，此时约束不起作用

- 情况2: $y_i[(\mathbf{w}^* \cdot \mathbf{x}_i) + b^*] - 1 = 0$

- 样本恰好落在边界超平面上， $\alpha_i^* \geq 0$



5.8.1 最优分类超平面

- b^* 求解

- 根据情况2，对于支持向量满足：


$$y_i[(\mathbf{w}^* \cdot \mathbf{x}_i) + b^*] - 1 = 0 \quad (5-107)$$


- 由于已经计算出 $\mathbf{w}^*$, b^* 可以用任何一个支持向量根据上式求得
- 在实际的数值计算中，通常用所有 α_i^* 非零的样本通过公式 5-107 求解 b^* 后再取平均

5.8.1 最优分类

支持向量机求解流程

- 原问题为最大化分类间隔，约束条件为使两类样本全部正确分类
- 由于原问题含有不等式约束，所以构造 KKT 条件下的广义拉格朗日函数
- 交换 min 和 max 的顺序，得到对偶问题
- 求解出最优参数 w^* , b^* 最终得到决策函数






5.8.1 最优分类超平面

■ 支持向量机例题 1

题目：给定以下四个二维训练样本：

样本	$\boldsymbol{x}_i$	y_i
$\boldsymbol{x}_1$	(1, 1)	+1
$\boldsymbol{x}_2$	(2, 0)	+1
$\boldsymbol{x}_3$	(0, 0)	-1
$\boldsymbol{x}_4$	(-1, 1)	-1

已知 $\boldsymbol{x}_1$ 和 $\boldsymbol{x}_3$ 是支持向量。求最优决策面 $\boldsymbol{w}^* \cdot \boldsymbol{x} + b^* = 0$ 的参数 $\boldsymbol{w}^*$ 和 b^* 。



5.8.1 最优分类超平面

■ 支持向量机例题 1 解答

由于 $\mathbf{x}_1$ 和 $\mathbf{x}_3$ 是支持向量，它们满足 $y_i(\mathbf{w} \cdot \mathbf{x}_i + b) = 1$ 。


设 $\mathbf{w} = (w_1, w_2)$ ，列方程：

对 $\mathbf{x}_1 = (1, 1)$ ， $y_1 = +1$ ：

$$w_1 + w_2 + b = 1 \quad (1)$$

对 $\mathbf{x}_3 = (0, 0)$ ， $y_3 = -1$ ：

$$-(0 + 0 + b) = 1 \implies b = -1 \quad (2)$$



5.8.1 最优分类超平面

■ 支持向量机例题 1 解答

再利用 $\mathbf{w}^* = \sum_i \alpha_i^* y_i \mathbf{x}_i$ ，其中只有支持向量的 $\alpha_i > 0$ ：

$$\mathbf{w}^* = \alpha_1 y_1 \mathbf{x}_1 + \alpha_3 y_3 \mathbf{x}_3 = \alpha_1 (1, 1) + \alpha_3 \cdot (-1) \cdot (0, 0) = \alpha_1 (1, 1)$$

所以 $w_1 = w_2 = \alpha_1$ 。代入式(1)：

$$\alpha_1 + \alpha_1 + (-1) = 1 \implies \alpha_1 = 1$$

因此：

$$\mathbf{w}^* = (1, 1), \quad b^* = -1$$

5.8.1 最优分类超平面


■ 支持向量机例题 2

题目（修订版）：已知线性SVM决策面为 $g(\mathbf{x}) = x_1 - 2x_2 + 1 = 0$ ，以下四个训练样本中，哪些是支持向量？

样本	$\mathbf{x}_i$	y_i
①	(0, 0)	+1
②	(3, 1)	+1
③	(2, 2)	-1
④	(1, 2)	-1

(A) ①③ (B) ②④ (C) ①④ (D) ②③

支持向量处于边界超平面上，满足 $y_i \cdot g(\mathbf{x}_i) = 1$



5.8.1 最优分类超平面

■ 支持向量机例题 2

验证：支持向量满足 $y_i \cdot g(\mathbf{x}_i) = 1$ 。

- ①: $g = 1$, $y_i \cdot g = (+1)(1) = 1 \checkmark$
- ②: $g = 2$, $y_i \cdot g = (+1)(2) = 2$, 非支持向量
- ③: $g = -1$, $y_i \cdot g = (-1)(-1) = 1 \checkmark$
- ④: $g = -2$, $y_i \cdot g = (-1)(-2) = 2$, 非支持向量