


5.7 罗杰斯特回归


- 罗杰斯特 (Logistic) 函数 (Sigmoid 函数)

$$\theta(s) = \frac{e^s}{1 + e^s} = \frac{1}{1 + e^{-s}} \quad (5-77)$$

- 性质

- $\theta(s)$ 取值介于 0-1 之间
- $\theta(-s) = 1 - \theta(s)$





5.7 罗杰斯特回归


- 一元 logit 函数

- 给定一维样本特征 x ，考查该样本是否属于所关心的类别中（例如患有某种疾病），样本与类别的关系符合罗杰斯特函数：

$$P(y = 1 \mid x) = \frac{e^{w_0 + w_1 x}}{1 + e^{w_0 + w_1 x}} \quad (5-76)$$

- 样本 x 不属于正类的概率：

$$P(y = -1 \mid x) = 1 - P(y = 1 \mid x) = 1 - \frac{1}{1 + e^{-(w_0 + w_1 x)}} = \frac{e^{-(w_0 + w_1 x)}}{1 + e^{-(w_0 + w_1 x)}}$$



5.7 罗杰斯特回归


- 一元 logit 函数

- 两类比例:

$$\begin{aligned}\frac{P(y = 1 \mid x)}{P(y = -1 \mid x)} &= \frac{P(y = 1 \mid x)}{1 - P(y = 1 \mid x)} \\ &= \frac{1}{1 + e^{-(w_0 + w_1 x)}} \\ &= \frac{e^{-(w_0 + w_1 x)}}{1 + e^{-(w_0 + w_1 x)}} \\ &= \frac{1}{e^{-(w_0 + w_1 x)}} = e^{w_0 + w_1 x}\end{aligned}\tag{5-79}$$

- 取自然对数，称作 **logit 函数**:

$$\text{logit}(x) = \ln\left(\frac{P(y = 1 \mid x)}{1 - P(y = 1 \mid x)}\right) = w_0 + w_1 x\tag{5-80}$$



5.7 罗杰斯特回归

- 多元 logit 函数

- 函数定义:


$$\text{logit}(\mathbf{x}) = \ln \left(\frac{P(y = 1 \mid \mathbf{x})}{1 - P(y = 1 \mid \mathbf{x})} \right) = w_0 + w_1 x_1 + \cdots + w_m x_m \quad (5-81)$$

- 样本 $\mathbf{x}$ 属于 $y = 1$ 类的概率:

$$P(y = 1 \mid \mathbf{x}) = \frac{e^{w_0 + w_1 x_1 + \cdots + w_m x_m}}{1 + e^{w_0 + w_1 x_1 + \cdots + w_m x_m}} \quad (5-82)$$

- 罗杰斯特回归的决策函数:

$$\text{若 } \text{logit}(\mathbf{x}) \geq 0, \text{ 则 } \begin{cases} \mathbf{x} \in \omega_1 \\ \mathbf{x} \in \omega_2 \end{cases} \quad (5-83)$$




5.7 罗杰斯特回归

- 计算未知参数向量 $\mathbf{w}$
 - 采用最大似然估计
 - 共 N 个训练样本 $\{(x_1, y_1), \dots, (x_N, y_N)\}$, $x_j \in \mathbb{R}^{d+1}$, $y_j \in \{-1, 1\}$
 - 同时考虑两类样本，似然函数为：

$$L(\mathbf{w}) = \prod_{j=1}^N P(y_j | x_j) = \prod_{j=1}^N \theta(y_j \mathbf{w}^T \mathbf{x}_j) \quad (5-87)$$


对于负样本，利用性质 $\theta(-s) = 1 - \theta(s)$



5.7 罗杰斯特回归

- 计算未知参数向量 w
 - 采用最大似然估计
 - 目标函数为最小化负对数似然函数：

$$\begin{aligned}\min E(w) &= -\frac{1}{N} \ln(L(w)) = -\frac{1}{N} \ln \left(\prod_{j=1}^N \theta(y_j w^T x_j) \right) \\ &= \frac{1}{N} \sum_{j=1}^N \ln \left(\frac{1}{\theta(y_j w^T x_j)} \right) \\ &= \frac{1}{N} \sum_{j=1}^N \ln \left(1 + e^{-y_j w^T x_j} \right)\end{aligned}$$



5.7 罗杰斯特回归


- 计算未知参数向量 $\mathbf{w}$
 - 用梯度下降法求解：
 - 1. $t = 0$, 任意选择初始的权重向量 $\mathbf{w}_0$
 - 2. 计算目标函数的梯度:

$$\nabla E = -\frac{1}{N} \sum_{j=1}^N \frac{y_j \mathbf{x}_j}{1 + e^{y_j \mathbf{w}_t^T \mathbf{x}_j}}$$

- 3. 根据学习率 ρ_t , 更新下一时刻参数:

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \rho_t \nabla E$$

- 4. 检查是否达到终止条件 (梯度已经小于某个预设值或迭代次数达到上限等), 如未达到, 重复进行步骤2
- 5. 算法停止, 输出得到的参数 $\mathbf{w}$



5.7 罗杰斯特回归


■ 例题

****题目： **** 已知逻辑回归模型的增广权向量为 $\mathbf{w} = (1, 2, -1)^T$ ，增广样本 $\mathbf{x}_j = (1, x_{j1}, x_{j2})^T$ 。现有 3 个待分类样本：

样本	x_{j1}	x_{j2}
1	1	1
2	-1	2
3	0	2

(1) 对每个样本，计算后验概率 $P(\omega_1 \mid \mathbf{x}_j)$ 和 $P(\omega_2 \mid \mathbf{x}_j)$ 。

(2) 利用逻辑回归的决策函数，判断每个样本所属类别。



5.7 罗杰斯特回归

■ 例题解答 (1) 后验概率

$$\text{由 } P(\omega_1 | \mathbf{x}) = \theta(\mathbf{w}^T \mathbf{x}) = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}}, \quad P(\omega_2 | \mathbf{x}) = 1 - P(\omega_1 | \mathbf{x}).$$

$$\text{样本 1: } \mathbf{w}^T \mathbf{x}_1 = 1 + 2 - 1 = 2$$


$$P(\omega_1 | \mathbf{x}_1) = \frac{1}{1 + e^{-2}} \approx 0.8808, \quad P(\omega_2 | \mathbf{x}_1) \approx 0.1192$$

$$\text{样本 2: } \mathbf{w}^T \mathbf{x}_2 = 1 - 2 - 2 = -3$$

$$P(\omega_1 | \mathbf{x}_2) = \frac{1}{1 + e^3} \approx 0.0474, \quad P(\omega_2 | \mathbf{x}_2) \approx 0.9526$$

$$\text{样本 3: } \mathbf{w}^T \mathbf{x}_3 = 1 + 0 - 2 = -1$$

$$P(\omega_1 | \mathbf{x}_3) = \frac{1}{1 + e^1} \approx 0.2689, \quad P(\omega_2 | \mathbf{x}_3) \approx 0.7311$$



5.7 罗杰斯特回归

■ 例题解答


(2) 决策

由逻辑回归的决策函数：若 $\text{logit}(\boldsymbol{x}) = \boldsymbol{w}^T \boldsymbol{x} \geq 0$ 则 $x \in \omega_1$ ，否则 $x \in \omega_2$ 。

样本 1: $\text{logit}(\boldsymbol{x}_1) = 2 > 0$ ，判为 ω_1

样本 2: $\text{logit}(\boldsymbol{x}_2) = -3 < 0$ ，判为 ω_2

样本 3: $\text{logit}(\boldsymbol{x}_3) = -1 < 0$ ，判为 ω_2




5.9 多类线性分类器


- 两种解决思路

- 把多类问题分解成多个二分类问题，通过多个二分类器实现多类的分类
- 直接设计多类分类器

5.9.1 多个两类分类器的组合


- 以手写数字识别为例
 - 设计多个二分类器
 - 第一个分类器把“0”和其他数字分开
 - 第二个分类器把“1”和其他数字分开
 - 依次类推





5.9.1 多个两类分类器的组合

- “一对多”做法
 - 需要 $c-1$ 个两类分类器就可以实现 c 个类的分类
 - 不足之处
 - 假如多类中各类的训练样本数目相当，构造每个一对多的两类分类器时会面临训练样本不均衡的问题
- “逐对分类”做法
 - 对多类中的每两类构造一个分类器
 - 对于 c 个类别，共需要 $\frac{c(c-1)}{2}$ 个两类分类器



5.9.2 多类线性判别函数

- 多类线性判别


- 为每一类定义一个判别函数：

$$g_i(x) = w_i^T x + w_{i0}, \quad i = 1, 2, \dots, c \quad (5-129)$$

- 将样本归到判别函数最大的类别中：

$$\text{若 } g_i(x) = \max_{j=1,2,\dots,c} g_j(x), \text{ 则 } x \in \omega_i$$

- 考虑多类线性可分情况，利用与感知器算法类似的步骤进行求解



5.9.2 多类线性判别函数

- 多类线性机器——逐步修正法
 - 1. 初始化：为每个类别任意指定初始权重向量
 - 2. 检验：对当前样本计算各类判别函数值，判断真实类别的判别函数值是否为所有类别中的**最大值**
 - 3. 修正：若是，则所有权重向量保持不变；若否，则增大真实类别的权重向量，削减响应值最大的错误类别的权重向量，其余类别权重向量不变
 - 4. 迭代：遍历全部样本，若所有样本均被正确分类则算法终止，否则返回第 2 步继续修正

详见教材 公式 5-132

5.9.3 多类罗杰斯特回归

- 二分类情况下的罗杰斯特函数

$$P(y = 1 \mid x) = \frac{e^{w_0 + w_1 x}}{1 + e^{w_0 + w_1 x}} \quad (5-133)$$

- 扩展到多类情况


- 样本属于第 j 类的概率与参数为 w_j 的指数判别函数成正比，即：

$$P(y = j \mid x) \propto e^{w_j x}$$

- 用样本属于全部 c 个类别的判别函数做归一化：

$$P(y = j \mid x) = \frac{e^{w_j x}}{\sum_{k=1}^c e^{w_k x}}, \quad j = 1, \dots, c \quad (5-134)$$

归一化指数函数为 softmax 函数



5.9.3 多类罗杰斯特回归


- 决策过程

- 选择后验概率最大的类别：

$$\hat{y} = \arg \max_j P(y = j \mid \mathbf{x}) = \arg \max_j \frac{e^{\mathbf{w}_j^T \mathbf{x}}}{\sum_{k=1}^c e^{\mathbf{w}_k^T \mathbf{x}}}$$

- 由于分母对所有类别相同，等价于直接比较分子：

$$\hat{y} = \arg \max_j \mathbf{w}_j^T \mathbf{x}$$




5.9.3 多类罗杰斯特回归

■ 例题

题目：在三分类逻辑回归中，某样本 $\mathbf{x}$ 对应三个类别的判别函数值分别为：

$$\mathbf{w}_1^T \mathbf{x} = 2, \quad \mathbf{w}_2^T \mathbf{x} = 1, \quad \mathbf{w}_3^T \mathbf{x} = -1$$

利用 softmax 函数计算该样本属于各类别的后验概率，并判断其所属类别。



5.9.3

■ 例题求解

由 softmax 函数 $P(y = j \mid \mathbf{x}) = \frac{e^{\mathbf{w}_j^T \mathbf{x}}}{\sum_{k=1}^3 e^{\mathbf{w}_k^T \mathbf{x}}}$, 先计算各指数值:

$$e^2 = 7.3891, \quad e^1 = 2.7183, \quad e^{-1} = 0.3679$$

$$\sum_{k=1}^3 e^{\mathbf{w}_k^T \mathbf{x}} = 7.3891 + 2.7183 + 0.3679 = 10.4753$$

各类后验概率:

$$P(\omega_1 \mid \mathbf{x}) = \frac{7.3891}{10.4753} \approx 0.7054$$

$$P(\omega_2 \mid \mathbf{x}) = \frac{2.7183}{10.4753} \approx 0.2595$$

$$P(\omega_3 \mid \mathbf{x}) = \frac{0.3679}{10.4753} \approx 0.0351$$

由于 $P(\omega_1 \mid \mathbf{x})$ 最大, 判定 $\mathbf{x} \in \omega_1$ 。