



第八章 非参数学习机 器与集成学习





8.2.1 最近邻法

- 基本思想

- 对于一个新样本，把它逐一与已知样本比较
- 找出距离新样本最近的已知样本，以该样本的类别作为新样本的类别

- 形式化定义

- 已知样本集 $\{(x_1, \omega_1), \dots, (x_N, \omega_N)\}$ ，共有 c 个类别，即 $\omega_i, i = 1, 2, \dots, c$
- 定义两个样本间的距离度量 $\delta(x_i, x_j)$ ，例如欧式距离等
- 对于未知样本 x ，计算样本集中与 x 距离最近的样本，设为 x' 对应类别为 ω' ，即 $\delta(x, x') = \min_{j=1, \dots, N} \delta(x, x_j)$
- 将 x 决策为 ω' 类

8.2.1 最近邻法

■ 判别函数


■ ω_i 类的判别函数


$$g_i(x) = \min_{x_j \in \omega_i} \delta(x, x_j), \quad i = 1, \dots, c \quad (8-1)$$

■ 决策规则

■ 比较各类判别函数的大小

$$\text{若 } g_k(x) = \min_{i=1, \dots, c} g_i(x), \text{ 则 } x \in \omega_k \quad (8-2)$$





8.2.1 最近邻法

已知样本集 $S_N = \{(\mathbf{x}_1, \omega_1), (\mathbf{x}_2, \omega_1), (\mathbf{x}_3, \omega_2), (\mathbf{x}_4, \omega_2)\}$, 各样本为:

样本	特征向量	类别
$\mathbf{x}_1$	$(1.5, 1.5)^T$	ω_1
$\mathbf{x}_2$	$(5, 0)^T$	ω_1
$\mathbf{x}_3$	$(0, 2.5)^T$	ω_2
$\mathbf{x}_4$	$(4, 4)^T$	ω_2

待分类样本 $\mathbf{x} = (0, 0)^T$ 。

(1) 采用欧氏距离 $\delta_E(\mathbf{a}, \mathbf{b}) = \|\mathbf{a} - \mathbf{b}\|_2$ 进行最近邻分类。

(2) 采用曼哈顿距离 $\delta_M(\mathbf{a}, \mathbf{b}) = \|\mathbf{a} - \mathbf{b}\|_1$ 进行最近邻分类。



8.2.1 最近邻法

(1) 欧氏距离

$$\delta_E(\mathbf{x}, \mathbf{x}_1) = \sqrt{1.5^2 + 1.5^2} = 1.5\sqrt{2} \approx 1.5 \times 1.414 = 2.121$$

$$\delta_E(\mathbf{x}, \mathbf{x}_2) = \sqrt{5^2 + 0^2} = 5$$


$$\delta_E(\mathbf{x}, \mathbf{x}_3) = \sqrt{0^2 + 2.5^2} = 2.5$$

$$\delta_E(\mathbf{x}, \mathbf{x}_4) = \sqrt{4^2 + 4^2} = 4\sqrt{2} \approx 5.657$$

距离从小到大排列: $\mathbf{x}_1$ (2.121) < $\mathbf{x}_3$ (2.5) < $\mathbf{x}_2$ (5) < $\mathbf{x}_4$ (5.657)

最近邻为 $\mathbf{x}_1$, 属于 ω_1 类。

欧氏距离下, $\mathbf{x} \rightarrow \omega_1$



8.2.1 最近邻法

(2) 曼哈顿距离

■ 例题

$$\delta_M(\mathbf{x}, \mathbf{x}_1) = |0 - 1.5| + |0 - 1.5| = 3$$

$$\delta_M(\mathbf{x}, \mathbf{x}_2) = |0 - 5| + |0 - 0| = 5$$

$$\delta_M(\mathbf{x}, \mathbf{x}_3) = |0 - 0| + |0 - 2.5| = 2.5$$


$$\delta_M(\mathbf{x}, \mathbf{x}_4) = |0 - 4| + |0 - 4| = 8$$

距离从小到大排列： $\mathbf{x}_3$ (2.5) < $\mathbf{x}_1$ (3) < $\mathbf{x}_2$ (5) < $\mathbf{x}_4$ (8)

最近邻为 $\mathbf{x}_3$ ，属于 ω_2 类。

曼哈顿距离下， $\mathbf{x} \rightarrow \omega_2$

例题说明：在已知样本集和未知样本均相同的前提下，选择不同的距离度量方法，所得到的决策结果不同！



8.2.1 最近邻法

- 平均错误率

- 将 N 个样本下的近邻法的平均错误率记作 $P_N(e)$, 样本 x 的最近邻为 x' , 则:

$$P_N(e) = E_{\mathbf{x}, \mathbf{x}'} [P_N(e \mid \mathbf{x}, \mathbf{x}')]]$$

将期望转成
二重积分




$$= \int_x \int_{x'} P_N(e \mid x, x') \cdot p(x', x) dx' dx$$

$p(x', x)$

$= p(x' \mid x) \cdot p(x)$



$$= \int_x \int_{x'} P_N(e \mid x, x') p(x' \mid x) dx' p(x) dx$$



8.2.1 最近邻法

- 渐进错误率


- 当样本数 $N \rightarrow \infty$ 时 $P_N(e)$ 的极限, $P = \lim_{N \rightarrow \infty} P_N(e)$ 存在如下关系:

$$P^* \leq P \leq P^* \left(2 - \frac{c}{c-1} P^* \right) \quad (8-3)$$

- 其中 P^* 为贝叶斯错误率, 即理论上最优的错误率, c 为类别数

$$P^* = \int P(e, x) dx = \int P(e | \mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

- 公式 8-3 说明: 最近邻法的渐进错误率最坏不会超过两倍的贝叶斯错误率, 而最好则有可能接近或达到贝叶斯错误率





8.2.2 k -近邻法

- 最近邻法的不足之处
 - 完全取决于一个最近邻，如果该邻居恰好是噪声或离群点，就会直接导致误判
- k -近邻法的改进
 - 引入投票机制，选择前若干个离未知样本最近的已知样本，根据它们的类别投票决定新样本的类别
 - 将参加投票的近邻样本个数记作 k
 - 最近邻法可以看作是 k -近邻法的特例

8.2.2 k-近邻法

二分类问题中，
通常将 k 设置为
奇数，以避免两
类出现得票相等
的情况





8.2.2 k-近邻法


- 形式化定义

- N 个已知样本分属于 c 个类别中 $\omega_i, i = 1, 2, \dots, c$
- 考查新样本 x 在已知样本中的前 k 近邻, 设其中有 k_i 个属于 ω_i 类, 则 ω_i 类对应的判别函数为:

$$g_i(x) = k_i, \quad i = 1, \dots, c \quad (8-4)$$

- 决策规则为:

$$\text{若 } g_k(x) = \max_{i=1, \dots, c} g_i(x), \text{ 则 } x \in \omega_k \quad (8-5)$$



8.2.2 k-近邻法

■ 例题


已知训练样本集如下：

样本	x_1	x_2	类别
$\mathbf{x}_1$	2	4	ω_1
$\mathbf{x}_2$	3	1	ω_1
$\mathbf{x}_3$	1	7	ω_1
$\mathbf{x}_4$	5	2	ω_2
$\mathbf{x}_5$	6	4	ω_2
$\mathbf{x}_6$	4	6	ω_2

距离度量采用切比雪夫距离：

$$d(\mathbf{a}, \mathbf{b}) = \max_j |a_j - b_j|$$

取 $k = 3$ ，试用 K 近邻法判断测试样本 $\mathbf{x} = (3, 3)^T$ 的类别。



8.2.2 k-近邻法

■ 例题求解

第一步：计算切比雪夫距离

$$d(\mathbf{x}, \mathbf{x}_1) = \max(|3 - 2|, |3 - 4|) = \max(1, 1) = 1$$


$$d(\mathbf{x}, \mathbf{x}_2) = \max(|3 - 3|, |3 - 1|) = \max(0, 2) = 2$$

$$d(\mathbf{x}, \mathbf{x}_3) = \max(|3 - 1|, |3 - 7|) = \max(2, 4) = 4$$

$$d(\mathbf{x}, \mathbf{x}_4) = \max(|3 - 5|, |3 - 2|) = \max(2, 1) = 2$$

$$d(\mathbf{x}, \mathbf{x}_5) = \max(|3 - 6|, |3 - 4|) = \max(3, 1) = 3$$

$$d(\mathbf{x}, \mathbf{x}_6) = \max(|3 - 4|, |3 - 6|) = \max(1, 3) = 3$$



8.2.2 k-近邻法

第二步：距离排序并选取 $k = 3$ 个近邻

■ 例题求解


排名	样本	距离	类别
1	$\mathbf{x}_1$	1	ω_1
2	$\mathbf{x}_2$	2	ω_1
3	$\mathbf{x}_4$	2	ω_2
4	$\mathbf{x}_5$	3	ω_2
5	$\mathbf{x}_6$	3	ω_2
6	$\mathbf{x}_3$	4	ω_1

前 $k = 3$ 个近邻为 $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_4$ 。

第三步：多数投票

$\omega_1 : 2$ 票, $\omega_2 : 1$ 票

$\mathbf{x} = (3, 3)^T$ 被判为 ω_1




8.2.2 k-近邻法

- 渐近错误率理论分析

- 仍然满足公式 8-3 的上下界关系

$$P^* \leq P \leq P^* \left(2 - \frac{c}{c-1} P^* \right) \quad (8-3)$$


- 但随着 k 的增加, 上界逐渐降低
 - 当 k 趋于无穷大时, 上界和下界相等, k -近邻法达到了贝叶斯错误率
 -  虽然此时 k 可以趋于无穷大, 但 k 与样本数 N 相比仍然是可以忽略的一小部分



8.2.2 k-近邻法

- 不足之处

- 当样本数目较多时才会取得好的性能
- 新样本需要与每一个样本计算距离并进行比较和排序
- 必须始终存储所有的已知样本
- 计算和存储成本较高



8.2.3 近邻法的快速算法


- 解决思路

- 采用分枝定界算法

- 将整个已知样本集分级划分成多个子集，形成一个树状结构
 - 每个节点是一个样本子集
 - 每个子集用较少的几个量表示
 - 将新样本按顺序与各个节点进行比较，排除不可能包含最近邻的样本子集（粗粒度剪枝，判断每个节点是否可以直接跳过）
 - 只在叶子节点上才需要与每个样本进行比较（细粒度剪枝，判断该节点对应的样本子集中的某个样本是否可以直接跳过）

8.2.3 近邻法的快速算法

示意图




8.2.3 近邻法的快速算法


- 第一阶段：划分样本集 $\mathcal{X}$ ，形成树结构
 -  首先讨论最近邻，再将其扩展到 k -近邻情况
 - 将样本集 $\mathcal{X}$ 分为 l 个子集。每个子集再分成 l 个子集，以此类推，构成树结构
 - 树中第 p 个节点的符号定义
 - $\mathcal{X}_p$: 节点 p 对应的样本子集
 - N_p : 样本子集 $\mathcal{X}_p$ 中的样本数目
 - M_p : 样本子集 $\mathcal{X}_p$ 中的样本均值
 - $r_p = \max_{x_i \in \mathcal{X}_p} D(x_i, M_p)$: 从 M_p 到 $x_i \in \mathcal{X}_p$ 的最大距离

8.2.3 近邻法的快速算法

- 第一阶段：划分样本集 $\mathcal{X}$ ，形成树结构




划分样本集可以使用教材中的聚类方法，例如 C 均值算法



8.2.3 近邻法的快速算法

- 第二阶段：搜索

- 为检验未知样本 x 的最近邻是否出现在第 p 个节点对应的样本子集 $\mathcal{X}_p$ 中，定义如下两个规则：
- **规则 1**: 如果存在 $D(x, M_p) > B + r_p$ 则 $x_i \in \mathcal{X}_p$ 不可能是 x 的最近邻
 - 其中， B 是算法执行到目前为止，找到的已知样本到 x 的最近距离



8.2.3 近邻法的快速算法

- 第二阶段：搜索


- **规则 1**: 如果存在 $D(x, M_p) > B + r_p$ 则 $x_i \in \mathcal{X}_p$ 不可能是 x 的最近邻。
 - **规则含义**: 该规则用于**粗粒度剪枝**, 判断第 p 个节点对应的样本子集 $\mathcal{X}_p$ 是否可以被完全排除

8.2.3 近邻法的快速算法


■ 第二阶段：搜索

- **规则 1**: 如果存在 $D(x, M_p) > B + r_p$ 则 $x_i \in \mathcal{X}_p$ 不可能是 x 的最近邻。

- **几何意义**: 即使 $\mathcal{X}_p$ 中离 x 最近的样本 (位于球的边缘上), 其距离也至少是 $D(x, M_p) - r_p > B$



意味着整个子集 $\mathcal{X}_p$ 中不可能存在比当前最近邻更近的点, 因此可以安全地剪枝



8.2.3 近邻法的快速算法

- 第二阶段：搜索

- **规则 1**: 如果存在 $D(x, M_p) > B + r_p$ 则 $x_i \in \mathcal{X}_p$ 不可能是 x 的最近邻。

- **证明过程**:

- 对于 $x_i \in \mathcal{X}_p$, 根据**三角不等式**:

$$D(x, x_i) \geq D(x, M_p) - \underline{D(x_i, M_p)}$$

- 由于 $x_i \in \mathcal{X}_p$, r_p 为子集的半径:

$$\underline{D(x_i, M_p)} \leq r_p$$

- 代入上式:

$$D(x, x_i) \geq D(x, M_p) - \underline{r_p}$$

8.2.3 近邻法的快速算法

- 第二阶段：搜索

- 规则 1: 如果存在 $D(x, M_p) > B + r_p$ 则 $x_i \in \mathcal{X}_p$ 不可能是 x 的最近邻。


- 证明过程：

- 代入上式：

$$D(x, x_i) \geq D(x, M_p) - r_p$$

- 若规则1 $D(x, M_p) > B + r_p$ 成立，则：


$$D(x, x_i) \geq \underline{D(x, M_p)} - r_p > \underline{(B + r_p)} - r_p = B$$



8.2.3 近邻法的快速算法

- 第二阶段：搜索

- 为检验未知样本 x 的最近邻是否出现在第 p 个节点对应的样本子集 $\mathcal{X}_p$ 中，定义如下两个规则：
- **规则 1**: 如果存在 $D(x, M_p) > B + r_p$ 则 $x_i \in \mathcal{X}_p$ 不可能是 x 的最近邻。
 - 其中， B 是在算法执行过程中，当前为止找到的已知样本到 x 的最近距离
- **规则 2**: 如果 $D(x, M_p) > B + D(x_i, M_p)$ ，其中 $x_i \in \mathcal{X}_p$ ，则 x_i 不是 x 的最近邻



8.2.3 近邻法的快速算法


- 第二阶段：搜索

- **规则2**: 如果 $D(x, M_p) > B + D(x_i, M_p)$, 其中 $x_i \in \mathcal{X}_p$, 则 x_i 不是 x 的最近邻
- **规则含义**: 该规则用于**细粒度剪枝**, 判断第 p 个节点对应的样本子集 $\mathcal{X}_p$ 内某个具体样本 x_i 是否可以被排除

8.2.3 近邻法的快速算法

■ 第二阶段：搜索

- **规则2**: 如果 $D(x, M_p) > B + D(x_i, M_p)$, 其中 $x_i \in \mathcal{X}_p$, 则 x_i 不是 x 的最近邻
- **几何意义**: 样本点 x 距离子集 $\mathcal{X}_p$ 不够远 (无法通过规则 1 整体剪枝), 但子集内离圆心近的个别样本仍然可以单独排除



8.2.3 近邻法的快速算法

■ 第二阶段：搜索

- **规则2**: 如果 $D(x, M_p) > B + D(x_i, M_p)$, 其中 $x_i \in \mathcal{X}_p$, 则 x_i 不是 x 的最近邻

- **证明过程**:

- 同样利用三角不等式:

$$D(x, x_i) \geq D(x, M_p) - D(x_i, M_p)$$

- 若规则2 $D(x, M_p) > B + D(x_i, M_p)$ 成立, 则:

$$D(x, x_i) \geq \underline{D(x, M_p)} - D(x_i, M_p) > \underline{B + D(x_i, M_p)} - D(x_i, M_p) = B$$

- 因此样本 x_i 到 x 的距离必然大于当前最佳距离 B , 可以**排除 x_i 作为最近邻的可能**

8.2.3 近邻法的快速算法

- 第二阶段：树搜索算法（输入：查询样本 x ，度量树 T ）

```
1   $B \leftarrow \infty$ ,  $NN \leftarrow \text{空}$ 
2  将 root 的所有子节点加入最小优先队列  $Q$ 
   ( $Q$  按  $D(x, M_p)$  从小到大排序, 每次弹出距离最小的节点)

3  当  $Q$  非空 时:
4  |    $c^* \leftarrow$  从  $Q$  中弹出距离最小的节点
5  |   若  $D(x, M_{\{c^*\}}) > B + r_{\{c^*\}}$ : 跳过  $c^*$       // 剪枝
6  |
7  |   若  $c^*$  是内部节点:
8  |   |   将  $c^*$  的所有子节点加入  $Q$ 
9  |   若  $c^*$  是叶节点:
10 |   |   对  $c^*$  中每个样本  $x_i$ :
11 |   |   |   若  $D(x, M_{\{c^*\}}) > D(x_i, M_{\{c^*\}}) + B$ : 跳过
12 |   |   |   若  $D(x, x_i) < B$ :  $B \leftarrow D(x, x_i)$ ,  $NN \leftarrow x_i$ 


13 输出  $NN$  和  $B$ 
```

8.2.3 近邻法的快速算法

■ 第二阶段：树搜索算法示例

查询样本 $x = (4,3)$,
找出该节点的最近
邻点

二叉度量树



叶子节点样本

(1,1) (3,1)
(2,4)

(5,1) (5,3)

(8,7) (10,7)
(9,4)

(11,2) (13,2)

8.2.3 近邻法的快速算法


■ 第二阶段：树搜索算法示例

第1轮：展开根节点的两个子节点进入优先队列

$$D(\mathbf{x}, M_{P_1}) = D((4, 3), (3.2, 2)) = \sqrt{0.64 + 1} = 1.28$$

$$D(\mathbf{x}, M_{P_2}) = D((4, 3), (10.2, 4.4)) = \sqrt{38.44 + 1.96} = 6.36$$

此时 $B = \infty$ ，无法剪枝，队列 $Q = \{(P_1, 1.28), (P_2, 6.36)\}$ 。



8.2.3 近邻法的快速算法


■ 第二阶段：树搜索算法示例

第2轮：取出 P_1 （距离最小），展开它的子节点

$$D(\mathbf{x}, M_A) = D((4, 3), (2, 2)) = \sqrt{4 + 1} = 2.24$$

$$D(\mathbf{x}, M_B) = D((4, 3), (5, 2)) = \sqrt{1 + 1} = 1.41$$

$B = \infty$ ，无法剪枝。队列 $Q = \{(B, 1.41), (A, 2.24), (P_2, 6.36)\}$ 。



8.2.3 近邻法的快速算法


■ 第二阶段：树搜索算法示例

第3轮：取出叶 **B**（距离最小），检查样本

叶 B 含样本 (5, 1) 和 (5, 3)，代表点 $M_B = (5, 2)$ ：

- 样本 (5, 1)： $D(\mathbf{x}, (5, 1)) = \sqrt{1 + 4} = 2.24$ ， B 更新为 2.24
- 样本 (5, 3)： $D(\mathbf{x}, (5, 3)) = \sqrt{1 + 0} = 1.0$ ， B 更新为 **1.0**， $NN = (5, 3)$

叶节点更新 B!



8.2.3 近邻法的快速算法


■ 第二阶段：树搜索算法示例


第4轮：取出叶 A，先检查剪枝条件

$$D(\mathbf{x}, M_A) = 2.24, B + r_A = 1.0 + 2.0 = 3.0$$

$2.24 \leq 3.0$ ，不能剪枝，需要检查样本。代表点 $M_A = (2, 2)$ ：

规则 1：如果存在 $D(x, M_p) > B + r_p$ 则 $x_i \in \mathcal{X}_p$ 不可能是 x 的最近邻





8.2.3 近邻法的快速算法

■ 第二阶段：树搜索算法示例

- 样本 (1, 1): $D(\mathbf{x}_i, M_A) = \sqrt{1+1} = 1.41$, 检查 $D(\mathbf{x}, M_A) > D(\mathbf{x}_i, M_A) + B$? 即 $2.24 > 1.41 + 1.0 = 2.41$? 否, 需要算距离。 $D(\mathbf{x}, (1, 1)) = \sqrt{9+4} = 3.61 > B$, 不更新。
- 样本 (3, 1): $D(\mathbf{x}_i, M_A) = 1.41$, 同理 $2.24 > 2.41$? 否, 算距离。 $D(\mathbf{x}, (3, 1)) = \sqrt{1+4} = 2.24 > B$, 不更新。
- 样本 (2, 4): $D(\mathbf{x}_i, M_A) = 2.0$, $2.24 > 2.0 + 1.0 = 3.0$? 否, 算距离。
 $D(\mathbf{x}, (2, 4)) = \sqrt{4+1} = 2.24 > B$, 不更新。

规则2: 如果 $D(x, M_p) > B + D(x_i, M_p)$, 其中 $x_i \in \mathcal{X}_p$, 则 x_i 不是 x 的最近邻

8.2.3 近邻法的快速算法

■ 第二阶段：树搜索算法示例


第5轮：取出 P_2 ，检查剪枝条件

$$D(\mathbf{x}, M_{P_2}) = 6.36, B + r_{P_2} = 1.0 + 3.69 = 4.69$$

$6.36 > 4.69$ ，剪枝成功！整棵右子树跳过！

队列为空，算法结束。输出 $NN = (5, 3)$ ， $B = 1.0$ 。

规则 1: 如果存在 $D(x, M_p) > B + r_p$ 则 $x_i \in \mathcal{X}_p$ 不可能是 x 的最近邻



8.2.3 近邻

■ 扩展到 k -近邻法

- 输入: 查询样本 x , 度量树 T , 近邻数 K
- 最大堆 L : 堆顶始终是第 K 个候选 (所有 K 个近邻中距离 x 最远)
- B : 第 K 近邻的距离 (L 中的最大距离)

```
1  B ← ∞, L ← 空的最大堆 (按距离从大到小, 容量为 K)
2  将 root 的所有子节点加入最小优先队列 Q
   (Q 按  $D(x, M_p)$  从小到大排序, 每次弹出距离最小的节点)

3  当 Q 非空 时:
4  |   c* ← 从 Q 中弹出距离最小的节点
5  |   若  $D(x, M_{\{c^*\}}) > B + r_{\{c^*\}}$ : 跳过 c*           // 剪枝
6  |
7  |   若 c* 是内部节点:
8  |   |   将 c* 的所有子节点加入 Q
9  |   若 c* 是叶节点:
10 |   |   对 c* 中每个样本  $x_i$ :
11 |   |   |   若  $D(x, M_{\{c^*\}}) > D(x_i, M_{\{c^*\}}) + B$ : 跳过
12 |   |   |   若  $|L| < K$ :
13 |   |   |   |   将  $(x_i, D(x, x_i))$  加入 L
14 |   |   |   |   若  $|L| = K$ : B ← L 中的最大距离
15 |   |   |   否则若  $D(x, x_i) < B$ :
16 |   |   |   |   从 L 中移除距离最大的元素
17 |   |   |   |   将  $(x_i, D(x, x_i))$  加入 L
18 |   |   |   |   B ← L 中的最大距离
```

8.2.3 近邻法的快速算法

■ 扩展到 k -近邻法例题—规则1：子树剪枝


使用 $K = 3$ 近邻法对查询样本 $\mathbf{x} = (1, 2)$ 进行分类。搜索过程中，当前已找到的 3-NN 列表为：

近邻样本	欧式距离 $D(\mathbf{x}, \mathbf{x}_i)$
$(3, 2)$	2
$(2, 4)$	$\sqrt{5}$
$(0, 5)$	$\sqrt{10}$

现在优先队列中弹出子树节点 p ，其代表点 $M_p = (7, 10)$ ，覆盖半径 $r_p = 3$ 。

(a) 计算 $D(\mathbf{x}, M_p)$ ，并判断能否对该子树剪枝。

(b) 若 r_p 变为 8，结论是否改变？请解释原因。




8.2.3 近邻法的快速算法

- 扩展到 k -近邻法例题解答—规则1：子树剪枝

(a) $D(\mathbf{x}, M_p) = \sqrt{6^2 + 8^2} = 10$ 。当前 $B = \sqrt{10}$ (第3近邻距离)。

$D(\mathbf{x}, M_p) = 10 > \sqrt{10} + 3 \approx 6.16 = B + r_p$ ，可以剪枝。

(b) 若 $r_p = 8$ ： $B + r_p = \sqrt{10} + 8 \approx 11.16 > 10 = D(\mathbf{x}, M_p)$ ，不能剪枝。覆盖半径增大意味着子树覆盖范围更广，不能排除其中存在比当前第 K 近邻更近的样本。



8.2.3 近邻法的快速算法

- 扩展到 k -近邻法例题—规则2：样本级剪枝

使用 $K = 2$ 近邻法对查询样本 $\mathbf{x} = (0, 2)$ 进行分类。搜索进入叶节点 p ，代表点 $M_p = (5, 2)$ ，节点内存储 5 个样本：

$$\mathbf{x}_1 = (4, 2), \quad \mathbf{x}_2 = (6, 2), \quad \mathbf{x}_3 = (5, 6), \quad \mathbf{x}_4 = (3, 2), \quad \mathbf{x}_5 = (9, 2)$$

当前 2-NN 列表中 $B = 2$ 。

判断每个样本是否可以跳过？是否需要更新近邻列表？

8.2.3 近邻法的快速算法

- 扩展到 k -近邻法例题解答—规则2：样本级剪枝

$$D(\mathbf{x}, M_p) = \sqrt{25 + 0} = 5$$


样本	$D(\mathbf{x}_i, M_p)$	$D(\mathbf{x}_i, M_p) + B$	$5 > ?$	结论
(4, 2)	1	3	$5 > 3 \checkmark$	跳过
(6, 2)	1	3	$5 > 3 \checkmark$	跳过
(5, 6)	4	6	$5 > 6 \times$	需要计算
(3, 2)	2	4	$5 > 4 \checkmark$	跳过
(9, 2)	4	6	$5 > 6 \times$	需要计算

只需对 $\mathbf{x}_3$ 和 $\mathbf{x}_5$ 计算实际距离：

$$D(\mathbf{x}, \mathbf{x}_3) = \sqrt{25 + 16} = \sqrt{41} \approx 6.40 > B$$

$$D(\mathbf{x}, \mathbf{x}_5) = \sqrt{81 + 0} = 9 > B$$

均大于 $B = 2$ ，不更新近邻列表。



8.2.4 剪辑近邻法


- 基本思想

- 当两类数据的分布存在一定重叠时，样本不能完全可分
- 将重叠部分的已知样本去掉，决策时不再受到错分样本影响
- 使近邻法的决策面更接近最优分类面

8.2.4 剪辑近邻法

示意图


- 原始训练集存在重叠区域，导致错分类情况出现




8.2.4 剪辑近邻法

■ 示意图

- 去除重叠部分的已知样本，使近邻法的决策面更接近最优分类面






8.2.4 剪辑近邻法

■ 具体流程

- 把已知样本集分成两部分：训练集 $\mathcal{X}^{\text{NR}}$ 和测试集 $\mathcal{X}^{\text{NT}}$
- 利用训练集 $\mathcal{X}^{\text{NR}}$ 对测试集 $\mathcal{X}^{\text{NT}}$ 中的每个样本进行近邻法分类
- 从 $\mathcal{X}^{\text{NT}}$ 中去除错误分类的样本
- 剩余样本构成剪辑样本集 $\mathcal{X}^{\text{NTE}}$
- 利用 $\mathcal{X}^{\text{NTE}}$ 对未知样本进行近邻法分类




8.2.4 剪辑近邻法

- 错误率理论分析

- 在剪辑阶段使用最近邻法，在分类阶段也使用最近邻法，则对于任意样本 x ，剪辑近邻法得到的渐近错误率与近邻法错误率的关系：

$$P_1^E(e | x) = \frac{P(e | x)}{2[1 - P(e | x)]} \quad (8-8)$$


- 其中， $P(e | x)$ 是最近邻法的错误率， $P_1^E(e | x)$ 是剪辑近邻法的错误率
- 由公式 8-3 可知，最近邻法的渐近错误率上界是两倍的贝叶斯错误率。如果最近邻法的错误率不大，剪辑近邻法的渐近错误率近似等于贝叶斯错误率



8.2.4 剪辑近邻法

- 错误率理论分析

- 在剪辑阶段使用 k -近邻法，在分类阶段使用最近邻法，则当 $N \rightarrow \infty, k \rightarrow \infty$ 但 $k/N \rightarrow 0$ 时，剪辑近邻法的渐近错误率收敛于贝叶斯错误率



8.2.4 剪辑近邻法


- 多重剪辑方法

- 目的

- 消除测试集、训练集划分中的偶然性造成的影响

- 流程

- 1. 划分。把样本集随机划分为 s 个子集, $x_1, \dots, x_s$, $s \geq 3$
 - 2. 分类。利用 $x_{(i+1) \bmod s}$ 对 x_i 中的样本分类, $i = 1, \dots, s$ (若 $s = 3$, 则用 x_2 对 x_1 分类, 用 x_3 对 x_2 分类, 用 x_1 对 x_3 分类)
 - 3. 剪辑。从各个子集中去掉在步骤 2 中被分错的样本



8.2.4 剪辑近邻法


- 多重剪辑方法

- 流程


- 4. 混合。把剩下的样本合在一起，形成新的样本集 $\mathcal{X}^{\text{NE}}$
 - 5. 迭代。用新的样本集 $\mathcal{X}^{\text{NE}}$ 替代原样本集，重复步骤 1
 - 6. 结束。若最近的 m 次迭代中都没有样本被剪掉，则终止迭代

8.2.4 剪辑近邻法


(a) 原始样本集
样本数: 400




(b) 第1次剪辑 (移除25个样本)
样本数: 375




(c) 第2次剪辑 (移除5个样本)
样本数: 370




(d) 第3次剪辑 (移除2个样本)
样本数: 368



(e) 第4次剪辑 (移除3个样本)
样本数: 365





(f) 第5次剪辑 (移除1个样本)
样本数: 364




8.2.4 剪辑近邻法

■ 多重剪辑方法示意图

- 左图：原始数据集下的最近邻方法决策边界十分不规则
- 右图：剪辑数据集后得到的决策边界变得平滑，逐渐接近贝叶斯最优分类面






8.2.5 压缩近邻法

- 基本思想

- 对于近邻法，远离分类边界的样本对于最后的分类决策没有贡献
- 找出各类样本中最有利于用来与其它类别区分的代表性样本

- 优点

- 在不牺牲分类准确度的前提下，大幅压缩近邻法决策时的训练样本数目



8.2.5 压缩近邻法

■ 具体做法

- 将整个样本集划分为储存集 $\mathcal{X}_S$ 和备选集 $\mathcal{X}_G$
- 算法开始时, $\mathcal{X}_S$ 中只有一个样本, 其余样本均在 $\mathcal{X}_G$ 中
- 考查 $\mathcal{X}_G$ 每一个样本 x , 若用 $\mathcal{X}_S$ 的样本能够对它正确分类, 则该样本保留在 $\mathcal{X}_G$ 中; 否则移到 $\mathcal{X}_S$ 中
- 依次类推, 直到没有样本再需要搬移为止
- 最后用 $\mathcal{X}_S$ 中的样本作为代表样本, 对未来样本进行近邻法分类