

8.2.5 压缩近邻法

■ 计算示例

题目：已知两类样本，采用最近邻法分类，距离度量为欧氏距离：

$$\omega_1 : \mathbf{x}_1 = (0, 0), \mathbf{x}_2 = (1, 0), \mathbf{x}_3 = (0, 1)$$

$$\omega_2 : \mathbf{x}_4 = (6, 6), \mathbf{x}_5 = (7, 6), \mathbf{x}_6 = (6, 7)$$

请用压缩近邻法对样本集进行压缩，初始储存集 $\mathcal{X}_S = \{\mathbf{x}_1\}$ 。写出算法的完整执行过程，给出最终的储存集 $\mathcal{X}_S$ 。

8.2.5 压缩近邻法

■ 计算示例

初始化: $\mathcal{X}_S = \{\mathbf{x}_1\}$, $\mathcal{X}_G = \{\mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4, \mathbf{x}_5, \mathbf{x}_6\}$

第1轮扫描 储存集 备选集

步骤1: 考查 $\mathbf{x}_2 = (1, 0) \in \omega_1$ 。 $\mathcal{X}_S$ 中最近邻为 $\mathbf{x}_1$, $d = 1.00$, 预测 ω_1 , 正确 $\rightarrow$ 保留在 $\mathcal{X}_G$ 。


步骤2: 考查 $\mathbf{x}_3 = (0, 1) \in \omega_1$ 。最近邻 $\mathbf{x}_1$, $d = 1.00$, 预测 ω_1 , 正确 $\rightarrow$ 保留。

步骤3: 考查 $\mathbf{x}_4 = (6, 6) \in \omega_2$ 。 $\mathcal{X}_S = \{\mathbf{x}_1\}$ 中最近邻为 $\mathbf{x}_1$, $d = 8.49$, 预测 ω_1 , 错误! $\rightarrow$ 将 $\mathbf{x}_4$ 移入 $\mathcal{X}_S$ 。此时 $\mathcal{X}_S = \{\mathbf{x}_1, \mathbf{x}_4\}$ 。

步骤4: 考查 $\mathbf{x}_5 = (7, 6) \in \omega_2$ 。现在 $\mathcal{X}_S = \{\mathbf{x}_1, \mathbf{x}_4\}$, 计算: $d(\mathbf{x}_5, \mathbf{x}_1) = 9.22$, $d(\mathbf{x}_5, \mathbf{x}_4) = 1.00$ 。最近邻为 $\mathbf{x}_4 \in \omega_2$, 预测 ω_2 , 正确 $\rightarrow$ 保留。

步骤5: 考查 $\mathbf{x}_6 = (6, 7) \in \omega_2$ 。 $d(\mathbf{x}_6, \mathbf{x}_1) = 9.22$, $d(\mathbf{x}_6, \mathbf{x}_4) = 1.00$ 。最近邻 $\mathbf{x}_4$, 预测 ω_2 , 正确 $\rightarrow$ 保留。

第1轮结束: $\mathcal{X}_S = \{\mathbf{x}_1, \mathbf{x}_4\}$, $\mathcal{X}_G = \{\mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_5, \mathbf{x}_6\}$



8.2.5 压缩近邻法

■ 计算示例

第2轮扫描


逐一考查 $\mathcal{X}_G$ 中所有样本，均被 $\mathcal{X}_S = \{\mathbf{x}_1, \mathbf{x}_4\}$ 正确分类，无需移动。算法终止。

最终结果

$$\mathcal{X}_S = \{\mathbf{x}_1(0, 0), \mathbf{x}_4(6, 6)\}$$

■ 总结

- 从 6 个样本压缩到 2 个代表样本 (每类1个)，压缩率 67%
- 用这 2 个代表样本进行最近邻分类，可以正确分类所有原始样本




8.2.5 压缩近邻法

■ 例题

题目：在压缩近邻法中，当前储存集为

$$\mathcal{X}_S = \{\mathbf{s}_1 = (1, 1) \in \omega_1, \mathbf{s}_2 = (6, 5) \in \omega_2\}$$

备选集中有样本 $\mathbf{x} = (3, 2)$ ，其真实类别为 ω_2 。采用欧氏距离，判断 $\mathbf{x}$ 是否应移入储存集 $\mathcal{X}_S$ ，并说明理由。



8.2.5 压缩近邻法

■ 例题解答

计算 $\boldsymbol{x}$ 到 $\mathcal{X}_S$ 中各样本的欧氏距离：

$$d(\boldsymbol{x}, \boldsymbol{s}_1) = \sqrt{(3-1)^2 + (2-1)^2} = \sqrt{5} \approx 2.24$$

$$d(\boldsymbol{x}, \boldsymbol{s}_2) = \sqrt{(3-6)^2 + (2-5)^2} = \sqrt{18} = 3\sqrt{2} \approx 4.24$$

因为 $d(\boldsymbol{x}, \boldsymbol{s}_1) < d(\boldsymbol{x}, \boldsymbol{s}_2)$ ，最近邻为 $\boldsymbol{s}_1 \in \omega_1$ ，预测类别为 ω_1 。

而 $\boldsymbol{x}$ 的真实类别为 ω_2 ，分类错误，因此应将 $\boldsymbol{x}$ 移入储存集 $\mathcal{X}_S$ 。

8.3.2 决策树

- 人类日常进行的树状决策过程
 - 医生判断患者是否感冒
 - 树状决策过程是根据专业知识或多年积累的常识进行的



8.3.2 决策树

■ 决策树构成

- **根节点**：包含全部样本，选择最优特征进行第一次划分
- **内部节点**：选择一个特征，定义划分条件（如“年龄 < 30?”）
- **分支**：划分条件的每个可能取值对应一条分支
- **叶节点**：不再划分，直接给出类别标签
- 决策树的构建过程就是选取特征和确定决策规则的过程

🤔 这棵决策树是如何构造出来的？




8.3.2 决策树

潜在客户分析

- 将年龄特征分为两档
- 将收入特征分为三档
- 正样本 (“是”) 共 4 例
- 负样本 (“否”) 共 12 例
- 根据年龄、性别、月收入三个特征进行分类
- **第一步**：确定第一步用哪个特征构造根节点

顾客编号	年龄	性别	月收入/元	是否购买
1	<30	男	中	否
2	≥30	女	中	否
3	≥30	女	中	否
4	≥30	女	低	否
5	<30	男	高	否
6	≥30	女	低	否
7	<30	女	低	否
8	<30	女	高	是
9	≥30	男	中	是
10	<30	男	高	否
11	≥30	女	中	否
12	<30	男	低	否
13	≥30	女	中	否
14	≥30	男	低	是
15	≥30	男	中	是
16	≥30	女	低	否




8.3.2 决策树

■ ID3 方法

- 如果一个事件有 k 种可能的结果，每种结果对应的概率为 $P_i, i = 1, \dots, k$ ，则得到的信息量可以用香农熵度量：

$$I = -(P_1 \log_2 P_1 + P_2 \log_2 P_2 + \dots + P_k \log_2 P_k) = - \sum_{i=1}^k P_i \log_2 P_i \quad (8-10)$$

- 公式意义：在决策树中，熵用于反映该节点上的特征对样本分类的不纯度



8.3.2 决策树

- ID3 方法

- 香农熵的计算:

$$I = -(P_1 \log_2 P_1 + P_2 \log_2 P_2 + \cdots + P_k \log_2 P_k) = -\sum_{i=1}^k P_i \log_2 P_i \quad (8-10)$$

- 若 $k = 4$, 四类的概率均为 0.25, 则:


$$I = -(4 \times 0.25 \times \log_2 0.25) = 2$$

- 此时样本不纯度最大, 即不确定性最大

- 若 $k = 4$, 其中一类的概率为 1, 其余三类概率都是 0, 则:

$$I = -(1 \times \log_2 1) = 0$$

- 此时样本纯度最大, 没有不确定性




8.3.2 决策树

- 构建决策树根节点

- 根据样本数据，在不考虑任何特征时，16 人中有 4 人买车，12 人不买车，此时的熵不纯度为：

$$I(16, 4) = - \left[\frac{4}{16} \log_2 \left(\frac{4}{16} \right) + \frac{12}{16} \log_2 \left(\frac{12}{16} \right) \right] \approx 0.8113$$

- $I(16, 4)$ 表示总共 16 个样本中 4 个为一类，12 个为另一类时的熵不纯度
- 目的：找到一个能够最有效地划分买车与不买车两类的特征，即引入该特征后，使熵不纯度最有效地减少




8.3.2 决策树

- 构建决策树根节点

- 分别计算将年龄、性别或月收入作为特征划分样本后的熵不纯度减少量 (信息增益):
- 选择年龄作为根节点:
 - 将所有样本分为两组
 - 30 岁以下组有 6 人, 1 人购车
 - 30 岁以上组有 10 人, 3 人购车
 - 总熵不纯度 (两组熵不纯度按照样本比例加权平均):

$$I_{\text{age}} = \frac{6}{16} I(6, 1) + \frac{10}{16} I(10, 3) = 0.7946$$



8.3.2 决策树

- 构建决策树根节点

- 选择年龄作为根节点：

- 信息增益为：

- $$\Delta I_{\text{age}} = I(16, 4) - I_{\text{age}} = 0.8113 - 0.7946 = 0.0167$$

- 同理，选择性别特征作为根节点：

- 信息增益为：


信息增益最大，作为根节点

- $$\Delta I_{\text{gender}}(16) = I(16, 4) - I_{\text{gender}} = 0.0972$$

- 选择月收入特征作为根节点：

- 信息增益为：

- $$\Delta I_{\text{income}}(16) = I(16, 4) - I_{\text{income}} = 0.0177$$



8.3.2 决策树

- 构建决策树根节点

- 选择年龄作为根节点：

- 信息增益为：

- $$\Delta I_{\text{age}} = I(16, 4) - I_{\text{age}} = 0.8113 - 0.7946 = 0.0167$$

- 同理，选择性别特征作为根节点：

- 信息增益为：

信息增益最大，作为根节点

- $$\Delta I_{\text{gender}}(16) = I(16, 4) - I_{\text{gender}} = 0.0972$$

- 选择月收入特征作为根节点：


- 信息增益为：

- $$\Delta I_{\text{income}}(16) = I(16, 4) - I_{\text{income}} = 0.0177$$

8.3.2 决策树

- 构建决策树根节点
 - 选择性别特征作为根节点：
 - 全部 16 个样本被按照性别特征分成了两组
 - 女性组有 9 个样本，其中 1 人购车
 - 男性组有 7 个样本，其中 3 人购车





8.3.2 决策树

- 构建决策树下一层节点

- 对于女性组和男性组，用与上面相同的方法，分别考查两组样本上如果再采用年龄或月收入作为特征所得到的信息增益
 - 对于男性组，采用年龄特征后熵不纯度减少最大，为0.9852
 - 对于女性组，采用月收入作为特征后熵不纯度减少最大，为0.688
- 分别用这两个特征构建下一级的决策树节点
- 此时，第二层划分之后产生的所有子节点，样本类别已经纯净，这一级节点为叶节点
- 决策树构建完成

8.3.2 决策树

■ 流程总结

- 1. 根据公式 8-10 计算当前节点包含的所有样本的熵不纯度
- 2. 比较采用不同特征进行分枝将会得到的信息增益
- 3. 选取具有最大信息增益的特征赋予当前节点，该特征的取值数目决定该节点下的分枝数目




8.3.2 决策树

■ 流程总结

- 4. 如果后继节点只包含一类样本，则停止该枝的生长，该节点成为叶节点
- 5. 如果后继节点仍包含不同类样本，则再次进行上述步骤，直至每一枝都到达叶节点为止





8.3.2 决策树

- 不纯度度量方法

- 香农熵:


$$I = -(P_1 \log_2 P_1 + P_2 \log_2 P_2 + \cdots + P_k \log_2 P_k) = -\sum_{i=1}^k P_i \log_2 P_i \quad (8-10)$$

- Gini 不纯度 (方差不纯度):

$$I(N) = \sum_{m \neq n} P(\omega_m)P(\omega_n) = 1 - \sum_{j=1}^k P^2(\omega_j) \quad (8-12)$$

- 误差不纯度:

$$I(N) = 1 - \max_j P(\omega_j) \quad (8-13)$$



8.3.2 决策树

- 不纯度度量方法计算

- 16 人中有 4 人买车, 12 人不买车

- 香农熵:

$$I(16, 4) = - \left[\frac{4}{16} \log_2 \left(\frac{4}{16} \right) + \frac{12}{16} \log_2 \left(\frac{12}{16} \right) \right] \approx 0.8113$$


- Gini 不纯度 (方差不纯度):

$$I(N) = 1 - \sum_{j=1}^k P^2(\omega_j) = 1 - \left(\frac{4}{16} \right)^2 - \left(\frac{12}{16} \right)^2 = 0.375$$

- 误差不纯度:

$$I(N) = 1 - \max_j P(\omega_j) = 1 - \frac{12}{16} = 0.25$$

-  多数情况下, 采用不同的不纯度度量方法对分类结果的影响不大



8.3.2 决策树

- ID3 算法改进

- C4.5 算法


- ID3 算法采用的信息增益偏好取值数目多的特征
- 采用信息增益率代替信息增益：

$$\Delta I_R(A) = \frac{\Delta I_A}{H_s(A)} \quad (8-14)$$

- 其中 ΔI_A 为特征 A 的信息增益， $H_s(A)$ 为特征 A 的固有熵（“特征 A 将数据分成若干份”这个划分本身的信息量）：

$$H_s(A) = - \sum_{v=1}^V \frac{N_v}{N} \log_2 \frac{N_v}{N}$$

- V 为特征 A 的取值数目， N 为当前节点的样本总数， N_v 为特征 A 取第 v 个值的样本数



8.3.2 决策树


- ID3 算法改进

- C4.5 算法

- 能够处理连续数值特征

- 做法

- 数值特征在训练集上共包含 n 个取值，将其按从小到大的顺序排序
 - 用二分法选择阈值，共 $n - 1$ 种可能的划分方案
 - 对每一种方案计算信息增益率，选择信息增益率最大的方案把该连续特征离散化为二值特征



8.3.2 决策树


- ID3 算法改进

- 分类和回归树 (CART) 算法

- 选择使划分后基尼不纯度加权和最小的特征及划分点

$$I(N) = \sum_{m \neq n} P(\omega_m)P(\omega_n) = 1 - \sum_{j=1}^k P^2(\omega_j) \quad (8-12)$$


- 在每一个节点上都采用二分法，即每个节点都只能有两个子节点，最终构成二叉树
- 既可用于分类问题，也可用于回归问题。回归时，叶节点输出均值，划分准则改为最小化均方误差



8.3.2 决策树

算法比较

比较维度	ID3	C4.5	CART
划分准则	信息增益	信息增益率	基尼不纯度
适用任务	分类	分类	分类 + 回归
树的结构	多叉树	多叉树	严格二叉树
特征类型	仅离散特征	离散 + 连续	离散 + 连续




8.3.2 决策树

例题 1

题目：给定数据集 D ，包含8个样本，特征 A 有三个取值 $\{a_1, a_2, a_3\}$ ，类别为 $\{\omega_1, \omega_2\}$ 。

样本	1	2	3	4	5	6	7	8
特征A	a_1	a_1	a_1	a_2	a_2	a_3	a_3	a_3
类别	ω_1	ω_1	ω_1	ω_1	ω_2	ω_2	ω_2	ω_2

请分别计算按特征 A 划分的信息增益 ΔI_A 、信息增益率 $\Delta I_R(A)$ ，以及 Gini 不纯度下降量。



8.3.2 决策树

■ 例题 1 解答

第一步：根节点的香农熵和 **Gini** 不纯度


8个样本， $\omega_1:4$ ， $\omega_2:4$ 。

$$I(8, 4) = -\frac{4}{8} \log_2 \frac{4}{8} - \frac{4}{8} \log_2 \frac{4}{8} = 1.0000$$

$$Gini(D) = 1 - \left(\frac{4}{8}\right)^2 - \left(\frac{4}{8}\right)^2 = 0.5000$$

$$I = -(P_1 \log_2 P_1 + P_2 \log_2 P_2 + \cdots + P_k \log_2 P_k) = -\sum_{i=1}^k P_i \log_2 P_i \quad (8-10)$$

$$I(N) = \sum_{m \neq n} P(\omega_m)P(\omega_n) = 1 - \sum_{j=1}^k P^2(\omega_j) \quad (8-12)$$



8.3.2 决策树

例题 1 解答

第二步：各子集

$A = a_1$: 3个样本 ($\omega_1:3, \omega_2:0$) , 纯 ω_1 类

$$I(3, 3) = 0, \quad Gini(a_1) = 0$$

$A = a_2$: 2个样本 ($\omega_1:1, \omega_2:1$)

$$I(2, 1) = -\frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{2} \log_2 \frac{1}{2} = 1.0000, \quad Gini(a_2) = 1 - \frac{1}{4} - \frac{1}{4} = 0.5000$$

$A = a_3$: 3个样本 ($\omega_1:0, \omega_2:3$) , 纯 ω_2 类

$$I(3, 0) = 0, \quad Gini(a_3) = 0$$

8.3.2 决策树

例题 1 解答

第三步：信息增益

$$I_A = \frac{3}{8} \times 0 + \frac{2}{8} \times 1.0 + \frac{3}{8} \times 0 = 0.2500$$

$$\Delta I_A = I(8, 4) - I_A = 1.0000 - 0.2500 = 0.7500$$


第四步：信息增益率

特征 A 的固有熵：

$$H_s(A) = - \sum_{v=1}^V \frac{N_v}{N} \log_2 \frac{N_v}{N} \quad H_s(A) = -\frac{3}{8} \log_2 \frac{3}{8} - \frac{2}{8} \log_2 \frac{2}{8} - \frac{3}{8} \log_2 \frac{3}{8} = 1.5613$$

$$\Delta I_R(A) = \frac{\Delta I_A}{H_s(A)} \quad (8-14)$$

$$\Delta I_R(A) = \frac{\Delta I_A}{H_s(A)} = \frac{0.7500}{1.5613} = 0.4804$$



8.3.2 决策树

■ 例题 1 解答

第五步: **Gini** 不纯度下降量

$$Gini(D|A) = \frac{3}{8} \times 0 + \frac{2}{8} \times 0.5000 + \frac{3}{8} \times 0 = 0.1250$$

$$\Delta Gini(A) = Gini(D) - Gini(D|A) = 0.5000 - 0.1250 = 0.3750$$


题目： 给定数据集 D ，包含10个样本和两个特征。特征 A 有2个取值 $\{a_1, a_2\}$ ，特征 B 有2个取值 $\{b_1, b_2\}$ ，类别为 $\{\omega_1, \omega_2\}$ 。

样本	A	B	类别
1	a_1	b_1	ω_1
2	a_1	b_1	ω_1
3	a_2	b_1	ω_1
4	a_2	b_1	ω_1
5	a_2	b_2	ω_1
6	a_2	b_1	ω_2
7	a_2	b_2	ω_2
8	a_2	b_2	ω_2
9	a_2	b_2	ω_2
10	a_2	b_2	ω_2

请分别使用 ID3（信息增益）、C4.5（信息增益率）、CART（Gini 不纯度）选择最优划分特征作为根节点，并比较三者的结果是否一致。



例题2



8.3.2 决策树


■ 例题 2 解答

第一步：计算根节点的香农熵和 **Gini** 不纯度

10个样本， $\omega_1:5$ ， $\omega_2:5$ 。

$$I(10, 5) = -\frac{5}{10} \log_2 \frac{5}{10} - \frac{5}{10} \log_2 \frac{5}{10} = 1.0000$$

$$Gini(D) = 1 - \left(\frac{5}{10}\right)^2 - \left(\frac{5}{10}\right)^2 = 0.5000$$



8.3.2 决策树

■ 例题 2 解答

第二步：计算按特征 A 划分的信息增益


$A = a_1$: 2个样本 ($\omega_1:2, \omega_2:0$) , 纯 ω_1 类, $I(a_1) = 0$

$A = a_2$: 8个样本 ($\omega_1:3, \omega_2:5$)

$$I(a_2) = -\frac{3}{8} \log_2 \frac{3}{8} - \frac{5}{8} \log_2 \frac{5}{8} = 0.9544$$

$$I_A = \frac{2}{10} \times 0 + \frac{8}{10} \times 0.9544 = 0.7635$$

$$\Delta I_A = I(10, 5) - I_A = 1.0000 - 0.7635 = 0.2365$$



8.3.2 决策树

例题 2 解答

第三步：计算按特征 B 划分的信息增益

$B = b_1$: 5个样本 ($\omega_1:4, \omega_2:1$)

$$I(b_1) = -\frac{4}{5} \log_2 \frac{4}{5} - \frac{1}{5} \log_2 \frac{1}{5} = 0.7219$$


$B = b_2$: 5个样本 ($\omega_1:1, \omega_2:4$)

$$I(b_2) = -\frac{1}{5} \log_2 \frac{1}{5} - \frac{4}{5} \log_2 \frac{4}{5} = 0.7219$$

$$I_B = \frac{5}{10} \times 0.7219 + \frac{5}{10} \times 0.7219 = 0.7219$$

$$\Delta I_B = 1.0000 - 0.7219 = 0.2781$$

ID3 结论: $\Delta I_B = 0.2781 > \Delta I_A = 0.2365$, ID3 选择特征 B 。



8.3.2 决策树

■ 例题 2 解答

第四步：计算信息增益率

$$H_s(A) = -\frac{2}{10} \log_2 \frac{2}{10} - \frac{8}{10} \log_2 \frac{8}{10} = 0.7219$$

$$\Delta I_R(A) = \frac{\Delta I_A}{H_s(A)} = \frac{0.2365}{0.7219} = 0.3275$$

$$H_s(B) = -\frac{5}{10} \log_2 \frac{5}{10} - \frac{5}{10} \log_2 \frac{5}{10} = 1.0000$$

$$\Delta I_R(B) = \frac{\Delta I_B}{H_s(B)} = \frac{0.2781}{1.0000} = 0.2781$$

C4.5 结论： $\Delta I_R(A) = 0.3275 > \Delta I_R(B) = 0.2781$ ，C4.5 选择特征 A 。

第五步：计算 **Gini** 不纯度下降量

$$A = a_1: Gini(a_1) = 0$$

$$A = a_2: Gini(a_2) = 1 - \left(\frac{3}{8}\right)^2 - \left(\frac{5}{8}\right)^2 = 0.4688$$

$$Gini(D|A) = \frac{2}{10} \times 0 + \frac{8}{10} \times 0.4688 = 0.3750$$

$$\Delta Gini(A) = 0.5000 - 0.3750 = 0.1250$$


$$B = b_1: Gini(b_1) = 1 - \left(\frac{4}{5}\right)^2 - \left(\frac{1}{5}\right)^2 = 0.3200$$

$$B = b_2: Gini(b_2) = 1 - \left(\frac{1}{5}\right)^2 - \left(\frac{4}{5}\right)^2 = 0.3200$$

$$Gini(D|B) = \frac{5}{10} \times 0.3200 + \frac{5}{10} \times 0.3200 = 0.3200$$

$$\Delta Gini(B) = 0.5000 - 0.3200 = 0.1800$$

CART 结论： $\Delta Gini(B) = 0.1800 > \Delta Gini(A) = 0.1250$ ，**CART** 选择特征 B 。



8.3.2 决策树

■ 例题 2 解答


第六步：汇总与分析


准则	特征A	特征B	最优特征
ΔI (ID3)	0.2365	0.2781	B
ΔI_R (C4.5)	0.3275	0.2781	A
$\Delta Gini$ (CART)	0.1250	0.1800	B

8.3.4 随机森林

定义

- 建立很多棵决策树，组成一个决策树的“森林”，通过多棵树投票进行决策





8.3.4 随机森林

- Bootstrap (自举)


- 基本思想

- 对现有样本进行重采样产生多个样本集

- 重采样：每次从原来的 N 个训练样本中有放回地随机抽取 N 个样本（包括可能的重复样本）

- 用于模拟数据中的随机性

- 并在最后的结果中考虑随机性的影响



8.3.4 随机森林

■ 算法流程

- 1. 对样本数据进行**自举重采样**，得到多个样本集
- 2. 每个重采样样本子集分别作为训练数据，构造一棵决策树
 - 每个节点分裂时，从全部 d 个候选特征中随机抽取 m 个特征 ($m \ll d$)
 - 仅从这 m 个特征中选择最优的一个作为该节点的分裂特征
- 3. 得到所需数目的决策树后，对这些树的输出进行投票，以得票最多的类作为随机森林的决策