



第十章 特征提取与降 维表示





10.1 引言

- 特征选择


- 从 D 维特征中选出 $d (< D)$ 个特征

- 特征提取 (或称特征变换)

- 从 D 维特征中通过一定的数学运算得到一组新特征

- 目的

- 降低特征空间的维数, 简化计算
 - 消除特征之间可能存在的相关性
 - 减少特征中与分类无关的信息, 使新的特征更有利于分类



10.1 引言

- 线性特征变换

- $\mathbf{x} \in \mathbb{R}^D$ 为 D 维原始特征, 变换后的 d 维新特征 $\mathbf{y} \in \mathbb{R}^d$ 为:

$$\mathbf{y} = \mathbf{W}^T \mathbf{x}$$

- 其中 $\mathbf{W} \in \mathbb{R}^{D \times d}$

- 特征提取任务

- 根据训练样本求出最优的 $\mathbf{W}^*$, 使得类别可分性最大

10.2 基于类别可分性判据的特征提取

- 问题定义

- 求出最优的 $\mathbf{W}^*$ 使得：

$$\mathbf{W}^* = \arg \max_{\mathbf{W}} J(\mathbf{W}^T \mathbf{x})$$

- 其中， $J(\cdot)$ 是第 9 章介绍的基于类内类间距离的类别可分性判据函数、基于概率分布的可分性判据函数、基于熵的可分性判据函数

回顾 9.2.1 基于类内类间距离的可分性判据

■ 将公式 9-5 写成矩阵形式:

- 定义加权类间离散度矩阵 $\tilde{S}_b$ ，用于度量各类均值之间的分散程度:

$$\tilde{S}_b = \sum_{i=1}^c P_i (\mathbf{m}_i - \mathbf{m})(\mathbf{m}_i - \mathbf{m})^T \quad (9-7)$$

- 定义加权类内离散度矩阵 $\tilde{S}_w$ ，用于度量各类内部样本的分散程度:

$$\tilde{S}_w = \sum_{i=1}^c P_i \cdot \frac{1}{n_i} \sum_{k=1}^{n_i} \left(\mathbf{x}_k^{(i)} - \mathbf{m}_i \right) \left(\mathbf{x}_k^{(i)} - \mathbf{m}_i \right)^T \quad (9-8)$$

内层就是第 i 类的样本协方差矩阵

外层得到所有类别内部离散度的加权平均

回顾 9.2.1 基于类内类间距离的可分性判据

- 将公式 9-5 写成矩阵形式:

$$J_d(\mathbf{x}) = \sum_{i=1}^c P_i \left[\frac{1}{n_i} \sum_{k=1}^{n_i} \left(\mathbf{x}_k^{(i)} - \mathbf{m}_i \right)^T \left(\mathbf{x}_k^{(i)} - \mathbf{m}_i \right) + (\mathbf{m}_i - \mathbf{m})^T (\mathbf{m}_i - \mathbf{m}) \right] \quad (9-5)$$

- 平均平方距离判据矩阵形式:

$$J_1 = J_d(\mathbf{x}) = \text{tr}(\tilde{\mathbf{S}}_w + \tilde{\mathbf{S}}_b)$$

回顾 9.2.1 基于类内类间距离的可分性判据

- 其它类似的基于类内类间距离的判据:

$$J_2 = \text{tr}(\tilde{\mathbf{S}}_w^{-1} \tilde{\mathbf{S}}_b)$$

$$J_3 = \ln \frac{\det(\tilde{\mathbf{S}}_b)}{\det(\tilde{\mathbf{S}}_w)} \text{ 行列式}$$

$$J_4 = \frac{\text{tr} \tilde{\mathbf{S}}_b}{\text{tr} \tilde{\mathbf{S}}_w}$$

$$J_5 = \frac{\det(\tilde{\mathbf{S}}_b - \tilde{\mathbf{S}}_w)}{\det(\tilde{\mathbf{S}}_w)}$$

-  不同判据计算的数值虽不同，但对特征的排序相同

10.2 基于类别可分性判据的特征提取

- 采取基于类内类间距离的可分性判据
 - 特征变换 $\mathbf{y} = \mathbf{W}^T \mathbf{x}$ 将原始空间的样本映射到低维空间, 则有:

- 第 i 类在新空间的均值:

$$\mathbf{m}_i^{(y)} = \mathbf{W}^T \mathbf{m}_i$$

- 总体均值:

$$\mathbf{m}^{(y)} = \mathbf{W}^T \mathbf{m}$$

- 第 i 类样本 k 在新空间的表示:

$$\mathbf{y}_k^{(i)} = \mathbf{W}^T \mathbf{x}_k^{(i)}$$

10.2 基于类别可分性判据的特征提取

- 采取基于类内类间距离的可分性判据

- 原始空间加权类间离散度矩阵 $\tilde{S}_b$:

$$\boxed{\tilde{S}_b} = \sum_{i=1}^c P_i (\mathbf{m}_i - \mathbf{m})(\mathbf{m}_i - \mathbf{m})^T \quad (9-7)$$

- 转换空间加权类间离散度矩阵 $\tilde{S}_b^{(y)}$:

$$\tilde{S}_b^{(y)} = \sum_{i=1}^c P_i (\mathbf{m}_i^{(y)} - \mathbf{m}^{(y)})(\mathbf{m}_i^{(y)} - \mathbf{m}^{(y)})^T$$

代入

$$= \sum_{i=1}^c P_i (\mathbf{W}^T (\mathbf{m}_i - \mathbf{m}))(\mathbf{W}^T (\mathbf{m}_i - \mathbf{m}))^T$$

展开最后一项转置

$$= \sum_{i=1}^c P_i \mathbf{W}^T (\mathbf{m}_i - \mathbf{m})(\mathbf{m}_i - \mathbf{m})^T \mathbf{W}$$

提出 $\mathbf{W}^T$ 和 $\mathbf{W}$
替换

$$= \mathbf{W}^T \left[\sum_{i=1}^c P_i (\mathbf{m}_i - \mathbf{m})(\mathbf{m}_i - \mathbf{m})^T \right] \mathbf{W}$$
$$= \mathbf{W}^T \boxed{\tilde{S}_b} \mathbf{W}$$

10.2 基于类别可分性判据的特征提取

- 采取基于类内类间距离的可分性判据

- 原始空间加权类内离散度矩阵 $\tilde{S}_w$:

$$\tilde{S}_w = \sum_{i=1}^c P_i \cdot \frac{1}{n_i} \sum_{k=1}^{n_i} (\mathbf{x}_k^{(i)} - \mathbf{m}_i) (\mathbf{x}_k^{(i)} - \mathbf{m}_i)^T \quad (9-8)$$

- 转换空间加权类内离散度矩阵 $\tilde{S}_w^{(y)}$:

$$\tilde{S}_w^{(y)} = \sum_{i=1}^c P_i \cdot \frac{1}{n_i} \sum_{k=1}^{n_i} (\mathbf{y}_k^{(i)} - \mathbf{m}_i^{(y)}) (\mathbf{y}_k^{(i)} - \mathbf{m}_i^{(y)})^T$$

代入

$$= \sum_{i=1}^c P_i \cdot \frac{1}{n_i} \sum_{k=1}^{n_i} (\mathbf{W}^T (\mathbf{x}_k^{(i)} - \mathbf{m}_i)) (\mathbf{W}^T (\mathbf{x}_k^{(i)} - \mathbf{m}_i))^T$$

展开最后一项转置

$$= \sum_{i=1}^c P_i \cdot \frac{1}{n_i} \sum_{k=1}^{n_i} \mathbf{W}^T (\mathbf{x}_k^{(i)} - \mathbf{m}_i) (\mathbf{x}_k^{(i)} - \mathbf{m}_i)^T \mathbf{W}$$

提出 $\mathbf{W}^T$ 和 $\mathbf{W}$
替换

$$= \mathbf{W}^T \left(\sum_{i=1}^c P_i \cdot \frac{1}{n_i} \sum_{k=1}^{n_i} (\mathbf{x}_k^{(i)} - \mathbf{m}_i) (\mathbf{x}_k^{(i)} - \mathbf{m}_i)^T \right) \mathbf{W}$$
$$= \mathbf{W}^T \tilde{S}_w \mathbf{W}$$

10.2 基于类别可分性判据的特征提取

- 采取基于类内类间距离的可分性判据

- $\tilde{\mathbf{S}}_b^{(y)} = \mathbf{W}^T \tilde{\mathbf{S}}_b \mathbf{W}$, $\tilde{\mathbf{S}}_w^{(y)} = \mathbf{W}^T \tilde{\mathbf{S}}_w \mathbf{W}$

- 替换判据函数 $J_1 - J_5$ 中的 $\tilde{\mathbf{S}}_b$ 和 $\tilde{\mathbf{S}}_w$:

$$J_1 = \text{tr}(\mathbf{W}^T (\tilde{\mathbf{S}}_w + \tilde{\mathbf{S}}_b) \mathbf{W})$$

$$J_2 = \text{tr}\left(\left(\mathbf{W}^T \tilde{\mathbf{S}}_w \mathbf{W}\right)^{-1} \left(\mathbf{W}^T \tilde{\mathbf{S}}_b \mathbf{W}\right)\right)$$

$$J_3 = \ln \frac{\det(\mathbf{W}^T \tilde{\mathbf{S}}_b \mathbf{W})}{\det(\mathbf{W}^T \tilde{\mathbf{S}}_w \mathbf{W})}$$

$$J_4 = \frac{\text{tr}(\mathbf{W}^T \tilde{\mathbf{S}}_b \mathbf{W})}{\text{tr}(\mathbf{W}^T \tilde{\mathbf{S}}_w \mathbf{W})}$$

$$J_5 = \frac{\det(\mathbf{W}^T (\tilde{\mathbf{S}}_w + \tilde{\mathbf{S}}_b) \mathbf{W})}{\det(\mathbf{W}^T \tilde{\mathbf{S}}_w \mathbf{W})}$$

- 目标: 求出最优的 $\mathbf{W}^*$ 使得 $\mathbf{W}^* = \text{argmax}_{\mathbf{W}} J(\mathbf{W}^T \mathbf{x})$

10.2 基于类别可分性判据的特征提取

- 采取基于类内类间距离的可分性判据

- 结论

- 矩阵 $\tilde{\mathbf{S}}_w^{-1}\tilde{\mathbf{S}}_b$ 本征值为 $\lambda_1, \lambda_2, \dots, \lambda_D$, 按大小排序为:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D$$

- 则选择前 d 个本征值对应的本征向量所构成的矩阵为最优变换矩阵 $\mathbf{W}^*$:

$$\mathbf{W}^* = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_d]$$

- 其中, μ_i 为第 i 个本征向量
- ⚠ 使用拉格朗日乘子法将有约束的优化问题变成无约束问题, 推导过程见教材公式 10-2 到 10-9

10.2 基于类别可分性判据的特征提取

- 本征值与本征向量

- 定义

- 对于方阵 A , 若存在非零向量 u 和标量 λ 满足:

$$Au = \lambda u$$

- 则 λ 为本征值, u 为本征向量

- 几何意义

- 矩阵作用于本征向量时, 只改变其长度 (缩放 λ 倍)

10.2 基于类别可分性判据的特征提取

- 求解本征值

- 非零解存在的条件为：

$$\det(\mathbf{A} - \lambda \mathbf{I}) = 0$$

- 矩阵 $A = \begin{pmatrix} 4 & 2 \\ 1 & 3 \end{pmatrix}$ ，根据上式：

$$\det \begin{pmatrix} 4 - \lambda & 2 \\ 1 & 3 - \lambda \end{pmatrix} = (4 - \lambda)(3 - \lambda) - 2 \times 1 = 0$$

- 展开得：

$$\lambda^2 - 7\lambda + 10 = 0$$

- 解得：

$$\lambda_1 = 5, \lambda_2 = 2$$

10.2 基于类别可分性判据的特征提取

■ 本征向量的求解

全 0 向量

- 将上一步计算出的本征值代入 $(A - \lambda I)\mathbf{u} = \mathbf{0}$ ，解齐次线性方程组得到对应特征向量

- 仍以矩阵 $A = \begin{pmatrix} 4 & 2 \\ 1 & 3 \end{pmatrix}$ 为例：

- 当 $\lambda_1 = 5$ 时：

$$(A - 5I)\mathbf{u} = \begin{pmatrix} -1 & 2 \\ 1 & -2 \end{pmatrix} \mathbf{u} = \mathbf{0}$$

- 由第一行得 $-u_1 + 2u_2 = 0$ ，即 $u_1 = 2u_2$ ，取：

$$\mathbf{u}_1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix} \quad \text{! 本征向量只需要确定方向，不需要唯一的具体数值}$$

10.2 基于类别可分性判据的特征提取

■ 本征向量的求解

- 将上一步计算出的本征值代入 $(A - \lambda I)\mathbf{u} = \mathbf{0}$ ，解齐次线性方程组得到对应特征向量

- 仍以矩阵 $A = \begin{pmatrix} 4 & 2 \\ 1 & 3 \end{pmatrix}$ 为例：

- 当 $\lambda_2 = 2$ 时：

$$(A - 2I)\mathbf{u} = \begin{pmatrix} 2 & 2 \\ 1 & 1 \end{pmatrix} \mathbf{u} = \mathbf{0}$$

- 由第一行得 $2u_1 + 2u_2 = 0$ ，即 $u_1 = -u_2$ ，取：

$$\mathbf{u}_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$$

10.2 基于类别可分性判据的特征提取

■ 例题

已知两类样本，先验概率相等 $P_1 = P_2 = \frac{1}{2}$ ，每类各有2个二维样本：

$$\omega_1 : \quad \mathbf{x}_1^{(1)} = \begin{pmatrix} 1 \\ 3 \end{pmatrix}, \quad \mathbf{x}_2^{(1)} = \begin{pmatrix} 3 \\ 1 \end{pmatrix}$$

$$\omega_2 : \quad \mathbf{x}_1^{(2)} = \begin{pmatrix} 5 \\ 3 \end{pmatrix}, \quad \mathbf{x}_2^{(2)} = \begin{pmatrix} 7 \\ 5 \end{pmatrix}$$

采用基于类别可分性判据的特征提取方法，将二维特征降至一维。

(1) 求各类样本均值 $\mathbf{m}_1$ 、 $\mathbf{m}_2$ 及总体均值 $\mathbf{m}$ 。

(2) 求原始空间加权类内离散度矩阵 $\tilde{S}_w$ 。

(3) 求原始空间加权类间离散度矩阵 $\tilde{S}_b$ 。

(4) 求矩阵 $\tilde{S}_w^{-1} \tilde{S}_b$ 。

(5) 求 $\tilde{S}_w^{-1} \tilde{S}_b$ 的本征值和本征向量。

(6) 写出最优变换向量 $\mathbf{W}^*$ ，并将各样本投影到一维空间。

⚠ 不使用向量
增广形式

10.2 基于类别可分性判据的特征提取

■ 例题求解

(1) 各类均值及总体均值

$$\mathbf{m}_1 = \frac{1}{2} \left[\begin{pmatrix} 1 \\ 3 \end{pmatrix} + \begin{pmatrix} 3 \\ 1 \end{pmatrix} \right] = \begin{pmatrix} 2 \\ 2 \end{pmatrix}$$

$$\mathbf{m}_2 = \frac{1}{2} \left[\begin{pmatrix} 5 \\ 3 \end{pmatrix} + \begin{pmatrix} 7 \\ 5 \end{pmatrix} \right] = \begin{pmatrix} 6 \\ 4 \end{pmatrix}$$

$$\mathbf{m} = P_1 \mathbf{m}_1 + P_2 \mathbf{m}_2 = \frac{1}{2} \begin{pmatrix} 2 \\ 2 \end{pmatrix} + \frac{1}{2} \begin{pmatrix} 6 \\ 4 \end{pmatrix} = \begin{pmatrix} 4 \\ 3 \end{pmatrix}$$

10.2 基于类别可分性判据的特

征提]

■ 例题求解

(2) 加权类内离散度矩阵 $\tilde{S}_w$

先计算各类离均差:

$$\mathbf{x}_1^{(1)} - \mathbf{m}_1 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}, \quad \mathbf{x}_2^{(1)} - \mathbf{m}_1 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

$$\mathbf{x}_1^{(2)} - \mathbf{m}_2 = \begin{pmatrix} -1 \\ -1 \end{pmatrix}, \quad \mathbf{x}_2^{(2)} - \mathbf{m}_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

第1类的类内散布:

$$\frac{1}{n_1} \sum_{k=1}^2 (\mathbf{x}_k^{(1)} - \mathbf{m}_1)(\mathbf{x}_k^{(1)} - \mathbf{m}_1)^T = \frac{1}{2} \left[\begin{pmatrix} -1 \\ 1 \end{pmatrix} (-1 \quad 1) + \begin{pmatrix} 1 \\ -1 \end{pmatrix} (1 \quad -1) \right] = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$$

第2类的类内散布:

$$\frac{1}{n_2} \sum_{k=1}^2 (\mathbf{x}_k^{(2)} - \mathbf{m}_2)(\mathbf{x}_k^{(2)} - \mathbf{m}_2)^T = \frac{1}{2} \left[\begin{pmatrix} -1 \\ -1 \end{pmatrix} (-1 \quad -1) + \begin{pmatrix} 1 \\ 1 \end{pmatrix} (1 \quad 1) \right] = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$$

加权求和:

$$\tilde{S}_w = P_1 \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix} + P_2 \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix} + \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

10.2 基于类别可分性判据的特征提取

■ 例题求解

(3) 加权类间离散度矩阵 $\tilde{S}_b$

$$\mathbf{m}_1 - \mathbf{m} = \begin{pmatrix} -2 \\ -1 \end{pmatrix}, \quad \mathbf{m}_2 - \mathbf{m} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$

$$\tilde{S}_b = P_1(\mathbf{m}_1 - \mathbf{m})(\mathbf{m}_1 - \mathbf{m})^T + P_2(\mathbf{m}_2 - \mathbf{m})(\mathbf{m}_2 - \mathbf{m})^T$$

$$= \frac{1}{2} \begin{pmatrix} -2 \\ -1 \end{pmatrix} (-2 \quad -1) + \frac{1}{2} \begin{pmatrix} 2 \\ 1 \end{pmatrix} (2 \quad 1) = \frac{1}{2} \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} + \frac{1}{2} \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} = \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix}$$

(4) 求 $\tilde{S}_w^{-1} \tilde{S}_b$

由于 $\tilde{S}_w = I$, 故 $\tilde{S}_w^{-1} = I$, 因此

$$\tilde{S}_w^{-1} \tilde{S}_b = I \cdot \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} = \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix}$$

10.2 基于类别可分性判据的特征提取

■ 例题求解

(5) 求本征值和本征向量

特征方程：

$$\det(\tilde{S}_w^{-1}\tilde{S}_b - \lambda I) = \det \begin{pmatrix} 4-\lambda & 2 \\ 2 & 1-\lambda \end{pmatrix} \overset{\text{一元二次方程 } ax^2 + bx + c = 0 (a \neq 0)}{=} (4-\lambda)(1-\lambda) - 4 = \lambda^2 - 5\lambda = 0$$

利用求根公式求解： $x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$

解得 $\lambda_1 = 5$, $\lambda_2 = 0$ 。

当 $\lambda_1 = 5$ 时：

$$(\tilde{S}_w^{-1}\tilde{S}_b - 5I)\mathbf{u} = \begin{pmatrix} -1 & 2 \\ 2 & -4 \end{pmatrix} \mathbf{u} = \mathbf{0} \implies u_1 = 2u_2, \quad \mathbf{u}_1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$

当 $\lambda_2 = 0$ 时：

$$\tilde{S}_w^{-1}\tilde{S}_b \mathbf{u} = \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} \mathbf{u} = \mathbf{0} \implies 2u_1 + u_2 = 0, \quad \mathbf{u}_2 = \begin{pmatrix} 1 \\ -2 \end{pmatrix}$$

10.2 基于类别可分性判据的特征提取

■ 例题求解

(6) 最优变换向量及投影


降至一维，取最大本征值 $\lambda_1 = 5$ 对应的本征向量：

$$W^* = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$

各样本投影 $y = W^{*T} \mathbf{x}$ ：

$$y_1^{(1)} = (2 \ 1) \begin{pmatrix} 1 \\ 3 \end{pmatrix} = 5, \quad y_2^{(1)} = (2 \ 1) \begin{pmatrix} 3 \\ 1 \end{pmatrix} = 7$$

$$y_1^{(2)} = (2 \ 1) \begin{pmatrix} 5 \\ 3 \end{pmatrix} = 13, \quad y_2^{(2)} = (2 \ 1) \begin{pmatrix} 7 \\ 5 \end{pmatrix} = 19$$



10.3 主成分分析 (PCA)

■ 动机

- 从原有组特征中计算出一组按重要性从大到小排列的新特征 (主成分)
- 新特征是原有特征的线性组合，并且特征之间互不相关
 - 特征之间互不相关是指：
 - 新特征（主成分）之间的协方差为零，即经 PCA 变换后的数据，其协方差矩阵是一个对角矩阵：


$$\Sigma_y = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_d \end{pmatrix}$$

回顾 2.5.1 正态分布及其性质回顾

- 多变量 (多元) 正态分布
 - 协方差矩阵

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1d} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2d} \\ \vdots & & \ddots & \vdots \\ \sigma_{d1} & \sigma_{d2} & \cdots & \sigma_{dd} \end{bmatrix}$$

- 对角线元素 $\sigma_{ii} = E[(x_i - \mu_i)^2]$: 第 i 个变量自身的方差
- 非对角线元素 $\sigma_{ij} = E[(x_i - \mu_i)(x_j - \mu_j)]$: 变量 i 与 j 的协方差
 - $\sigma_{ij} > 0$: 两变量正相关; $\sigma_{ij} < 0$: 负相关; $\sigma_{ij} = 0$: 线性无关



10.3 主成分分析 (PCA)


- 形式化定义

- 令 $\mathbf{x} = \{x_1, \dots, x_p\}$ 表示 p 个原始特征, 设每个新特征 ξ_i 是原始特征的线性组合:

$$\xi_i = \sum_{j=1}^p a_{ij} x_j = \mathbf{a}_i^T \mathbf{x} \quad (10-10)$$

- 为统一新特征的尺度, 要求特征变换向量 $\mathbf{a}_i$ 为一个单位向量 (模长为 1):

$$\mathbf{a}_i^T \mathbf{a}_i = \|\mathbf{a}_i\|^2 = \sum_{j=1}^d a_{ij}^2 = 1 \quad (10-11)$$



10.3 主成分分析 (PCA)

- 优化目标

- 依次求出各个特征变换向量 $\mathbf{a}_i$
- 每一步最大化新特征 ξ_i 的方差
 - 变量的方差越大，表明数据在该方向上的数据点越分散，区分度越高
- 同时满足与已求出的特征变换向量正交的约束
 - 原始变量间通常存在相关性，以此消除特征间的冗余

- 优化步骤

- 先求 $\mathbf{a}_1$ ，使第一主成分 $\xi_1 = \mathbf{a}_1^T \mathbf{x}$ 的方差最大
- 再求 $\mathbf{a}_2$ ，使 $\xi_2 = \mathbf{a}_2^T \mathbf{x}$ 在与 $\mathbf{a}_1$ 正交的约束下方差最大
- 依此类推

10.3 主成分分析 (PCA)

- 考虑第一个新特征 ξ_1
 - 方差公式推导

$$\text{var}(\xi_1) = E[(\xi_1 - E[\xi_1])^2]$$

展开平方项

$$= E[\xi_1^2 - 2\xi_1 E[\xi_1] + (E[\xi_1])^2]$$

利用期望的线性性质，展开大括号


$$= E[\xi_1^2] - \underline{E[2\xi_1 E[\xi_1]]} + \underline{E[(E[\xi_1])^2]}$$

$E[\xi_1]$ 是常数，提出 2 和 $E[\xi_1]$

$$\underline{E[2\xi_1 E[\xi_1]]} = 2E[\xi_1] \cdot E[\xi_1] = 2(E[\xi_1])^2$$

常数的期望等于其本身，
直接去掉最外层期望

$$E[(E[\xi_1])^2] = (E[\xi_1])^2$$



10.3 主成分分析 (PCA)

- 考虑第一个新特征 ξ_1

- 方差公式推导

$$\text{var}(\xi_1) = E[(\xi_1 - E[\xi_1])^2]$$

展开平方项

$$= E[\xi_1^2 - 2\xi_1 E[\xi_1] + (E[\xi_1])^2]$$

利用期望的线性性质，展开大括号

$$= E[\xi_1^2] - E[2\xi_1 E[\xi_1]] + E[(E[\xi_1])^2]$$

代入

$$= E[\xi_1^2] - 2(E[\xi_1])^2 + (E[\xi_1])^2$$

合并

$$= E[\xi_1^2] - (E[\xi_1])^2$$

10.3 主成分分析 (PCA)

- 考虑第一个新特征 ξ_1

- 方差计算

$$\text{var}(\xi_1) = E[\xi_1^2] - (E[\xi_1])^2$$

- 第一项:


- 由于 $\xi_1 = \mathbf{a}_1^T \mathbf{x}$ 是标量, 因此:

$$\xi_1^2 = (\mathbf{a}_1^T \mathbf{x})^2 = (\mathbf{a}_1^T \mathbf{x})(\mathbf{a}_1^T \mathbf{x}) = \mathbf{a}_1^T \mathbf{x} \mathbf{x}^T \mathbf{a}_1$$

- 取期望:

$$E[\xi_1^2] = E[\mathbf{a}_1^T \mathbf{x} \mathbf{x}^T \mathbf{a}_1] = \mathbf{a}_1^T E[\mathbf{x} \mathbf{x}^T] \mathbf{a}_1$$

! 期望与样本 $\mathbf{x}$ 有关



10.3 主成分分析 (PCA)

- 考虑第一个新特征 ξ_1

- 方差计算

$$\text{var}(\xi_1) = E[\xi_1^2] - (E[\xi_1])^2$$

- 第二项:


$$E[\xi_1] = E[\mathbf{a}_1^T \mathbf{x}] = \mathbf{a}_1^T E[\mathbf{x}]$$

- 取平方:

$$(E[\xi_1])^2 = (\mathbf{a}_1^T E[\mathbf{x}])^2 = \mathbf{a}_1^T E[\mathbf{x}] E[\mathbf{x}]^T \mathbf{a}_1$$

- 两项合并:

$$\begin{aligned} \text{var}(\xi_1) &= \mathbf{a}_1^T E[\mathbf{x} \mathbf{x}^T] \mathbf{a}_1 - \mathbf{a}_1^T E[\mathbf{x}] E[\mathbf{x}]^T \mathbf{a}_1 \\ &= \mathbf{a}_1^T (E[\mathbf{x} \mathbf{x}^T] - E[\mathbf{x}] E[\mathbf{x}]^T) \mathbf{a}_1 \end{aligned}$$



10.3 主成分分析 (PCA)

- 考虑第一个新特征 ξ_1


- 方差计算

- 引入协方差:

$$\boxed{\Sigma} = E[(\mathbf{x} - E[\mathbf{x}])(\mathbf{x} - E[\mathbf{x}])^T] = \underline{E[\mathbf{x}\mathbf{x}^T] - E[\mathbf{x}]E[\mathbf{x}]^T}$$

- 由此:

$$\begin{aligned}\text{var}(\xi_1) &= \mathbf{a}_1^T (\underline{E[\mathbf{x}\mathbf{x}^T] - E[\mathbf{x}]E[\mathbf{x}]^T}) \mathbf{a}_1 \\ &= \mathbf{a}_1^T \boxed{\Sigma} \mathbf{a}_1\end{aligned}\tag{10-14}$$



10.3 主成分分析 (PCA)


- 考虑第一个新特征 ξ_1
 - 在约束条件 $\mathbf{a}_1^\top \mathbf{a}_1 = 1$ 下最大化 $\text{var}(\xi_1)$
 - 采用拉格朗日乘子法
 - 构造拉格朗日函数：

$$L(\mathbf{a}_1, \lambda) = \mathbf{a}_1^\top \Sigma \mathbf{a}_1 - \lambda(\mathbf{a}_1^\top \mathbf{a}_1 - 1)$$

- 对 $\mathbf{a}_1$ 求偏导并令其为零：

$$\frac{\partial L}{\partial \mathbf{a}_1} = 2\Sigma \mathbf{a}_1 - 2\lambda \mathbf{a}_1 = \mathbf{0}$$

$$\frac{\partial}{\partial \mathbf{w}} (\mathbf{w}^\top A \mathbf{w}) = 2A\mathbf{w} \quad (A \text{ 对称})$$



10.3 主成分分析 (PCA)

- 考虑第一个新特征 ξ_1
 - 在约束条件 $\mathbf{a}_1^T \mathbf{a}_1 = 1$ 下最大化 $\text{var}(\xi_1)$
 - 采用拉格朗日乘子法


- 最优解满足本征值方程：

$$\Sigma \mathbf{a}_1 = \lambda \mathbf{a}_1 \quad (10-16)$$

- $\mathbf{a}_1$ 是协方差矩阵 Σ 的本征向量
 - λ 是对应的本征值
 - 带回目标函数：

$$\text{Var}(\xi_1) = \mathbf{a}_1^T \Sigma \mathbf{a}_1 = \lambda \mathbf{a}_1^T \mathbf{a}_1 = \lambda$$

- 公式含义：让目标函数最大等同于让本征值最大



10.3 主成分分析 (PCA)

- 考虑第一个新特征 ξ_1
 - 在约束条件 $\mathbf{a}_1^T \mathbf{a}_1 = 1$ 下最大化 $\text{var}(\xi_1)$
 - 采用拉格朗日乘子法
 - 最优解 $\mathbf{a}_1^*$ 是协方差矩阵 Σ 最大本征值对应的本征向量
 - ξ_1 称作第一主成分，它在原始特征的所有线性组合里方差最大

10.3 主成分分析 (PCA)

- 考虑第二个新特征 ξ_2
 - 需满足与 ξ_1 同样的要求 (方差最大、模长为 1)
 - 同时必须与第一主成分 ξ_1 不相关

标量 ■ 说明 ξ_2 与 ξ_1 协方差为零

$$\text{Cov}(\xi_2, \xi_1) = E[(\xi_2 - E[\xi_2])(\xi_1 - E[\xi_1])]$$

展开平方项 $\rightarrow = E[\xi_2\xi_1 - \xi_2E[\xi_1] - E[\xi_2]\xi_1 + E[\xi_2]E[\xi_1]]$

展开大括号 $\rightarrow = E[\xi_2\xi_1] - E[\xi_2] \cdot E[\xi_1] - E[\xi_2] \cdot E[\xi_1] + E[\xi_2]E[\xi_1]$

合并 $\rightarrow = E[\xi_2\xi_1] - E[\xi_2]E[\xi_1]$

10.3 主成分分析 (PCA)

- 考虑第二个新特征 ξ_2
 - 需满足与 ξ_1 同样的要求 (方差最大、模长为 1)
 - 同时必须与第一主成分 ξ_1 不相关
 - 说明 ξ_2 与 ξ_1 协方差为零

$$\text{Cov}(\xi_2, \xi_1) = E[\xi_2 \xi_1] - E[\xi_2]E[\xi_1] = 0$$

- 第一项

$$\begin{aligned} E[\xi_2 \xi_1] &= E[(\mathbf{a}_2^T \mathbf{x})(\mathbf{a}_1^T \mathbf{x})] \\ &= E[\mathbf{a}_2^T \mathbf{x} \mathbf{x}^T \mathbf{a}_1] \\ &= \mathbf{a}_2^T E[\mathbf{x} \mathbf{x}^T] \mathbf{a}_1 \end{aligned}$$




10.3 主成分分析 (PCA)

- 考虑第二个新特征 ξ_2
 - 需满足与 ξ_1 同样的要求 (方差最大、模长为 1)
 - 同时必须与第一主成分 ξ_1 不相关
 - 说明 ξ_2 与 ξ_1 协方差为零

$$\text{Cov}(\xi_2, \xi_1) = E[\xi_2 \xi_1] - \boxed{E[\xi_2] E[\xi_1]} = 0$$

■ 第二项

$$\begin{aligned} E[\xi_2] E[\xi_1] &= E[\mathbf{a}_2^T \mathbf{x}] E[\mathbf{a}_1^T \mathbf{x}] \\ &= \mathbf{a}_2^T E[\mathbf{x}] E[\mathbf{x}^T \mathbf{a}_1] \\ &= \mathbf{a}_2^T E[\mathbf{x}] E[\mathbf{x}]^T \mathbf{a}_1 \end{aligned}$$



10.3 主成分分析 (PCA)

- 考虑第二个新特征 ξ_2
 - 需满足与 ξ_1 同样的要求 (方差最大、模长为 1)
 - 同时必须与第一主成分 ξ_1 不相关
 - 说明 ξ_2 与 ξ_1 协方差为零

$$\text{Cov}(\xi_2, \xi_1) = E[\xi_2 \xi_1] - E[\xi_2]E[\xi_1] = 0$$

- 两项合并

$$\begin{aligned}\text{Cov}(\xi_2, \xi_1) &= \mathbf{a}_2^T E[\mathbf{x}\mathbf{x}^T] \mathbf{a}_1 - \mathbf{a}_2^T E[\mathbf{x}] E[\mathbf{x}]^T \mathbf{a}_1 \\ &= \mathbf{a}_2^T \left(\underline{E[\mathbf{x}\mathbf{x}^T] - E[\mathbf{x}] E[\mathbf{x}]^T} \right) \mathbf{a}_1 \\ &= \mathbf{a}_2^T \underline{\Sigma} \mathbf{a}_1 = 0\end{aligned}$$

10.3 主成分分析 (PCA)

- 考虑第二个新特征 ξ_2
 - 需满足与 ξ_1 同样的要求 (方差最大、模长为 1)
 - 同时必须与第一主成分 ξ_1 不相关
 - 不相关的要求等价于 $\mathbf{a}_2$ 与 $\mathbf{a}_1$ 正交

$$\text{Cov}(\xi_2, \xi_1) = E[\xi_2 \xi_1] - E[\xi_2]E[\xi_1] = 0$$

- 将 $\mathbf{a}_2^T \Sigma \mathbf{a}_1 = 0$ 代入公式 10-16:

$$\Sigma \mathbf{a}_1 = \lambda \mathbf{a}_1 \tag{10-16}$$

- 得到:

$$\mathbf{a}_2^T \Sigma \mathbf{a}_1 = \mathbf{a}_2^T (\lambda \mathbf{a}_1) = \lambda (\mathbf{a}_2^T \mathbf{a}_1) = 0 \Rightarrow \boxed{\mathbf{a}_2^T \mathbf{a}_1 = 0}$$

说明 $\mathbf{a}_2$ 与 $\mathbf{a}_1$ 正交

10.3 主成分分析 (PCA)

- 考虑第二个新特征 ξ_2
 - 在约束条件 $\mathbf{a}_2^\top \mathbf{a}_2 = 1$ 和 $\mathbf{a}_2^\top \mathbf{a}_1 = 0$ 下最大化 $\text{var}(\xi_2)$
 - 采用拉格朗日乘子法

- 构造拉格朗日函数：

$$L(\mathbf{a}_2, \lambda, \beta) = \underbrace{\mathbf{a}_2^\top \Sigma \mathbf{a}_2}_{\text{公式 10-14}} - \lambda(\mathbf{a}_2^\top \mathbf{a}_2 - 1) - \beta(\mathbf{a}_2^\top \mathbf{a}_1)$$

- 对 $\mathbf{a}_2$ 求偏导并令其为零：

$$\frac{\partial L}{\partial \mathbf{a}_2} = 2\Sigma \mathbf{a}_2 - 2\lambda \mathbf{a}_2 - \beta \mathbf{a}_1 = \mathbf{0}$$

- 上式两侧左乘 $\mathbf{a}_1^\top$

$$2\mathbf{a}_1^\top \Sigma \mathbf{a}_2 - 2\lambda \mathbf{a}_1^\top \mathbf{a}_2 - \beta \mathbf{a}_1^\top \mathbf{a}_1 = 0$$

! 等号右侧从
向量变成了标量

10.3 主成分分析 (PCA)

- 考虑第二个新特征 ξ_2
 - 在约束条件 $\mathbf{a}_2^T \mathbf{a}_2 = 1$ 和 $\mathbf{a}_2^T \mathbf{a}_1 = 0$ 下最大化 $\text{var}(\xi_2)$
 - 采用拉格朗日乘子法

- 上式两侧左乘 $\mathbf{a}_1^T$

$$\boxed{2\mathbf{a}_1^T \Sigma \mathbf{a}_2} - 2\lambda \mathbf{a}_1^T \mathbf{a}_2 - \beta \mathbf{a}_1^T \mathbf{a}_1 = 0$$

- 第一项

$$\mathbf{a}_1^T \Sigma \mathbf{a}_2 = (\Sigma \mathbf{a}_1)^T \mathbf{a}_2 = \lambda_1 \mathbf{a}_1^T \mathbf{a}_2 = 0$$

- 第二项 和 第三项

- 第二项: $\mathbf{a}_1$ 与 $\mathbf{a}_2$ 正交 等于 0

- 第三项: $\mathbf{a}_1^T \mathbf{a}_1 = 1$

10.3 主成分分析 (PCA)

- 考虑第二个新特征 ξ_2
 - 在约束条件 $\mathbf{a}_2^T \mathbf{a}_2 = 1$ 和 $\mathbf{a}_2^T \mathbf{a}_1 = 0$ 下最大化 $\text{var}(\xi_2)$
 - 采用拉格朗日乘子法

- 上式两侧左乘 $\mathbf{a}_1^T$

$$\underbrace{2\mathbf{a}_1^T \Sigma \mathbf{a}_2}_{\text{等于 } 0} - \underbrace{2\lambda \mathbf{a}_1^T \mathbf{a}_2}_{\text{等于 } 0} - \underbrace{\beta \mathbf{a}_1^T \mathbf{a}_1}_{\text{等于 } \beta} = 0$$

- 推出 $\beta = 0$

- 将 $\beta = 0$ 代回偏导条件:

$$2\Sigma \mathbf{a}_2 - 2\lambda \mathbf{a}_2 = \mathbf{0} \implies \Sigma \mathbf{a}_2 = \lambda \mathbf{a}_2$$

说明 $\mathbf{a}_2$ 同样是协方差矩阵 Σ 的本征向量


10.3 主成分分析 (PCA)

- 考虑第二个新特征 ξ_2
 - 在约束条件 $\mathbf{a}_2^T \mathbf{a}_2 = 1$ 和 $\mathbf{a}_2^T \mathbf{a}_1 = 0$ 下最大化 $\text{var}(\xi_2)$
 - 采用拉格朗日乘子法

- 带回目标函数：

$$\text{var}(\xi_2) = \mathbf{a}_2^T \Sigma \mathbf{a}_2 = \mathbf{a}_2^T (\lambda \mathbf{a}_2) = \underbrace{\lambda \mathbf{a}_2^T \mathbf{a}_2}_{=1} = \lambda$$

- 为使方差最大，应取协方差矩阵 Σ 所有满足正交约束 $\mathbf{a}_2^T \mathbf{a}_1 = 0$ 的本征值中最大者
 - **！ 实对称矩阵 (Σ) 不同本征值的本征向量正交**
 - 由于 $\mathbf{a}_1$ 已对应最大本征值 λ_1 ，因此 $\mathbf{a}_2$ 是 Σ 第二大本征值 λ_2 对应的本征向量



10.3 主成分分析 (PCA)

- 考虑第 k 个新特征 ξ_k
 - 在约束条件 $\mathbf{a}_k^T \mathbf{a}_k = 1$ 和 $\mathbf{a}_k^T \mathbf{a}_i = 0$ ($i = 1, 2, \dots, k-1$) 下最大化 $\text{var}(\xi_k)$
 - 由同样的推导可得: $\mathbf{a}_k$ 是 Σ 第 k 大本征值 λ_k 对应的本征向量
 - 对应的方差为 $\text{var}(\xi_k) = \lambda_k$
 - 一般结论:
 - 取前 d' 个本征向量构成变换矩阵 $\mathbf{A} = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_{d'}]$, 则 $\xi = \mathbf{A}^T \mathbf{x}$ 将原始 d 维特征压缩到 d' 维
 - 各主成分互不相关, 且方差依次递减: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_{d'}$



10.3 主成分分析 (PCA)


- 一般结论

- 取前 d' 个正交归一的本征向量构成变换矩阵 $\mathbf{A} = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_{d'}]$ ，则 $\boldsymbol{\xi} = \mathbf{A}^T \mathbf{x}$ 将原始 d 维特征压缩到 d' 维

- 正交归一变换矩阵 $\mathbf{A}$ 满足的性质

$$\mathbf{A}^T \mathbf{A} = \mathbf{I}$$

$$\mathbf{A}^T = \mathbf{A}^{-1}$$



10.3 主成分分析 (PCA)

- 一般结论

- 各主成分互不相关，且方差依次递减： $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_{d'}$
- 全部主成分的方差之和等于本征值之和：

$$\sum_{i=1}^p \text{var}(\xi_i) = \sum_{i=1}^p \lambda_i$$

- 逆变换：


- $\xi = A^T \mathbf{x}$ 两侧分别左乘 A ：

$$\begin{aligned} \mathbf{A}\xi &= \mathbf{A}\mathbf{A}^T \mathbf{x} \\ &= \mathbf{x} \end{aligned}$$


10.3 主成分分析 (PCA)

■ 流程

- 1. 每个样本进行零均值化。 $x_i - \mu$, 其中 μ 是均值向量



原始数据




減去均值

10.3 主成分分析 (PCA)

■ 流程


- 2. 计算协方差矩阵 $\Sigma = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T$
- 3. 计算本征值与本征向量



10.3 主成分分析 (PCA)

■ 流程

- 4. 选择主成分。根据本征值的大小，决定保留哪些本征向量作为主成分
- 5. 降维。将原始数据投影到所选的主成分方向上 $\xi_i = A^T(x_i - \mu)$



选择第一主成分

10.3 主成分分析 (PCA)

■ 例题

已知有 4 个二维样本点：

$$\mathbf{x}_1 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad \mathbf{x}_2 = \begin{pmatrix} 3 \\ 4 \end{pmatrix}, \quad \mathbf{x}_3 = \begin{pmatrix} 5 \\ 6 \end{pmatrix}, \quad \mathbf{x}_4 = \begin{pmatrix} 3 \\ 8 \end{pmatrix}$$

请用主成分分析 (PCA) 将数据从二维降到一维。

(1) 计算样本均值向量 $\boldsymbol{\mu}$ ，并对数据进行零均值化；


(2) 计算协方差矩阵 $\boldsymbol{\Sigma}$ ；

(3) 求 $\boldsymbol{\Sigma}$ 的本征值和本征向量；

(4) 选择主成分方向；

(5) 将各样本投影到主成分方向上，求降维后的一维表示。

! PCA 是无监督学习方法，无需样本类别信息



10.3 主成分分析 (PCA)

■ 例题求解

(1) 零均值化

$$\boldsymbol{\mu} = \frac{1}{4} \sum_{i=1}^4 \mathbf{x}_i = \frac{1}{4} \begin{pmatrix} 1+3+5+3 \\ 2+4+6+8 \end{pmatrix} = \begin{pmatrix} 3 \\ 5 \end{pmatrix}$$

$$\mathbf{x}_1 - \boldsymbol{\mu} = \begin{pmatrix} -2 \\ -3 \end{pmatrix}, \quad \mathbf{x}_2 - \boldsymbol{\mu} = \begin{pmatrix} 0 \\ -1 \end{pmatrix}, \quad \mathbf{x}_3 - \boldsymbol{\mu} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad \mathbf{x}_4 - \boldsymbol{\mu} = \begin{pmatrix} 0 \\ 3 \end{pmatrix}$$

(2) 协方差矩阵

$$\boldsymbol{\Sigma} = \frac{1}{4} \sum_{i=1}^4 (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T$$

$$= \frac{1}{4} \left[\begin{pmatrix} 4 & 6 \\ 6 & 9 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} + \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 9 \end{pmatrix} \right] = \frac{1}{4} \begin{pmatrix} 8 & 8 \\ 8 & 20 \end{pmatrix} = \begin{pmatrix} 2 & 2 \\ 2 & 5 \end{pmatrix}$$

10.3 主成分分析 (PCA)

(3) 本征值和本征向量

■ 例题求解 解 $\det(\Sigma - \lambda \mathbf{I}) = 0$:

$$\det \begin{pmatrix} 2 - \lambda & 2 \\ 2 & 5 - \lambda \end{pmatrix} = \lambda^2 - 7\lambda + 6 = 0$$

一元二次方程 $ax^2 + bx + c = 0 (a \neq 0)$

利用求根公式求解: $x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$ $(\lambda - 6)(\lambda - 1) = 0 \Rightarrow \lambda_1 = 6, \lambda_2 = 1$

对 $\lambda_1 = 6$, 将 $\lambda_1 = 6$ 代入 $(\Sigma - \lambda \mathbf{I})\mathbf{a} = \mathbf{0}$ 展开得方程组:

本征方程为: $\Sigma \mathbf{a} = \lambda \mathbf{a}$, 移项得 $(\Sigma - \lambda \mathbf{I})\mathbf{a} = \mathbf{0}$

$$\begin{cases} -4a_1 + 2a_2 = 0 \\ 2a_1 - a_2 = 0 \end{cases} \Rightarrow a_2 = 2a_1$$

$\mathbf{a}_i^T \mathbf{a}_i = \|\mathbf{a}_i\|^2 = \sum_{j=1}^d a_{ij}^2 = 1$ 取 $a_1 = 1, a_2 = 2$, 归一化 $\|\mathbf{a}\| = \sqrt{1^2 + 2^2} = \sqrt{5}$ 得:

(10-11)

$$\mathbf{a}_1 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$



10.3 主成分分析 (PCA)

■ 例题求解


(3) 本征值和本征向量

对 $\lambda_2 = 1$ ，将 $\lambda_2 = 1$ 代入 $(\mathbf{\Sigma} - \lambda\mathbf{I})\mathbf{a} = \mathbf{0}$ ，展开得方程组：

$$\begin{cases} a_1 + 2a_2 = 0 \\ 2a_1 + 4a_2 = 0 \end{cases} \Rightarrow a_1 = -2a_2$$

取 $a_2 = -1$, $a_1 = 2$ ，归一化 $\|\mathbf{a}\| = \sqrt{4+1} = \sqrt{5}$ ，得：

$$\mathbf{a}_2 = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 \\ -1 \end{pmatrix}$$



10.3 主成分分析 (PCA)

■ 例题求解

(4) 选择主成分

因为 $\lambda_1 = 6 > \lambda_2 = 1$, 选择 λ_1 对应的本征向量 $\mathbf{a}_1$ 作为主成分方向。

(5) 投影降维


各样本在主成分 $\mathbf{a}_1$ 上的投影 $\xi_i = \mathbf{a}_1^T (\mathbf{x}_i - \boldsymbol{\mu})$:

$$\xi_1 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ 2 \end{pmatrix}^T \begin{pmatrix} -2 \\ -3 \end{pmatrix} = \frac{1}{\sqrt{5}}(-2 - 6) = -\frac{8}{\sqrt{5}}$$

$$\xi_2 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ 2 \end{pmatrix}^T \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \frac{1}{\sqrt{5}}(0 - 2) = -\frac{2}{\sqrt{5}}$$

$$\xi_3 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ 2 \end{pmatrix}^T \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \frac{1}{\sqrt{5}}(2 + 2) = \frac{4}{\sqrt{5}}$$

$$\xi_4 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ 2 \end{pmatrix}^T \begin{pmatrix} 0 \\ 3 \end{pmatrix} = \frac{1}{\sqrt{5}}(0 + 6) = \frac{6}{\sqrt{5}}$$



10.4.1 K-L 变换

- 与 PCA 的联系


- 二者都是对协方差矩阵（或散布矩阵）做本征值分解，找到一组正交基，将原始数据投影到这组基上，实现降维或去相关

- 与 PCA 的区别

- 优化目标不同：


- PCA：最大化投影后方差

- K-L 变换：用低维表示来近似重构原始数据，使均方误差最小，即最小化重构误差



10.4.1 K-L 变换

- 与 PCA 的区别
 - 是否利用类别信息
 - PCA 是**无监督**的，完全不考虑类别标签信息
 - K-L 变换既可以**无监督**，同时也可以实现**有监督**的特征提取
 - 总结
 - 当 K-L 变换应用于**有限维随机向量**并以**协方差矩阵**作为特征分解对象时，就退化为 PCA



10.4.1 K-L 变换


- 形式化定义

- 任意随机向量 $\mathbf{x}$ 可以用一个完备的正交归一向量系 $\mathbf{u}_j, j = 1, 2, \dots, \infty$ 展开:

$$\mathbf{x} = \sum_{j=1}^{\infty} c_j \mathbf{u}_j \quad (10-24)$$

- 公式含义: 将随机向量 $\mathbf{x}$ 表示为 $\mathbf{u}_j, j = 1, 2, \dots, \infty$ 的线性组合
- 正交归一体现在:

$$\mathbf{u}_i^T \mathbf{u}_j = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases} \quad (10-25)$$



10.4.1 K-L 变换

- 形式化定义

- 公式 10-24 两边同时左乘 $\mathbf{u}_i^T$:

$$\mathbf{u}_i^T \mathbf{x} = \mathbf{u}_i^T \sum_{j=1}^{\infty} c_j \mathbf{u}_j = \sum_{j=1}^{\infty} c_j (\mathbf{u}_i^T \mathbf{u}_j)$$

- 同时考虑公式 10-25, 最右侧只有 $j = i$ 存在, 其余全部为 0:

$$\mathbf{u}_i^T \mathbf{x} = c_i \cdot 1 = c_i \quad (10-26)$$

- 仅用有限的 d 个基向量逼近随机向量 $\mathbf{x}$:

$$\hat{\mathbf{x}} = \sum_{j=1}^d c_j \mathbf{u}_j \quad (10-27)$$

10.4.1 K-L 变换

■ 形式化定义

- 用 $\hat{x}$ 估计 x 的均方误差：

$$e = E[(\mathbf{x} - \hat{\mathbf{x}})^T (\mathbf{x} - \hat{\mathbf{x}})]$$

代入公式 10-24 与 10-27 

$$= E \left[\left(\sum_{j=d+1}^{\infty} c_j \mathbf{u}_j \right)^T \left(\sum_{j=d+1}^{\infty} c_j \mathbf{u}_j \right) \right]$$

代入公式 10-25 

$$= E \left[\sum_{j=d+1}^{\infty} c_j^2 \right]$$

代入公式 10-26 


$$= E \left[\sum_{j=d+1}^{\infty} \mathbf{u}_j^T \mathbf{x} \mathbf{x}^T \mathbf{u}_j \right]$$

期望符号提到里面 

$$= \sum_{j=d+1}^{\infty} \mathbf{u}_j^T E[\mathbf{x} \mathbf{x}^T] \mathbf{u}_j$$

• 令 $\Psi = E[\mathbf{x} \mathbf{x}^T]$:

$$e = \sum_{j=d+1}^{\infty} \mathbf{u}_j^T \Psi \mathbf{u}_j \quad (10-28)$$



10.4.1 K-L 变换

- 优化过程

- 求解带约束的最优化问题：

$$\min e = \sum_{j=d+1}^{\infty} \mathbf{u}_j^T \Psi \mathbf{u}_j \quad (10-29)$$

$$\text{s.t.} \quad \mathbf{u}_j^T \mathbf{u}_j = 1, \forall j$$

- 采用拉格朗日法，得到无约束的优化目标函数：

$$L(\mathbf{u}, \boldsymbol{\lambda}) = \sum_{j=d+1}^{\infty} \mathbf{u}_j^T \Psi \mathbf{u}_j - \sum_{j=d+1}^{\infty} \lambda_j [\mathbf{u}_j^T \mathbf{u}_j - 1] \quad (10-30)$$

- 对每个向量 $\mathbf{u}_j, j = d + 1, \dots, +\infty$ 求偏导并令其为零：

$$(\Psi - \lambda_j \mathbf{I}) \mathbf{u}_j = 0, j = d + 1, 2, \dots, +\infty \quad (10-31)$$



10.4.1 K-L 变换

- 优化过程


- 根据公式 10-31 可得：

$$\Psi \mathbf{u}_j = \lambda_j \mathbf{u}_j \quad (10-32)$$

- 即 $\mathbf{u}_j$ 是方阵 $\Psi = E[\mathbf{x}\mathbf{x}^T]$ 的本征向量
 - λ_j 是矩阵 Ψ 的本征值
 - 将公式 10-25 和公式 10-29 代入到公式 10-28中，均方误差为：

$$e = \sum_{j=d+1}^{\infty} \lambda_j \quad (10-33)$$


- **公式含义**：用 d 个基向量近似 $\mathbf{x}$ 时，重构的均方误差恰好等于被丢弃的那些本征向量所对应的本征值之和



10.4.1 K-L 变换

- d 个基向量的选择
 - 将矩阵 Ψ 的本征值接从大到小的排列
 - 选择前 d 个本征值对应的本征向量 $\mathbf{u}_j, j = 1, \dots, d$
- 样本特征提取
 - 将原始样本 $\mathbf{x}$ 投影到各个本征向量上，组成了样本的新特征向量：

$$c_j = \mathbf{u}_j^T \mathbf{x}, j = 1, \dots, d$$



10.4.1 K-L 变换

- 与 PCA 相比在产生矩阵上的不同

- PCA 的产生矩阵是协方差矩阵：

$$\Sigma = E[(\mathbf{x} - \underline{E[\mathbf{x}]})(\mathbf{x} - \underline{E[\mathbf{x}]})^T]$$

- K-L 变换的产生矩阵：

$$\Psi = E[\mathbf{x}\mathbf{x}^T]$$

- ⚠ 若去掉均值信息，此时 K-L 变换就等同于主成分分析

10.4.2 用于监督模式识别的 K-L 变换

■ 形式化定义

- 给定样本集 $(x_1, \omega_1), (x_2, \omega_2), \dots, (x_N, \omega_N), x_i \in \mathbb{R}^d, \omega_i, i = 1, \dots, c$
- 用 $\mathbf{m}_i$ 表示第 i 类样本集的均值向量:

$$\mathbf{m}_i = \frac{1}{n_i} \sum_{k=1}^{n_i} \mathbf{x}_k^{(i)} \quad (9-3)$$

- 用 $\mathbf{m}$ 表示各类样本集的总均值向量:

$$\mathbf{m} = \sum_{i=1}^c P_i \mathbf{m}_i \quad (9-4)$$

10.4.2 用于监督模式识别的 K-L 变换

■ 形式化定义

- 定义加权类间离散度矩阵 $\tilde{S}_b$ ，用于度量各类均值之间的分散程度：

$$\tilde{S}_b = \sum_{i=1}^c P_i (\mathbf{m}_i - \mathbf{m})(\mathbf{m}_i - \mathbf{m})^T \quad (9-7)$$

- 定义加权类内离散度矩阵 $\tilde{S}_w$ ，用于度量各类内部样本的分散程度：

$$\tilde{S}_w = \sum_{i=1}^c P_i \cdot \left[\frac{1}{n_i} \sum_{k=1}^{n_i} \left(\mathbf{x}_k^{(i)} - \mathbf{m}_i \right) \left(\mathbf{x}_k^{(i)} - \mathbf{m}_i \right)^T \right] \quad (9-8)$$

内层就是第 i 类的样本协方差矩阵

外层得到所有类别内部离散度的加权平均

10.4.2 用于监督模式识别的 K-L 变换

- 从类均值中提取判别信息
 - 若样本中的主要分类信息包含在均值中：
 - “主要分类信息包含在均值中”的含义
 - 各类数据分布形状相似（协方差接近）
 - 但位置不同（均值差异大）
 - 处理流程
 - 1. 根据公式 9-8 计算加权类内离散度矩阵 $\tilde{S}_w$
 - 2. 用 $\tilde{S}_w$ 作为产生矩阵进行 K-L 变换，求解本征值 λ_i 和对应的本征向量 $\mathbf{u}_i, i = 1, \dots, D$
 - 3. 得到样本新特征 $y_i = \mathbf{u}_i^T \mathbf{x}, i = 1, \dots, D$ ，各维新特征的方差是 λ_i

10.4.2 用于监督模式识别的 K-L 变换

- 从类均值中提取判别信息
 - 若样本中的主要分类信息包含在均值中：
 - 处理流程
 - 4. 根据 Fisher 准则函数公式 5-31, 计算新特征的判据值:

$$J(y_i) = \frac{\mathbf{u}_i^T \tilde{\mathbf{S}}_b \mathbf{u}_i}{\lambda_i}, \quad i = 1, 2, \dots, D \quad (10-37)$$

- 5. 根据上述判据值对新特征进行排序:

$$J(y_1) \geq J(y_2) \geq \dots \geq J(y_d) \geq \dots \geq J(y_D)$$

- 6. 选择其中前 d 个新特征, 相应的 d 个本征向量 $\mathbf{u}_i, i = 1, \dots, d$ 组成特征变换矩阵 $U = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_d]$

10.4.2 用于监督模式识别的

K-

设有两类二维样本 ($D = 2, c = 2$)，先验概率相等 $P_1 = P_2 = 0.5$ 。

第一类 ω_1 的样本 ($n_1 = 3$)：

$$\mathbf{x}_1^{(1)} = \begin{pmatrix} 2 \\ 3 \end{pmatrix}, \quad \mathbf{x}_2^{(1)} = \begin{pmatrix} -1 \\ 3 \end{pmatrix}, \quad \mathbf{x}_3^{(1)} = \begin{pmatrix} -1 \\ 0 \end{pmatrix}$$

第二类 ω_2 的样本 ($n_2 = 3$)：

$$\mathbf{x}_1^{(2)} = \begin{pmatrix} 10 \\ 7 \end{pmatrix}, \quad \mathbf{x}_2^{(2)} = \begin{pmatrix} 7 \\ 7 \end{pmatrix}, \quad \mathbf{x}_3^{(2)} = \begin{pmatrix} 7 \\ 4 \end{pmatrix}$$

要求：

(1) 计算各类均值向量 $\mathbf{m}_1, \mathbf{m}_2$ 和总均值向量 $\mathbf{m}$ 。

(2) 计算加权类内离散度矩阵 $\tilde{S}_w$ 。

(3) 对 $\tilde{S}_w$ 进行特征分解，求本征值 λ_i 和本征向量 $\mathbf{u}_i$ 。

(4) 计算加权类间离散度矩阵 $\tilde{S}_b$ 。

(5) 利用Fisher准则函数计算各新特征的判据值 $J(y_i)$ ，并选择最优的1维投影方向，写出特征变换矩阵 U 。

■ 例题

10.4.2 用于监督模式识别的 K-L 变换

■ 例题求解

(1) 均值向量

由公式(9-3), $\mathbf{m}_i = \frac{1}{n_i} \sum_{k=1}^{n_i} \mathbf{x}_k^{(i)}$:

$$\mathbf{m}_1 = \frac{1}{3} \left[\begin{pmatrix} 2 \\ 3 \end{pmatrix} + \begin{pmatrix} -1 \\ 3 \end{pmatrix} + \begin{pmatrix} -1 \\ 0 \end{pmatrix} \right] = \frac{1}{3} \begin{pmatrix} 0 \\ 6 \end{pmatrix} = \boxed{\begin{pmatrix} 0 \\ 2 \end{pmatrix}}$$

$$\mathbf{m}_2 = \frac{1}{3} \left[\begin{pmatrix} 10 \\ 7 \end{pmatrix} + \begin{pmatrix} 7 \\ 7 \end{pmatrix} + \begin{pmatrix} 7 \\ 4 \end{pmatrix} \right] = \frac{1}{3} \begin{pmatrix} 24 \\ 18 \end{pmatrix} = \boxed{\begin{pmatrix} 8 \\ 6 \end{pmatrix}}$$

由公式(9-4), $\mathbf{m} = \sum_{i=1}^c P_i \mathbf{m}_i$:

$$\mathbf{m} = 0.5 \begin{pmatrix} 0 \\ 2 \end{pmatrix} + 0.5 \begin{pmatrix} 8 \\ 6 \end{pmatrix} = \boxed{\begin{pmatrix} 4 \\ 4 \end{pmatrix}}$$

10.4.2 用于监督模式识别的 K-L 变换

■ 例题求解

(2) 加权类内离散度矩阵 $\tilde{S}_w$

由公式(9-8): $\tilde{S}_w = \sum_{i=1}^c P_i \cdot \frac{1}{n_i} \sum_{k=1}^{n_i} (\mathbf{x}_k^{(i)} - \mathbf{m}_i)(\mathbf{x}_k^{(i)} - \mathbf{m}_i)^T$

第一类偏差向量:

$$\mathbf{x}_1^{(1)} - \mathbf{m}_1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad \mathbf{x}_2^{(1)} - \mathbf{m}_1 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}, \quad \mathbf{x}_3^{(1)} - \mathbf{m}_1 = \begin{pmatrix} -1 \\ -2 \end{pmatrix}$$

$$\Sigma_1 = \frac{1}{3} \left[\begin{pmatrix} 2 \\ 1 \end{pmatrix} (2 \quad 1) + \begin{pmatrix} -1 \\ 1 \end{pmatrix} (-1 \quad 1) + \begin{pmatrix} -1 \\ -2 \end{pmatrix} (-1 \quad -2) \right]$$

$$= \frac{1}{3} \left[\begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} + \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix} + \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix} \right] = \frac{1}{3} \begin{pmatrix} 6 & 3 \\ 3 & 6 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

10.4.2 用于监督模式识别的 K-L 变换

■ 例题求解

(2) 加权类内离散度矩阵 $\tilde{S}_w$

由公式(9-8): $\tilde{S}_w = \sum_{i=1}^c P_i \cdot \frac{1}{n_i} \sum_{k=1}^{n_i} (\mathbf{x}_k^{(i)} - \mathbf{m}_i)(\mathbf{x}_k^{(i)} - \mathbf{m}_i)^T$

第二类偏差向量:

$$\mathbf{x}_1^{(2)} - \mathbf{m}_2 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad \mathbf{x}_2^{(2)} - \mathbf{m}_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}, \quad \mathbf{x}_3^{(2)} - \mathbf{m}_2 = \begin{pmatrix} -1 \\ -2 \end{pmatrix}$$

$$\Sigma_2 = \frac{1}{3} \begin{pmatrix} 6 & 3 \\ 3 & 6 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

因此:

$$\tilde{S}_w = 0.5 \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} + 0.5 \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} = \boxed{\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}}$$

10.4.2 用于监督模式识别的 K-L 变换

- 例题求解
- (3) 对 $\tilde{S}_w$ 求本征值和本征向量
解 $\det(\tilde{S}_w - \lambda \mathbf{I}) = 0$:

$$\det \begin{pmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{pmatrix} = (2 - \lambda)^2 - 1 = \lambda^2 - 4\lambda + 3 = 0$$

$$(\lambda - 3)(\lambda - 1) = 0 \Rightarrow \lambda_1 = 3, \quad \lambda_2 = 1$$

对 $\lambda_1 = 3$, 代入 $(\tilde{S}_w - 3\mathbf{I})\mathbf{a} = \mathbf{0}$:

$$\begin{cases} -a_1 + a_2 = 0 \\ a_1 - a_2 = 0 \end{cases} \Rightarrow a_2 = a_1$$

取 $a_1 = 1, a_2 = 1$, 归一化 $\|\mathbf{a}\| = \sqrt{1^2 + 1^2} = \sqrt{2}$, 得:

$$\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

10.4.2 用于监督模式识别的 K-L 变换

■ 例题求解

(3) 对 $\tilde{S}_w$ 求本征值和本征向量

对 $\lambda_2 = 1$, 代入 $(\tilde{S}_w - \mathbf{I})\mathbf{a} = \mathbf{0}$:

$$\begin{cases} a_1 + a_2 = 0 \\ a_1 + a_2 = 0 \end{cases} \Rightarrow a_2 = -a_1$$

取 $a_1 = 1, a_2 = -1$, 归一化 $\|\mathbf{a}\| = \sqrt{2}$, 得:

$$\mathbf{u}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

10.4.2 用于监督模式识别的 K-L 变换

■ 例题求解

(4) 加权类间离散度矩阵 $\tilde{S}_b$

由公式(9-7): $\tilde{S}_b = \sum_{i=1}^c P_i (\mathbf{m}_i - \mathbf{m})(\mathbf{m}_i - \mathbf{m})^T$

$$\mathbf{m}_1 - \mathbf{m} = \begin{pmatrix} 0 \\ 2 \end{pmatrix} - \begin{pmatrix} 4 \\ 4 \end{pmatrix} = \begin{pmatrix} -4 \\ -2 \end{pmatrix}, \quad \mathbf{m}_2 - \mathbf{m} = \begin{pmatrix} 8 \\ 6 \end{pmatrix} - \begin{pmatrix} 4 \\ 4 \end{pmatrix} = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$$

$$\tilde{S}_b = 0.5 \begin{pmatrix} -4 \\ -2 \end{pmatrix} (-4 \quad -2) + 0.5 \begin{pmatrix} 4 \\ 2 \end{pmatrix} (4 \quad 2) = \begin{pmatrix} 16 & 8 \\ 8 & 4 \end{pmatrix}$$

10.4.2 用于监督模式识别的 K-L 变换

■ 例题求解

(5) Fisher准则函数与特征选择

由公式(10-37): $J(y_i) = \frac{\mathbf{u}_i^T \tilde{S}_b \mathbf{u}_i}{\lambda_i}$

计算 $J(y_1)$ ($\lambda_1 = 3$) :

$$\tilde{S}_b \mathbf{u}_1 = \begin{pmatrix} 16 & 8 \\ 8 & 4 \end{pmatrix} \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 24 \\ 12 \end{pmatrix}$$

$$\mathbf{u}_1^T \tilde{S}_b \mathbf{u}_1 = \frac{1}{\sqrt{2}} (1 \quad 1) \cdot \frac{1}{\sqrt{2}} \begin{pmatrix} 24 \\ 12 \end{pmatrix} = \frac{1}{2} (24 + 12) = 18$$

$$J(y_1) = \frac{18}{3} = 6$$

10.4.2 用于监督模式识别的 K-L 变换

■ 例题求解

(5) Fisher准则函数与特征选择

由公式(10-37): $J(y_i) = \frac{\mathbf{u}_i^T \tilde{S}_b \mathbf{u}_i}{\lambda_i}$

计算 $J(y_2)$ ($\lambda_2 = 1$) :

$$\tilde{S}_b \mathbf{u}_2 = \begin{pmatrix} 16 & 8 \\ 8 & 4 \end{pmatrix} \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 8 \\ 4 \end{pmatrix}$$

$$\mathbf{u}_2^T \tilde{S}_b \mathbf{u}_2 = \frac{1}{\sqrt{2}} (1 \quad -1) \cdot \frac{1}{\sqrt{2}} \begin{pmatrix} 8 \\ 4 \end{pmatrix} = \frac{1}{2} (8 - 4) = 2$$

$$J(y_2) = \frac{2}{1} = 2$$



10.4.2 用于监督模式识别的 K-L 变换

■ 例题求解

排序与选择： $J(y_1) = 6 > J(y_2) = 2$ ，因此降至1维时选 $\mathbf{u}_1$ ，特征变换矩阵为：

$$U = [\mathbf{u}_1] = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

降维后新特征 $y = \mathbf{u}_1^T \mathbf{x}$ 。