

4.2 贝叶斯网络


- 随机变量的独立性

- 随机变量 X 和 Y 独立

- 对于随机变量 X, Y ，对它们所有可能的取值，都满足 $p(x, y) = p(x)p(y)$
 -  约定用大写字母表示随机变量，用小写字母表示随机变量的取值

- 随机变量 X 和 Y 关于 Z 条件独立

- 对于随机变量 X, Y, Z ，对它们所有可能的取值，都满足 $p(x, y | z) = p(x | z)p(y | z)$



4.2 贝叶斯网络

- 链式法则

- 作用：降低联合概率计算的复杂度
- 根据贝叶斯公式，对于高维随机变量的联合分布，可以写为下面的形式：

$$p(x_1, x_2, \dots, x_d) = p(x_d \mid x_1, x_2, \dots, x_{d-1})p(x_1, x_2, \dots, x_{d-1})$$

- 反复利用上述性质，可以得到：

(4-3)

$$p(x_1, x_2, \dots, x_d) = p(x_1)p(x_2 \mid x_1)p(x_3 \mid x_1, x_2) \cdots p(x_d \mid x_1, x_2, \dots, x_{d-1})$$
(4-4)

- 公式含义：整体的联合概率可以分解为一系列条件概率的乘积


4.2 贝叶斯网络

■ 作用

- 利用有向无环图表示随机变量之间的概率依赖关系，实现对复杂的联合概率分布的有效计算

■ 构成

- 节点: 代表一个随机变量
- 有向边: 表示随机变量之间的条件依赖关系
 - 父节点: 箭头出发的节点
 - 子节点: 箭头指向的节点



4.2 贝叶斯网络

- 作用


- 利用有向无环图表示随机变量之间的概率依赖关系, 实现对复杂的联合概率分布的有效计算

- 对图中随机变量求解联合概率

- 利用公式 4-4 将联合概率展开成一系列条件概率的乘积

$$p(x) = \prod_{i=1}^d p(x_i \mid pa_i) \quad (4-6)$$

- 贝叶斯网络中,图的结构规定了条件独立性, 每个分量 x_i 仅依赖于它的父节点集合 pa_i , 而非全部变量



4.2 贝叶斯网络


- 作用


- 利用有向无环图表示随机变量之间的概率依赖关系，实现对复杂的联合概率分布的有效计算

- 对图中随机变量求解联合概率

- 右图四个事件的联合概率可以分解为：

$$P(A, B, C, D) = P(A)P(D)P(B | A, D)P(C | B)$$





4.4 朴素贝叶斯分类器

- 介绍

- 假设各个特征的取值只依赖于类别标签，而特征之间互相条件独立

$$p(x_l x_k | \omega_i) = p(x_l | \omega_i) p(x_k | \omega_i), l, k = 1, \dots, d, k \neq l \quad (4-28)$$


- 需要求解的联合概率可以分解为：


$$p(x_1, x_2, \dots, x_d, \omega_i) = p(x_1 | \omega_i) p(x_2 | \omega_i) \cdots p(x_d | \omega_i) p(\omega_i) \quad (4-29)$$

- **公式含义**：类别标签 ω_i 是所有特征 $x_1, x_2, \dots, x_d$ 的共同父节点，各特征之间条件独立

4.4 朴素贝叶斯分类器

- 公式 4-29 对应的贝叶斯网络





4.4 朴素贝叶斯分类器


- 取值估计

- 先验概率估计

- 统计训练样本中第 i 类样本占总训练样本的比率:

$$p(Y = \omega_i) = \frac{\sum_{j=1}^N I(y_j = \omega_i)}{N} \quad (4-30)$$

- $I(\cdot)$ 是指示函数, 当括号中条件值满足时取值为 1, 不满足时取值为 0
 - N 为总样本数



4.4 朴素贝叶斯分类器

- 取值估计

- 各个特征的条件概率估计

- 在第 i 类中, 第 k 个离散特征 x_k 取值为 v_l 的估计值为:

$$p(x_k = v_l \mid Y = \omega_i) = \frac{\sum_{j=1}^N I(x_k^{(j)} = v_l, y_j = \omega_i)}{\sum_{j=1}^N I(y_j = \omega_i)} \quad (4-31)$$

- $x_k^{(j)}$ 表示第 j 个样本的第 k 个特征的取值

4.4 朴素贝叶斯分类器

■ 拉普拉斯平滑

- 避免训练样本的局限（样本量较少，或某些特征取值概率较低）
- 在估计概率分布时加入伪计数对概率值进行平滑矫正

$$p(Y = \omega_i) = \frac{\sum_{j=1}^N I(y_j = \omega_i) + 1}{N + C} \quad (4-32)$$

C 为总类别数


$$p(x_k = v_l | Y = \omega_i) = \frac{\sum_{j=1}^N I(x_k^{(j)} = v_l, y_j = \omega_i) + 1}{\sum_{j=1}^N I(y_j = \omega_i) + S_k} \quad (4-33)$$

S_k 为第 k 维特征的可能取值数


4.4 朴素贝叶斯分类器

■ 拉普拉斯平滑示意图

MLE (no smoothing)



Laplace smoothing



取值 E 的观测计数为 0

4.4 朴素贝叶斯分类器


表 4-2 一组假设的客户数据

■ 例题

16条数据：反应客户的年龄、性别、收入与是否买车的记录（4人购买，16人未购买）

利用朴素贝叶斯模型建立客户特征与是否买车之间的关系，用于对新客户是否买车进行预测

编号	年龄	性别	收入	是否购买
1	<30	男	中	否
2	≥ 30	女	中	否
3	≥ 30	女	中	否
4	≥ 30	女	低	否
5	<30	男	高	否
6	≥ 30	女	低	否
7	<30	女	低	否
8	<30	女	高	是
9	≥ 30	男	中	是
10	<30	男	高	否
11	≥ 30	女	中	否
12	<30	男	低	否
13	≥ 30	女	中	否
14	≥ 30	男	低	是
15	≥ 30	男	中	是
16	≥ 30	女	低	否



4.4 朴素贝叶斯分类器

- 例题求解

- 1. 通过拉普拉斯平滑估计类的先验概率:

$$p(\text{购买} = \text{是}) = \frac{4 + 1}{16 + 2} = \frac{5}{18}; \quad p(\text{购买} = \text{否}) = \frac{13}{18}$$

4.4 朴素贝叶斯分类器

■ 例题求解

- 2. 通过拉普拉斯平滑分别估计两个类别条件下各个特征出现的条件概率：

$$p(\text{年龄} \geq 30 \mid \text{购买} = \text{是}) = \frac{3+1}{4+2} = \frac{4}{6}; p(\text{年龄} < 30 \mid \text{购买} = \text{是}) = \frac{1+1}{4+2} = \frac{2}{6} \downarrow$$

$$p(\text{年龄} \geq 30 \mid \text{购买} = \text{否}) = \frac{7+1}{12+2} = \frac{8}{14}; p(\text{年龄} < 30 \mid \text{购买} = \text{否}) = \frac{5+1}{12+2} = \frac{6}{14} \downarrow$$


$$p(\text{性别} = \text{男} \mid \text{购买} = \text{是}) = \frac{3+1}{4+2} = \frac{4}{6}; p(\text{性别} = \text{女} \mid \text{购买} = \text{是}) = \frac{1+1}{4+2} = \frac{2}{6} \downarrow$$

$$p(\text{性别} = \text{男} \mid \text{购买} = \text{否}) = \frac{4+1}{12+2} = \frac{5}{14}; p(\text{性别} = \text{女} \mid \text{购买} = \text{否}) = \frac{8+1}{12+2} = \frac{9}{14} \downarrow$$

$$p(\text{收入} = \text{高} \mid \text{购买} = \text{是}) = \frac{1+1}{4+3} = \frac{2}{7}; p(\text{收入} = \text{中} \mid \text{购买} = \text{是}) = \frac{2+1}{4+3} = \frac{3}{7} \downarrow$$

$$p(\text{收入} = \text{低} \mid \text{购买} = \text{是}) = \frac{1+1}{4+3} = \frac{2}{7}; p(\text{收入} = \text{高} \mid \text{购买} = \text{否}) = \frac{2+1}{12+3} = \frac{3}{15};$$

$$p(\text{收入} = \text{中} \mid \text{购买} = \text{否}) = \frac{5+1}{12+3} = \frac{6}{15}; p(\text{收入} = \text{低} \mid \text{购买} = \text{否}) = \frac{5+1}{12+3} = \frac{6}{15}$$



4.4 朴素贝叶斯分类器

■ 例题求解

- 3. 对于新的一个测试样本，若其特征取值为 {年龄=38岁，性别=男，收入=高} 根据公式 4-29 预测其是否购买：

$$\begin{aligned} & p(\text{购买} = \text{是}, \text{年龄} = 38 \text{ 岁}, \text{性别} = \text{男}, \text{收入} = \text{高}) \\ &= p(\text{购买} = \text{是}) p(\text{年龄} \geq 30 \mid \text{购买} = \text{是}) p(\text{性别} = \text{男} \mid \text{购买} = \text{是}) \cdot \\ & \quad p(\text{收入} = \text{高} \mid \text{购买} = \text{是}) \\ &= \frac{5}{18} \times \frac{4}{6} \times \frac{4}{6} \times \frac{2}{7} \approx 0.035 \end{aligned}$$

4.4 朴素贝叶斯分类器

■ 例题求解

- 3. 对于新的一个测试样本，若其特征取值为 {年龄=38岁，性别=男，收入=高} 根据公式 4-29 预测其是否购买：

$$\begin{aligned} & p(\text{购买} = \text{否}, \text{年龄} = 38 \text{ 岁}, \text{性别} = \text{男}, \text{收入} = \text{中}) \\ &= p(\text{购买} = \text{否}) p(\text{年龄} \geq 30 \mid \text{购买} = \text{否}) p(\text{性别} = \text{男} \mid \text{购买} = \text{否}) \cdot \\ & \quad p(\text{收入} = \text{高} \mid \text{购买} = \text{否}) \\ &= \frac{13}{18} \times \frac{8}{14} \times \frac{5}{14} \times \frac{3}{15} \approx 0.029 \end{aligned}$$

由于 $p(\text{购买} = \text{是}, \text{年龄} = 38 \text{ 岁}, \text{性别} = \text{男}, \text{收入} = \text{高})$
 $> p(\text{购买} = \text{否}, \text{年龄} = 38 \text{ 岁}, \text{性别} = \text{男}, \text{收入} = \text{高})$
因此，预测其会购买汽车