




课程回顾






讲过的教材内容

- 第一章 概论
- 第二章 统计决策方法
- 第三章 概率密度函数的估计
- 第四章 隐马尔可夫模型与贝叶斯网络
- 第五章 线性学习机器与线性分类器
- 第六章 典型的非线性分类器
- 第八章 非参数学习机器与集成学习
- 第九章 特征选择
- 第十章 特征提取与降维表示



未讲过的教材内容

- 第七章 统计学习理论概要
- 第十一章 非监督学习与聚类
- 第十二章 深度学习
-



考试题型与范围

- 考试题型 (开卷)

- 客观题：选择题 + 填空题 (30分)
- 主观题：计算题 + 简答题 (70分)

- 考试范围

- 课件中的推导、证明过程都不考
- 本节课课件中没有提及的内容都不考
- 除明确说明课件中哪道例题不考之外，其它课件中的例题都要关注




第一章 概论

- 模式识别

- 根据样本的特征将样本划分到正确的类别中


- 相似性度量

- 曼哈顿距离
 - 欧氏距离
 - 明氏距离
 - 与前两者的关系
 - 切比雪夫距离
 - 马氏距离
 - 余弦相似度



第一章 概论

- 数据标准化
 - 极差标准化
 - 标准差标准化
- 二分类性能评价
 - 混淆矩阵
 - True Positive (真正, TP)
 - True Negative (真负, TN)
 - False Positive (假正, FP)
 - False Negative (假负, FN)



第一章 概论

- 二分类性能评价

- 评价指标

- 准确率 Accuracy

- 精确率 Precision

- 召回率 Recall


- 特异度 Specificity

- F-Measure

- β 取值的含义


- PR 曲线 与 ROC 曲线

- 横纵轴、数据平衡性、对负样本敏感性的区别




第二章 统计决策方法

- 贝叶斯公式
 - 类条件概率和后验概率区别
 - 条件概率计算公式
 - 联合概率计算公式
- 贝叶斯决策
 - 最小错误率贝叶斯决策
 - 最小风险贝叶斯决策
 - Neyman-Pearson决策准则




第二章 统计决策方法

- 最小错误率贝叶斯决策
 - 使错误率最小的分类决策就是使后验概率最大的决策
 - 多种等价形式
 - 后验概率形式
 - 先验概率及类条件概率密度形式
 - 比值形式
 - 对数形式
 - 二分类问题错误率计算公式



第二章 统计决策方法

- 最小风险贝叶斯决策
 - 决策表：损失函数以表格形式给出
 - 二分类问题多种等价形式
 - 计算公式
 - 最小风险贝叶斯决策 与 最小错误率贝叶斯决策的关系
- 聂曼-皮尔逊准则
 - 目的
 - 拉格朗日乘子法
 - 写成 $l(x) = \frac{p(x|\omega_1)}{p(x|\omega_2)}$ 形式时，三种决策规则的比较



第二章 统计决策方法

- 正态分布

- 单变量正态分布

- 公式定义

- 3σ 原则


- 多变量正态分布

- 公式定义

- 协方差矩阵计算公式

- 2×2 矩阵行列式计算

- 性质：边缘分布和条件分布的正态性、线性变换的正态性、线性组合的正态性




第二章 统计决策方法

- 正态分布概率模型下的最小错误率贝叶斯决策
 - 情况1: $\Sigma_i = \sigma^2 I, i = 1, 2, \dots, c$
 - (1) 先验概率 $P(\omega_i)$ 与 $P(\omega_j)$ 不相等时的结论, 包括分类决策面 (一般式、点法式)
 - (2) 先验概率 $P(\omega_i)$ 与 $P(\omega_j)$ 相等时的结论, 包括分类决策面 (一般式、点法式)
 - 情况2: $\Sigma_i = \Sigma$
 - 同上
 - 情况3: 各类的协方差矩阵均不相等




第二章 统计决策方法

- 正态分布且各类协方差短阵相等情况下错误率的计算
 - 标准正态累积分布表的性质
 - $\Phi(z)$: 标准正态随机变量取值小于等于 z 的概率
 - $\Phi(-z) = 1 - \Phi(z)$
 - 利用标准正态累积分布表进行错误率计算




第二章 统计决策方法

- 离散时间序列样本的统计决策
 - 马尔可夫模型定义
 - 状态转移矩阵与对数似然比矩阵
 - 马尔可夫模型下的贝叶斯决策流程



第三章 概论密度函数的估计

- 估计量评价标准
 - 无偏性和渐进无偏定义
- 最大似然估计的求解
 - 指数分布求解
 - 泊松分布求解
 - 正态分布下的最大似然估计均值跟方差的结论
 - 方差的无偏估计



第三章 概论密度函数的估计

- 贝叶斯估计


- 损失函数是平方误差时的结论
- 损失函数是绝对值损失时的结论
- 损失函数是均匀损失时的结论

- 正态分布时的贝叶斯估计

- 单变量正态分布均值的贝叶斯估计值计算

- 贝叶斯学习

- 作用：后验概率可以仅凭上一步后验+当前样本递推得到
- 单变量正态分布，均值与方差的递推公式及计算过程（前两步）



第三章 概论密度函数的估计

- 非参数估计
 - 基本原理
 - 估计方法
 - 直方图方法
 - 计算公式、缺点
 - K_N 近邻估计
 - 计算公式、优点
 - Parzen 窗法
 - d 维单位方窗函数
 - 计算公式
 - 三种方法的比较与不同

第四章 隐马尔可夫模型与贝叶斯网络

- 隐马尔可夫模型

- 初始概率、状态转移概率、发射概率定义

- 三类典型问题

- 模型评估问题

- 已知观测序列 o 背后的隐状态序列 x

- 计算观测序列似然度


- 观测序列和隐状态序列的联合概率

- 隐状态序列未知

- 前向算法计算


- 动态规划

- 后向算法计算



第四章 隐马尔可夫模型与贝叶斯网络

- 隐马尔可夫模型
 - 三类典型问题
 - 隐状态推断问题
 - 维特比算法定义
 - 维特比算法计算例题
 - 模型学习问题
 - 监督模型学习
 - 非监督模型学习
 - Baum-Welch (BW) 算法定义
 - 期望最大化 EM 算法定义




第四章 隐马尔可夫模型与贝叶斯网络

- 贝叶斯网络
 - 随机变量的独立性
 - 随机变量 X 和 Y 独立定义
 - 随机变量 X 和 Y 关于 Z 条件独立定义
 - 联合概率计算链式法则
 - 定义
 - 根据有向无环图分解联合概率




第四章 隐马尔可夫模型与贝叶斯网络

- 朴素贝叶斯分类器
 - 定义
 - 利用统计方法估计先验概率、各个特征的条件概率
 - 拉普拉斯平滑
 - 决策过程计算




第五章 线性学习机器与线性分类器

- 线性回归
 - 样本的增广特征向量定义
 - 最优参数求解
 - 2×2 矩阵行列式计算
 - 2×2 矩阵求逆矩阵
- 线性判别函数的基本概念
 - 二分类决策面点 x 到决策面的 (有符号) 距离
 - 决策面函数值与样本点 x 距离决策边界远近的关系




第五章 线性学习机器与线性分类器

- 线性 Fisher 线性判别分析
 - 动机
 - 原样本空间中：类均值向量、各类的类内离散度矩阵、总类内离散度矩阵、类间离散度矩阵计算
 - 投影后的一维空间中：类均值、各类的类内离散度值、总类内离散度值、类间离散度值计算
 - Fisher 判别准则下的最优投影方向计算公式
 - 当样本是正态分布且两类协方差矩阵相同且 $P(\omega_1) = P(\omega_2)$ 时，分类阈值 w_0 计算公式




第五章 线性学习机器与线性分类器

- 感知机
 - 规范化增广样本向量
 - 感知器准则函数
 - 梯度下降法，参数更新公式
 - 固定增量法第一轮按样本先后顺序依次检查计算
- 最小平方误差判别



第五章 线性学习机器与线性分类器


- 最优分类超平面与线性支持向量机
 - 最优分类超平面概念
 - 边界超平面概念
 - 两类分类间隔计算公式
 - 鞍点问题运算顺序与含义
 - KKT互补松弛条件
 - 正类、负类样本拉格朗日算子的关联
 - 最优权重向量 $\mathbf{w}^*$ 计算公式
 - 支持向量的概念与计算



第五章 线性学习机器与线性分类器


- 罗杰斯特回归

- 罗杰斯特（或称 Sigmoid 函数）性质与计算
- 一元与多元 logit 函数定义
- 计算未知参数对应的目标函数
- 决策过程



第五章 线性学习机器与线性分类器

- 多类线性分类器
 - 多个两类分类器的组合
 - 多类线性判别函数
 - 多类罗杰斯特回归
 - softmax 函数计算



第六章 典型的非线性分类器


- 神经元感知器
 - 模型结构
- 多个感知器实现非线性分类
 - 多层感知机结构
 - 隐藏层与输出层激活函数的区别
 - 每层以及总体模型参数量统计
 - 前向传播计算



第六章 典型的非线性分类器


- 反向传播算法

- 平方误差损失计算
- Sigmoid 函数求导
- 链式求导法则计算
- 梯度下降法参数更新公式
- 输出层、隐藏层误差信号 δ 计算
- 多层感知机算法流程




第八章 非参数学习机器与集成学习

- 最近邻法
 - 决策规则
 - 平均错误率
 - 渐进错误率
- K 近邻法
 - 决策规则
 - 通常 k 的设置
 - 渐近错误率理论分析



第八章 非参数学习机器与集成学习

- 近邻法的快速算法
 - 分枝定界算法思想
 - 粗粒度、细粒度剪枝规则计算
 - 最近邻法快速算法流程与伪代码
 - k-近邻法快速算法流程与伪代码
 - 二者的不同之处
- 剪辑近邻法
 - 作用
 - 具体流程
 - 错误率理论分析
 - 多重剪辑方法



第八章 非参数学习机器与集成学习

- 压缩近邻法
 - 基本思想
 - 完整执行过程例题
 - 判断样本是否移入储存集
- 决策树
 - 香农熵度量公式
 - 特征信息增益计算
 - 构建流程
 - Gini 不纯度度量公式
 - 误差不纯度度量公式

第八章 非参数学习机器与集成学习

■ 决策树

■ C4.5 算法

■ 信息增益率度量公式


■ 分类和回归树 (CART) 算法

■ ID3、C4.5、CART

■ 算法比较

■ 最优划分特征计算

■ 随机森林




第九章 特征选择

■ 用于分类的特征评价准则

- 从 D 个特征中选最优的 d 个特征的组合数
- 类别可分性准则满足的要求


■ 基于类内类间距离的可分性判据

- 类均值向量计算
- 总均值向量计算
- 加权类间离散度矩阵 $\tilde{S}_b$ 计算
- 加权类内离散度矩阵 $\tilde{S}_w$ 计算
- 平均平方距离判据 J_1 计算、选择最优特征子集
- 判据 $J_2 - J_5$



第九章 特征选择

- 基于概率分布的可分性判据
 - Chernoff 界限 与 Bhattacharyya 距离的关系
 - Jeffreys 散度
 - 公式定义
 - 与 KL 散度的关系
 - KL 散度公式定义与性质
 - 在两类样本都服从正态分布且两类协方差矩阵相等时
 - 计算公式
 - 与 Bhattacharyya 距离的关联
- 基于熵的可分性判据✗




第九章 特征选择

- 利用统计检验作为可分性判据
 - t -检验
 - 双边 t -检验定义
 - 单边 t -检验
 - t 分布定义与参数
 - t -分布表含义
 - 总体样本方差计算
 - t -检验统计量计算
 - 检验流程与特征选择计算




第九章 特征选择

- 利用统计检验作为可分性判据
 - 秩和检验
 - 具体做法
 - 零假设与检验统计量
 - 检验流程与特征选择计算
 - 统计检验方法与其它类别可分性判据的区别




第九章 特征选择

- 特征选择的最优算法
 - 分枝定界法思想
 - 去重规则
 - 每层保留节点数目
 - 算法流程
- 特征选择的次优算法
- 遗传算法



第十章 特征提取与降维表示


- 基于类别可分性判据的特征提取
 - 转换空间加权类间离散度矩阵 $\tilde{\mathbf{S}}_b^{(y)}$ 计算
 - 转换空间加权类内离散度矩阵 $\tilde{\mathbf{S}}_w^{(y)}$ 计算
 - 转换空间判据函数 J_1
 - 本征值、本征向量计算
 - 特征提取流程计算



第十章 特征提取与降维表示

- 主成分分析

- 特征之间互不相关概念
- 优化目标
- 新特征对应方差的计算公式
- 主成分方差之和与本征值之和的关系
- 算法流程与计算



第十章 特征提取与降维表示

- K-L 变换
 - 与主成分分析的联系与区别（包括在本征方程产生矩阵上的不同）
 - 优化目标
- 用于监督模式识别的 K-L 变换
 - 当主要分类信息包含在均值中，算法流程与计算